

Dall'interfaccia EGF–EGFR alla progettazione di peptidi e alla selezione di lead molecolari

Narrazione metodologica unitaria delle Pipeline 1–5 del progetto PEARL

Scopo del rapporto

Ricostruire in modo unitario l'intero workflow computazionale del progetto PEARL, dall'analisi strutturale dell'interfaccia extracellulare EGF–EGFR e dalla progettazione e valutazione di candidati peptidici, attraverso dinamica molecolare e ottimizzazione guidata da intelligenza artificiale, fino alla derivazione di un farmacoforo e alla selezione di piccoli ligandi. Il rapporto distingue sistematicamente risultati computazionali, score e proxy energetici, livelli di evidenza e verifiche site-specifiche, mantenendoli separati da qualsiasi conclusione di validazione sperimentale.

Sintesi metodologica

Le cinque pipeline del progetto PEARL formano un unico processo di riduzione progressiva dell'incertezza e di trasformazione del problema progettuale. Non costituiscono cinque analisi indipendenti né una semplice successione di risultati: ciascuna fase utilizza gli output e i limiti emersi nelle precedenti per introdurre un livello ulteriore di selezione, caratterizzazione o progettazione. Il workflow parte dall'analisi dell'interfaccia extracellulare EGF–EGFR e dalla definizione di un seed peptidico, procede attraverso miniaturizzazione, generazione di controfattuali, valutazione strutturale, dinamica molecolare e analisi energetica, quindi amplia lo spazio delle sequenze mediante metodi di intelligenza artificiale. Le informazioni strutturali e dinamiche vengono infine utilizzate per derivare un farmacoforo e avviare una linea di esplorazione di piccoli ligandi. I diversi livelli computazionali devono essere interpretati secondo la loro specifica funzione e non come prove sperimentali o come evidenze necessariamente indipendenti.

Pipeline	Domanda centrale	Input	Output decisionale
1 — Reverse-engineering	Quale porzione dell'interfaccia può diventare un punto di partenza peptidico?	Struttura 3NJP, interfaccia B-D	Seed ufficiale D22–51 e varianti pre-docking
2 — Miniaturizzazione e CLEAR	Quali frammenti e modifiche locali meritano una verifica strutturale più severa?	Seed lungo e hotspot	F0010; CF06, CF10, CF02; controlli CF03/CF05
3 — MD ed endpoint	Quali priorità restano convincenti quando si considera il tempo e un proxy energetico su ensemble?	Complesso B–D; F0010, CF02 e CF06	Priorità computazionale finale CF02 + CF06
4 — Ottimizzazione peptidica guidata	È possibile ampliare lo spazio delle sequenze mantenendo caratteristiche strutturali e computazionali favorevoli?	Candidati delle pipeline precedenti, struttura e informazioni di sequenza	Nuovi design ProteinMPNN/ESM-2, valutazione multi-dominio e candidati prioritari per ulteriori verifiche
5 — Farmacoforo e piccoli ligandi	Le informazioni strutturali e dinamiche possono essere tradotte in un modello farmacoforico e utilizzate per esplorare candidati small-molecule?	Ensemble MD, farmacoforo consolidato e candidati molecolari	Screening e ranking multi-criterio di piccoli ligandi, con successiva verifica della pertinenza delle pose rispetto alla native EGF–EGFR interface

1. Introduzione generale

1.1 Obiettivo scientifico e razionale PEARL

Il progetto affronta un problema tipico del design di modulatori peptidici: passare da un'interfaccia estesa, osservata in una struttura tridimensionale, a poche sequenze motivate per analisi successive e, in prospettiva, esperimenti. Il target effettivo è l'interazione extracellulare EGF–EGFR di PDB 3NJP: B è il dominio extracellulare di EGFR, D è EGF. La struttura sperimentale costituisce il punto di partenza; i confronti strutturali e la persistenza dinamica dei contatti sostengono il razionale computazionale, ma non dimostrano il legame o l'attività dei peptidi estratti.

1.2 Target EGFR/3NJP e ipotesi di lavoro

Chiarimento sul target effettivamente implementato. La proposta originaria del progetto PEARL era formulata rispetto all'interfaccia del dimero del dominio chinasi di EGFR e indicava PDB 3NJP come struttura di riferimento. L'implementazione effettivamente sviluppata utilizza invece l'interfaccia extracellulare EGF-EGFR rappresentata in 3NJP, con la catena B corrispondente alla componente extracellulare di EGFR e la catena D a EGF. A seguito del chiarimento con il supervisore, l'interazione extracellulare EGF-EGFR è stata mantenuta come target effettivo del progetto. La proposta originaria resta pertanto il riferimento storico iniziale, mentre le analisi e i risultati qui descritti si riferiscono al sistema extracellulare EGF-EGFR.

L'ipotesi operativa è che una porzione della catena D, ricavata dalla regione di contatto con la catena B, possa conservare elementi riconoscitivi dell'interfaccia e fungere da seed. Il termine reverse-engineering indica dunque un percorso che non parte da una sequenza arbitraria: osserva un'interazione strutturale, individua i residui vicini, distingue connessione geometrica e contributo energetico stimato, quindi estrae una finestra naturale continua.

Anche se il progetto è orientato alla generazione di possibili modulatori peptidici di EGFR, nessuno dei passaggi autorizza da solo a parlare di inibitore. Un peptide derivato dall'interfaccia dovrebbe ancora dimostrare di assumere una conformazione appropriata, raggiungere il sito, legare il target, competere con il partner naturale, essere selettivo e produrre un effetto biologico misurabile.

1.3 Due livelli da non confondere

Livello	Che cosa stabilisce	Che cosa non stabilisce
Prioritizzazione computazionale	Ordina candidati secondo criteri espliciti all'interno del protocollo.	Non dimostra binding o attività.
Validazione computazionale	Valuta coerenza e plausibilità con FoldX, Rosetta e MD, tenendo conto delle dipendenze tra metodi e dati.	Non equivale a validazione sperimentale.

2. Architettura unitaria del processo

Il processo può essere letto come una catena di trasformazioni dell'oggetto studiato. All'inizio l'oggetto è un'interfaccia tra proteine; diventa poi una mappa di contatti e hotspot, quindi un frammento lungo, una famiglia di frammenti annidati, un seed di 11 residui, uno spazio locale di controfattuali. A ogni trasformazione la ricerca si restringe, mentre aumenta il costo e la profondità del metodo applicato.

Passaggio	Operazione	Criterio di avanzamento
Struttura → interfaccia	Contatti entro 4,5 Å e grafo B-D	Delimitare una superficie plausibile
Interfaccia → hotspot	Alanine scanning FoldX controllato	BuildModel >1,5 kcal/mol: criterio di sensibilità mutazionale
Hotspot → seed lungo	Finestra contigua ufficiale D22-51	Copertura di interfaccia/hotspot e continuità
Seed lungo → F0010	Trimming, ranking e FlexPepDock	Compromesso miniaturizzazione/posa/hotspot

Passaggio	Operazione	Criterio di avanzamento
F0010 → controfattuali	Dataset locale, oracle GNN, CLEAR	Modifiche minime ammissibili con target predetto migliore
Controfattuali → lead	FoldX, FlexPepDock, pair score	Convergenza o divergenza interpretabile tra metriche
Lead → priorità dinamica	OpenMM, contatti, RMSD/RMSF, endpoint	Robustezza relativa nel protocollo breve

Ruolo di CLEAR nel processo. CLEAR costituisce il livello di ottimizzazione interpretabile della Pipeline 2: ricerca perturbazioni minime di F0010 che migliorino la predizione dell'oracle locale. Le proposte restano ipotesi computazionali. FoldX 05c verifica la coerenza con la stessa famiglia di informazione energetica già presente nel target dell'oracle; Rosetta/FlexPepDock e MD aggiungono valutazioni con assunzioni differenti, senza costituire validazione sperimentale.

Nel progetto hanno ruoli diversi ma complementari:

- **FoldX:** BuildModel valuta la sensibilità energetica alle mutazioni (mutation-energy sensitivity). AnalyseComplex permette invece un confronto WT-vs-Ala dell'energia di interazione B-D (interaction-energy sensitivity). Le due quantità hanno significati diversi e non misurano direttamente l'affinità sperimentale.
- **Rosetta / FlexPepDock:** Rosetta è il framework più ampio; FlexPepDock è il protocollo Rosetta specializzato nel refinement del docking peptide-proteina. Parte da una posa iniziale e ottimizza la conformazione del peptide e dell'interfaccia, generando più decoy e assegnando score energetici per identificare le pose più plausibili.

FoldX fornisce quindi uno screening energetico rapido; FlexPepDock/Rosetta aggiunge un affinamento strutturale e conformazionale della posa. Nel flusso PEARL questi strumenti aiutano a restringere e riordinare i candidati, entro i limiti dei rispettivi modelli.

3. Lavori correlati e posizionamento di PEARL

3.1 Peptidi derivati dalle interfacce e targeting di EGFR

La progettazione di modulatori peptidici a partire da interfacce proteina-proteina o proteina-ligando caratterizzate strutturalmente è una strategia consolidata per agire su interazioni difficili da affrontare con piccole molecole convenzionali. Le analisi strutturali di EGFR hanno fornito diversi esempi in cui segmenti peptidici relativamente brevi possono modulare l'attivazione del recettore mimando o perturbando motivi di interazione nativi. La struttura cristallografica associata al PDB 3NJP descrive il complesso extracellulare EGFR-EGF e fornisce la base strutturale utilizzata in PEARL per identificare la regione di interazione EGF-EGFR. È importante precisare che, nell'attuale implementazione di PEARL, il peptide estratto proviene dalla catena D di EGF che interagisce con la catena B di EGFR, anziché dall'interfaccia di dimerizzazione EGFR-EGFR in sé.

Un paradigma biologico strettamente correlato è offerto da MIG6, un regolatore negativo naturale di EGFR. Il lavoro strutturale di Zhang et al. ha mostrato che un segmento di MIG6 di circa 25 residui si lega alla superficie distale del lobo C della chinasi di EGFR e interferisce con la formazione del dimero asimmetrico attivante della chinasi. Ciò ha dimostrato che un epitopo peptidico relativamente breve può interferire efficacemente con un'ampia interfaccia proteina-proteina di EGFR.

Diversi studi hanno successivamente sfruttato le interfacce strutturali di EGFR per progettare peptidi inibitori. Hanold et al. hanno sviluppato peptidi con ponti triazolici che mimano il braccio di dimerizzazione extracellulare di EGFR; sono state utilizzate simulazioni di dinamica molecolare per valutarne la stabilità conformazionale, e il peptide EDA2 ha mostrato un'inibizione della dimerizzazione e della fosforilazione di EGFR. Fulton et al. hanno progettato peptidi conformazionalmente vincolati che mimano l'elica H dell'interfaccia del dimero asimmetrico della chinasi di EGFR. L'introduzione di vincoli covalenti ha migliorato le proprietà dei peptidi, e il peptide EHBI2 ha ridotto la fosforilazione di EGFR e Akt in saggi cellulari.

Tavakoli e Ganjalikhyani hanno seguito un percorso computazionale più esteso, derivando 31 candidati peptidici da MIG6 e valutandoli mediante docking, dinamica molecolare e MM-PBSA contro il mutante EGFR L858R. Il loro flusso di lavoro è particolarmente pertinente per PEARL perché combina già progettazione di peptidi derivati dall'interfaccia, docking, MD e valutazione energetica, sebbene non si estenda all'ottimizzazione delle sequenze guidata dall'intelligenza artificiale o al trasferimento verso piccole molecole mediato dal farmacoforo.

Altri studi incentrati su EGFR hanno utilizzato la progettazione razionale e computazionale di peptidi per perturbare l'interfaccia di dimerizzazione del recettore. Sono stati sviluppati peptidi autoinibitori derivati razionalmente dall'interfaccia di dimerizzazione asimmetrica della chinasi di EGFR, mentre Feiner et al. hanno progettato computazionalmente peptidi leganti EGFR diretti verso l'interfaccia di dimerizzazione e hanno caratterizzato sperimentalmente alcuni candidati selezionati.

Questi studi dimostrano che la progettazione di peptidi derivati dall'interfaccia contro EGFR non costituisce di per sé un concetto nuovo. L'elemento distintivo di PEARL non dovrebbe quindi essere presentato semplicemente come l'estrazione di un peptide da un'interfaccia correlata a EGFR, ma piuttosto come il modo in cui l'informazione strutturale dell'interfaccia viene successivamente propagata attraverso l'ottimizzazione guidata dall'intelligenza artificiale, la validazione dinamica e la traduzione in piccole molecole.

3.2 Metodi generali per derivare peptidi dalle interfacce proteiche

PEARL presenta anche una forte affinità concettuale con PeptiDerive di Rosetta. PeptiDerive analizza un complesso proteina-proteina di struttura risolta utilizzando una finestra peptidica scorrevole e stima quale segmento lineare contribuisca maggiormente all'energia di interazione. Questi "segmenti ad alto contributo energetico" possono quindi fungere da punti di partenza per la progettazione di inibitori peptidici.

Ciò rende PeptiDerive un riferimento di confronto particolarmente adatto per le fasi iniziali di PEARL. Un benchmark informativo confronterebbe la regione peptidica identificata dall'analisi dei contatti e dell'interfaccia di PEARL con la regione selezionata da PeptiDerive utilizzando lo stesso complesso strutturale. I risultati pertinenti comprenderebbero la sovrapposizione del segmento selezionato, la copertura dei punti chiave dell'interazione, i contatti di interfaccia e le energie di interazione stimate.

Rassegne più ampie sulla modulazione delle interazioni proteina-proteina mediante peptidi descrivono analogamente un flusso di lavoro comune basato sull'identificazione dell'interfaccia, il riconoscimento dei residui

chiave, l'estrazione o la progettazione del peptide, la stabilizzazione conformazionale e la successiva ottimizzazione. Pertanto, gli elementi concettuali iniziali di PEARL sono saldamente radicati in strategie consolidate di progettazione peptidica basata sulla struttura.

3.3 Progettazione delle sequenze peptidiche guidata dall'intelligenza artificiale

PEARL si distingue più chiaramente dalla progettazione classica di peptidi derivati dalle interfacce quando introduce metodi moderni basati su modelli linguistici delle proteine e sul ripiegamento inverso.

ProteinMPNN è un metodo di apprendimento profondo per progettare sequenze amminoacidiche compatibili con un dato scheletro strutturale. Nel benchmark originale ha ottenuto un recupero della sequenza nativa del 52,4%, rispetto al 32,9% di Rosetta nel test riportato sullo scheletro nativo. In PEARL, ProteinMPNN non viene utilizzato per scoprire l'interfaccia di interazione originale, ma per generare sequenze alternative condizionate dalla struttura dopo che il peptide di partenza è già stato identificato.

Bryant ed Elofsson hanno proposto un sistema per la progettazione di peptidi leganti che combina Foldseek, ESM-IF1 e AlphaFold2. Il loro benchmark ha confrontato direttamente ESM-IF1 e ProteinMPNN per la progettazione delle interfacce, riportando un tasso di successo più elevato per ESM-IF1 secondo il loro protocollo di valutazione. Ciò offre un confronto esterno particolarmente utile per PEARL, perché suggerisce che i benchmark futuri non dovrebbero valutare ProteinMPNN isolatamente.

Un approccio complementare è PepMLM, che genera peptidi lineari leganti condizionati dal bersaglio utilizzando un modello linguistico ESM-2 ulteriormente addestrato e non richiede una struttura del bersaglio in ingresso. PepMLM è stato valutato mediante analisi strutturali basate su AlphaFold e validato sperimentalmente in saggi di legame e degradazione. Questo approccio si differenzia da PEARL, in cui la generazione dei peptidi è informata dalla struttura e dall'interfaccia.

Per la validazione strutturale, ESMFold fornisce una predizione diretta dalla sequenza alla struttura utilizzando un modello linguistico delle proteine. All'interno di PEARL, il suo ruolo più appropriato non è quindi quello di generatore di peptidi, ma di controllo indipendente della plausibilità strutturale delle sequenze progettate.

L'idoneità allo sviluppo rappresenta un altro asse rilevante. CamSol fornisce un sistema computazionale per predire e migliorare razionalmente la solubilità delle proteine ed è quindi un termine di confronto appropriato per la fase di selezione di PEARL basata sulla solubilità e sull'idoneità allo sviluppo.

3.4 Dinamica molecolare ed estrazione del farmacoforo dinamico

Una delle scelte metodologiche centrali di PEARL consiste nel derivare il farmacoforo non da una singola struttura statica, ma da insiemi di conformazioni ottenuti mediante dinamica molecolare di complessi peptide-EGFR selezionati.

La base concettuale di questa scelta è ben supportata dalla letteratura sui farmacofori. Shrestha, Fajardo e Fiser hanno sottolineato che i farmacofori basati sui residui e derivati mediante dinamica molecolare possono incorporare flessibilità conformazionale, solvatazione e informazioni dinamiche sull'interfaccia assenti nelle rappresentazioni puramente statiche.

Un confronto recente particolarmente importante è **PPIS-MDPharma**, introdotto da Ibrahim e Zacharias nel 2026. Questo flusso di lavoro ricava caratteristiche farmacoforiche relative a legami a idrogeno, interazioni elettrostatiche, idrofobiche e aromatiche da traiettorie MD di complessi proteina-proteina, utilizzando poi questi modelli per lo screening farmacoforico su larga scala di piccole molecole.

Questa pubblicazione implica che **l'estrazione di farmacofori derivati dalla MD seguita dallo screening di piccole molecole non può essere rivendicata come un'idea intrinsecamente nuova.**

La differenza riguarda invece l'architettura del metodo. PPIS-MDPharma deriva farmacofori direttamente dalle interfacce PPI ed è progettato per scoprire stabilizzatori delle PPI. PEARL ricava un farmacoforo di consenso da diversi peptidi progettati legati a EGFR, selezionati computazionalmente e valutati dinamicamente, proseguendo poi con generazione molecolare, filtraggio basato su criteri chimici, docking con DiffDock, raffinamento con Vina e definizione integrata delle priorità.

Un solido benchmark sperimentale per PEARL confronterebbe quindi:

farmacoforo da una singola struttura

rispetto a

farmacoforo da un insieme di conformazioni MD

utilizzando la stessa libreria di composti nelle fasi successive e valutando il tasso di composti che soddisfano rigorosamente i criteri, la diversità chimica, il successo del docking, le sovrapposizioni steriche e la stabilità delle graduatorie tra metodi diversi.

3.5 Dai peptidi e dai farmacofori alle piccole molecole

Anche la traduzione delle informazioni sui peptidi o sulle interfacce proteiche in ligandi costituiti da piccole molecole è un campo consolidato. Voet e Zhang hanno esaminato la modellazione farmacoforica specificamente come strategia di screening virtuale per inibitori delle interazioni proteina-proteina costituiti da piccole molecole. Xu et al. hanno fornito un esempio pratico particolarmente pertinente utilizzando l'interazione uPA-uPAR. Hanno costruito rappresentazioni farmacoforiche e impronte di interazione dei residui dell'interfaccia nativa, effettuato lo screening di piccole molecole e identificato sperimentalmente nuovi chemiotipi capaci di perturbare la PPI.

Questo lavoro è uno dei precedenti metodologici più vicini alla Pipeline 5 di PEARL, perché segue la logica:

interazione proteica nativa

↓

informazioni critiche sull'interfaccia

↓

farmacoforo

↓

piccole molecole

↓

docking

↓

verifica sperimentale

PEARL si differenzia perché l'informazione trasferita viene ottenuta da **un insieme di traiettorie MD di complessi tra peptidi progettati ed EGFR**, anziché direttamente da una singola interfaccia cristallografica proteina-proteina nativa.

Hayward e Beekman hanno più recentemente esaminato strategie per convertire i motivi di interazione peptidici in piccole molecole non peptidiche, sottolineando che i gruppi funzionali responsabili del riconoscimento peptidico possono essere trasferiti su strutture portanti di piccole molecole opportunamente organizzate. Ciò fornisce un'adeguata giustificazione concettuale per il passaggio dal peptide alla piccola molecola implementato in PEARL.

3.6 Progettazione molecolare generativa e docking

PEARL utilizza REINVENT4 come componente di generazione molecolare. REINVENT4 è un sistema generativo a codice aperto che supporta la generazione molecolare de novo, l'apprendimento per trasferimento, l'apprendimento per rinforzo e l'ottimizzazione molecolare multiparametrica.

Nel descrivere l'attuale implementazione di PEARL occorre tuttavia mantenere una distinzione metodologica: il flusso di lavoro corrente genera molecole con REINVENT4 e successivamente applica il farmacoforo derivato dalla MD come criterio di screening. Dovrebbe pertanto essere descritto come:

generazione molecolare

→

screening farmacoforico

anziché come una **progettazione generativa interamente condizionata dal farmacoforo**, a meno che il farmacoforo stesso non venga esplicitamente incorporato nella ricompensa o nell'obiettivo di ottimizzazione di REINVENT. Per il docking, PEARL combina la generazione di pose basata su DiffDock con una rivalutazione dei punteggi e un affinamento locale mediante AutoDock Vina. AutoDock Vina è un metodo ampiamente consolidato per il docking e l'attribuzione di punteggi. Più in generale, benchmark di docking peptidico come LEADS-PEP e PepPro dimostrano la necessità di una valutazione standardizzata del posizionamento peptide-proteina e forniscono riferimenti strutturali esterni che potrebbero essere utilizzati per testare singoli componenti di PEARL oltre EGFR. LEADS-PEP contiene 53 complessi determinati sperimentalmente con peptidi di 3–12 residui, mentre PepPro contiene 89 complessi non ridondanti determinati sperimentalmente con peptidi di 5–30 residui. PepBDB offre una risorsa strutturale curata più ampia di complessi biologici peptide-proteina, adatta a studi di docking e valutazione dei punteggi.

3.7 Posizionamento di PEARL rispetto ai lavori precedenti

Nel complesso, la letteratura mostra che nessuno dei seguenti elementi è singolarmente unico:

peptidi derivati dalle interfacce, ottimizzazione strutturale dei peptidi, ProteinMPNN, progettazione basata su modelli linguistici delle proteine, dinamica molecolare, farmacofori derivati dalla MD, screening farmacoforico, trasferimento dal peptide alla piccola molecola, progettazione molecolare generativa, DiffDock o Vina.

Il potenziale contributo di PEARL risiede invece nell'integrazione sistematica di questi elementi in un unico flusso di lavoro tracciabile:

interfaccia sperimentale peptide–recettore



analisi dell’interfaccia e dei contatti



estrazione del peptide



esplorazione delle sequenze e riprogettazione guidata dall’IA



validazione strutturale e dinamica



insieme di conformazioni MD di più peptidi



farmacoforo dinamico di consenso



generazione di piccole molecole



screening farmacoforico



recupero e filtraggio basati su criteri chimici



DiffDock



raffinamento con Vina



definizione delle priorità dei candidati mediante più metodi

Una pubblicazione dovrebbe quindi evitare un’affermazione forte come “*il primo utilizzo di farmacofori derivati dalla MD per la scoperta di farmaci diretti alle PPI*”. L’ipotesi più difendibile è che PEARL fornisca un **sistema completo per trasferire informazioni da un’interazione peptide–recettore definita strutturalmente, attraverso l’ottimizzazione peptidica guidata dall’IA e la validazione dinamica, fino alla generazione di candidati costituiti da piccole molecole e alla definizione delle priorità mediante più metodi**. Lo studio PPIS–MDPharma del 2026 rende questa distinzione particolarmente importante.

4. Matrice comparativa PEARL rispetto alla letteratura

Legenda: ✓ = elemento centrale/implementato; ● = presente solo parzialmente o concettualmente; — = non costituisce una componente centrale del lavoro. Per rassegne e banche dati la matrice indica soprattutto **copertura metodologica**, non necessariamente esecuzione sperimentale.

#	Lavoro	EGFR	Peptide derivato dall'interfaccia	Progettazione con IA	Predizione del ripiegamento	MD	Energica	Farmacoforo	Peptide → piccola molecola	IA generativa	Doc king	Validazione sperimentale	Cosa manca rispetto a PEARL
1	Lu et al., 2010, EGFR-EGF/3NJP	✓	—	—	—	—	—	—	—	—	—	✓	Nessuna progettazione o ottimizzazione nelle fasi successive
2	Zhang et al., 2007, MIG6-EGFR	✓	✓	—	—	—	●	—	—	—	—	✓	Assenti IA, farmacoforo da MD e piccole molecole
3	Hanold et al., 2015, peptidi EDA	✓	✓	—	●	✓	—	—	—	—	—	✓	Assenti IA e passaggio peptide → piccola molecola
4	Fulton et al., 2018, peptidi EHBI	✓	✓	—	●	—	—	—	—	—	—	✓	Assenti insieme di conformazioni MD, farmacoforo e piccole molecole
5	Tavakoli & Ganjalikhany, 2019	✓	✓	—	—	✓	✓	—	—	—	✓	—	Assenti progettazione con IA, farmacoforo e chimica generativa
6	Peptidi razionali per la dimerizzazione di EGFR, 2020	✓	✓	—	●	●	●	—	—	—	●	✓	Assente trasferimento completo verso piccole molecole
7	Feiner et al., 2020, peptidi leganti EGFR	✓	✓	●	●	—	—	—	—	—	●	✓	Assente fase MD-farmacoforo-piccola molecola
8	Lavoro sul ripiegamento e sulla stabilizzazione di MIG6	✓	✓	—	✓	●	—	—	—	—	—	✓	Focalizzato sul peptide, non sulle successive piccole molecole
9	PeptiDerive, 2016	—	✓	—	●	—	✓	—	—	—	—	●	Assenti IA, MD, farmacoforo e piccole molecole
10	van Wier & Beekman, 2025, rassegna	●	✓	●	●	●	●	●	●	●	●	●	Rassegna, non flusso di lavoro integrato
11	Bryant & Elofsson, 2023	—	✓	✓	✓	—	—	—	—	—	●	—	Assenti MD, farmacoforo e piccole molecole
12	ProteinMPNN, Dauparas et al., 2022	—	●	✓	—	—	—	—	—	—	—	✓	Solo progettazione delle sequenze
13	ESMFold, Lin et al., 2023	—	—	✓	✓	—	—	—	—	—	—	●	Solo predizione strutturale
14	PepMLM	—	✓	✓	●	—	—	—	—	—	●	✓	Assenti MD, farmacoforo e conversione in piccole molecole
15	CamSol, Sormanni et al., 2015	—	—	●	—	—	—	—	—	—	—	✓	Solo solubilità e idoneità allo sviluppo

#	Lavoro	EGFR	Peptide derivato dall'interfaccia	Progettazione con IA	Predizione del ripiegamento	MD	Energia	Farmacoforo	Peptide → piccola molecola	IA generativa	Docking	Validazione sperimentale	Cosa manca rispetto a PEARL
16	Shrestha et al., 2021	—	●	—	—	✓	●	✓	●	—	●	—	Rassegna/ farmacoforo, non progettazione completa
17	Ibrahim & Zacharias, 2026, PPIS-MDPharma	—	—	—	—	✓	●	✓	✓	—	—	—	Assente progettazione peptidica con IA; focus sugli stabilizzatori PPI
18	Voet & Zhang, 2012	—	●	—	—	●	—	✓	✓	—	●	●	Rassegna, non percorso completo analogo a PEARL
19	Xu et al., 2017, uPA-uPAR	—	●	—	—	—	✓	✓	✓	—	✓	✓	Assenti riprogettazione peptidica con IA e consenso da MD
20	Hayward & Beekman, 2024	—	✓	—	●	—	—	●	✓	—	●	●	Rassegna; assente percorso integrato IA/MD
21	REINVENT4, Loeffler et al., 2024	—	—	✓	—	—	—	●	✓	✓	—	—	Solo chimica generativa
22	DiffDock, Corso et al.	—	—	✓	—	—	—	—	—	—	✓	●	Solo docking
23	AutoDock Vina, Trott & Olson, 2010	—	—	—	—	—	●	—	—	—	✓	—	Solo docking e valutazione dei punteggi
24	LEADS-PEP	—	✓	—	—	—	—	—	—	—	✓	✓	Benchmark di docking, non percorso di progettazione
25	PepBDB	—	✓	—	—	—	—	—	—	—	●	✓	Database strutturale, non pipeline
26	PepPro	—	✓	—	—	—	—	—	—	—	✓	✓	Benchmark di docking, non percorso di progettazione
PEARL	flusso di lavoro proposto	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	— per ora	Manca soprattutto validazione sperimentale e benchmark esterno sistematico

La lettura più importante della tabella è questa: **nessuna singola riga riproduce l'intera sequenza metodologica PEARL**, ma diversi lavori coprono in modo molto forte singoli segmenti. Questo rende necessario presentare l'originalità come **integrazione metodologica**, non come invenzione dei singoli strumenti.

4.1 Quali sono i termini di confronto più importanti

Tra i lavori e gli approcci considerati, cinque costituiscono termini di confronto particolarmente rilevanti:

1. **PeptiDerive** — termine di confronto più forte per l'estrazione del peptide dall'interfaccia.
2. **Tavakoli & Ganjalikhany 2019** — termine di confronto su EGFR per progettazione → docking → MD → energetica.
3. **Bryant & Elofsson 2023** — termine di confronto sull'IA per la progettazione di peptidi leganti e alternativa a ProteinMPNN.
4. **Ibrahim & Zacharias 2026 / PPIS-MDPharma** — termine di confronto più importante per MD → farmacoforo → piccole molecole.
5. **Xu et al. 2017** — termine di confronto più forte per trasferimento dell'informazione di una PPI verso piccole molecole mediante farmacoforo e docking.

Alla domanda “che cosa c'è effettivamente di diverso?”, il confronto con questi cinque dovrebbe essere il nucleo della risposta.

4.2 Benchmark futuri suggeriti dalla letteratura

La matrice suggerisce quattro benchmark forti.

Benchmark A – Dall'interfaccia al peptide. PEARL contro Rosetta PeptiDerive sulla stessa interfaccia, confrontando segmento selezionato, sovrapposizione dei punti chiave dell'interazione, copertura dei contatti ed eventuale energia Rosetta.

Benchmark B – Ottimizzazione peptidica con IA. Peptide di partenza originale contro mutanti casuali/locali, ProteinMPNN ed eventualmente ESM-IF1, sottoponendo tutti allo stesso protocollo di ripiegamento/struttura, MD, persistenza dei contatti, RMSD/RMSF ed energia.

Benchmark C – valore della MD per il farmacoforo. Farmacoforo estratto da una singola struttura contro il farmacoforo ottenuto dall'insieme di conformazioni MD. Questo è probabilmente il benchmark più direttamente collegato all'originalità della Pipeline 5.

Benchmark D – valore dell'integrazione finale. Graduatoria basata solo sul farmacoforo, graduatoria basata solo su DiffDock, graduatoria basata solo su Vina e graduatoria integrata di PEARL. Questo consentirebbe di verificare se la convergenza multi-metodo aggiunge robustezza rispetto a un singolo punteggio.

5. Pipeline 1 — Dalla struttura all'ipotesi peptidica

5.1 Input strutturale e mappa dell'interfaccia

La Pipeline 1 usa 3NJP e analizza la coppia B-D. Un contatto è registrato quando almeno due atomi appartenenti a residui delle due catene si trovano entro 4,5 Å. Il cutoff è un criterio geometrico operativo: identifica vicinanze plausibili, non misura la forza dell'interazione. Con questo criterio risultano 88 coppie di contatto, 43 residui di interfaccia in B e 31 in D. La rappresentazione a grafo contiene quindi 74 nodi e 88 archi.

Il numero di archi supera quello dei nodi perché uno stesso residuo può contattare più residui della catena opposta. Il grado di un nodo descrive la connettività topologica, ma non coincide con l'importanza energetica: molti contatti deboli e pochi contatti decisivi possono produrre gradi simili. Questa distinzione giustifica il passaggio successivo dall'analisi geometrica all'alanine scanning.

Contesto dell'interfaccia La coppia B-D rappresenta l'interazione extracellulare EGFR-EGF; il supporto strutturale non equivale a una validazione dei peptidi estratti.

5.2 FoldX BuildModel e verifica AnalyseComplex

L'alanine scanning storico valuta 29 sostituzioni singole nella catena D con FoldX BuildModel e una lista esplicita di mutazioni. BuildModel confronta l'energia del modello mutato con **quella del riferimento: il risultato è una FoldX mutation-energy sensitivity**, non un $\Delta\Delta G_{\text{bind}}$. La soglia >1,5 kcal/mol identifica 15 posizioni sensibili usate come design anchors; non identifica automaticamente hotspot sperimentali di binding. La successiva verifica usa FoldX AnalyseComplex sui modelli WT e Ala e confronta l'energia di interazione tra le catene B e D. La differenza $\Delta\text{Interaction} = E_{\text{interaction}}(\text{Ala}) - E_{\text{interaction}}(\text{WT})$ descrive la interaction-energy sensitivity: un valore positivo indica un'interazione meno favorevole dopo la sostituzione secondo il modello. Questa analisi è più specifica per l'interazione **rispetto a BuildModel**, ma resta una valutazione computazionale dipendente dalla preparazione e dalla funzione energetica. I 145 risultati AnalyseComplex dei modelli mutanti sono riassunti per le 29 sostituzioni; le valutazioni ripetute non sono repliche biologiche. Le etichette storiche “hotspot” nei grafici e nei vincoli di design vanno quindi lette come posizioni prioritarie derivate da BuildModel. La concordanza o divergenza fra le due analisi informa la selezione della finestra senza trasformare la sensibilità mutazionale in affinità del peptide isolato.

- 29 sostituzioni singole: confronto controllato con il WT;
- 15 design anchors storici con BuildModel >1,5 kcal/mol;
- AnalyseComplex WT-vs-Ala: sensibilità dell'energia di interazione B-D.

Integrazione visuale — Pipeline 1: interfaccia B–D e hotspot




Figura 5.1a — Matrice dei contatti residuo-residuo tra le catene B e D di 3NJP.




Figura 5.1b — Grafo dell'interfaccia B–D a livello di residuo.

Interpretazione. La matrice rende visibili le coppie residue-residuo che soddisfano il criterio geometrico di contatto, mentre il grafo mostra la connettività della stessa interfaccia. Il grado di un nodo descrive quante connessioni geometriche possiede, ma non equivale a un contributo energetico: per questo la pipeline passa successivamente all'alanine scanning con FoldX.




Figura 5.1c — Confronto del supporto strutturale relativo per le principali interfacce di 3NJP.

Interpretazione. Il confronto delle interfacce fornisce un controllo interno sulla scelta B–D e supporta l'uso di questa coppia come interfaccia operativa del prototipo. Tale supporto resta computazionale/strutturale e non sostituisce una validazione biologica sperimentale dell'assemblaggio.

5.3 Selezione del seed ufficiale D22–51

Gli hotspot non vengono concatenati artificialmente: si seleziona una finestra contigua della sequenza EGF. Dopo la verifica AnalyseComplex, il seed ufficiale è D22–51, YIEALDKYACNCVVG YIGERCQYRDLKWWE, lungo 30 aa. D21–50 è la selezione storica; le due finestre condividono 29 residui e sono quasi equivalenti.

Proprietà del seed D22–51	Valore	Interpretazione
Lunghezza	30 aa	Seed di partenza, non ancora miniaturizzato in senso stretto
Posizioni di interfaccia	23/30	Copertura geometrica ~76,7%
Design anchors BuildModel inclusi	10/15	Copertura ~66,7% dei design anchors storici
Sensibilità cumulativa AnalyseComplex	22,66614 kcal/mol	Descrittore di finestra; non affinità del frammento

D22–51 supera di poco D21–50 nella somma con segno delle sensibilità AnalyseComplex: 22,66614 contro 22,51558 kcal/mol (differenza 0,15056). Lo scambio di M21 con E51 motiva la scelta aggiornata; entrambe le finestre includono 21 residui testati. Il risultato non stabilisce un optimum sotto ogni criterio. Le somme residue descrivono copertura e priorità: non assumono additività fisica e non sono energie di legame né affinità dei frammenti estratti.

5.4 Generazione delle varianti e filtro pre-docking

Il ramo aggiornato su D22–51 valuta 194 sequenze complessive, di cui 193 varianti generate e un seed; 156 sequenze sono classificate high-priority. Il filtro pre-docking esporta 10 candidati non-seed più il seed di riferimento. Questi conteggi sostituiscono quelli del ramo storico.

Il candidato in testa dopo il filtro pre-docking aggiornato è FIEALDHFACNCIVGYIGERCQYRDLKWWE, con Y22F, K28H, Y29F e V34I. Il ranking deriva dai vincoli e dallo score operativo, non da una misura di affinità. Di seguito è descritta la logica di generazione e selezione.

5.4.1 Generazione delle varianti: dataset di training e modello diffusion

Il procedimento descritto è implementato nel notebook **03b della Pipeline 1** e comprende due fasi distinte: la costruzione di un dataset locale di addestramento mediante mutazioni conservative e la successiva generazione di sequenze mediante un modello diffusion.

Il peptide seed e la costruzione del dataset

Il seed operativo aggiornato è D22–51. Attorno a questa sequenza viene costruito il dataset locale:

YIEALDKYACNCVVG YIGERCQYRDLKWWE

La sequenza contiene **30 amminoacidi** e corrisponde alla numerazione PDB D22–51. La selezione aggiornata segue AnalyseComplex; i vincoli di generazione conservano design anchors storici derivati da BuildModel.

La costruzione del dataset precede l'addestramento del diffusion. Le varianti iniziali vengono prodotte mediante regole esplicite di mutazione che favoriscono sostituzioni all'interno dei seguenti gruppi:

Gruppo	Amminoacidi	Significato nel procedimento
AVLIM	Alanina, valina, leucina, isoleucina, metionina	Raggruppamento di residui prevalentemente idrofobici.
FWY	Fenilalanina, triptofano, tirosina	Residui aromatici.
KRH	Lisina, arginina, istidina	Residui con catene laterali basiche; la loro carica dipende anche dal contesto e dal pH.
DE	Aspartato, glutammato	Residui acidi.
STNQ	Serina, treonina, asparagina, glutammina	Residui polari non carichi nella classificazione adottata.
GP	Glicina, prolina	Raggruppamento operativo del codice: i due residui hanno effetti differenti sulla conformazione del backbone e non sono strutturalmente equivalenti.
C	Cisteina	Gruppo singolo: in questa procedura la cisteina non viene sostituita.

Questi gruppi rappresentano una semplificazione operativa delle proprietà degli amminoacidi. Quando una posizione viene scelta per la mutazione, il codice seleziona un altro residuo dello stesso gruppo, se disponibile. La conservazione del gruppo non garantisce comunque il mantenimento della struttura o della funzione.

La probabilità di mutazione dipende inoltre dal ruolo della posizione: è ridotta nei residui di interfaccia ed è ancora più bassa negli design anchors BuildModel. Il dataset viene quindi costruito per esplorare variazioni del peptide mantenendo una maggiore conservazione delle posizioni considerate importanti per l'interazione.

Il parametro di generazione del dataset è **6000**: il codice include il seed e compie **5999 tentativi di mutazione**. Dopo la deduplicazione, il dataset locale contiene **le sequenze uniche utilizzate nell'esecuzione**. **Il conteggio del training del ramo storico non va attribuito automaticamente al ramo aggiornato D22–51.**

5.4.1.2 Addestramento del modello diffusion

Il dataset locale alimenta un modello di *denoising* su sequenze amminoacidiche discrete. Durante l'addestramento, alcuni amminoacidi vengono sostituiti secondo **50 livelli di perturbazione** e la rete impara a ricostruire la sequenza originaria.

Il componente di ricostruzione è una rete convoluzionale unidimensionale con **quattro strati**, che utilizza informazioni sull'identità degli amminoacidi, sulla loro posizione nella sequenza e sul livello di perturbazione. L'addestramento viene eseguito per **25 epoche**, minimizzando una funzione di perdita cross-entropy che misura l'errore nella ricostruzione degli amminoacidi originari.

Il modello apprende quindi le regolarità presenti nel dataset locale, comprese quelle introdotte dalle regole di mutazione e dalla maggiore conservazione degli hotspot.

Generazione dei candidati e conteggio aggiornato

Terminato l'addestramento, il modello viene utilizzato per generare sequenze a partire da configurazioni amminoacidiche casuali, attraverso **50 passaggi iterativi di ricostruzione e ricampionamento**.

Il notebook richiede due gruppi di campioni:

- **700 campioni hard**, con temperatura di campionamento pari a **0,8**. A ogni passaggio, nelle posizioni designate come design anchors BuildModel viene ripristinato l'amminoacido del seed, imponendone la conservazione esatta.
- **300 campioni soft**, con temperatura pari a **1,0**. Il ripristino obbligatorio degli hotspot viene disattivato, consentendo variazioni anche in queste posizioni. Rimane comunque l'influenza del dataset di addestramento, costruito favorendone la conservazione.

La temperatura regola quanto il campionamento privilegia gli amminoacidi ai quali il modello assegna probabilità maggiori: il valore 0,8 concentra maggiormente la scelta sulle opzioni più probabili rispetto al valore 1,0.

Vengono quindi richiesti complessivamente **1000 campioni**, che possono contenere duplicati. Dopo l'unione dei due gruppi, l'aggiunta esplicita del seed e la rimozione delle sequenze duplicate, l'esecuzione documentata restituisce:

194 sequenze uniche = 193 varianti diverse dal seed + 1 seed di riferimento.

Il numero di sequenze nel training e quello dei candidati generati descrivono insiemi diversi. La deduplicazione **dell'output** non dimostra che tutte le varianti siano assenti dal dataset di addestramento.

Il procedimento costituisce un prototipo locale di generazione mediante denoising, con uno schema di campionamento semplificato. Le sequenze ottenute sono candidati da sottoporre a ranking e alle successive verifiche strutturali ed energetiche; la generazione non dimostra, da sola, affinità per EGFR o attività biologica.

Integrazione visuale — Pipeline 1: alanine scanning e selezione del seed




Figura 5.4a — Sensibilità mutazionale FoldX BuildModel della catena D. Le etichette “hotspot” e $\Delta\Delta G$ del grafico storico non indicano $\Delta\Delta G_{\text{bind}}$.




Figura 5.4b — Profilo storico BuildModel; soglia operativa 1,5 kcal/mol. Si tratta di mutation-energy sensitivity, non di energia libera di binding.

Interpretazione. Ranking e profilo localizzano le posizioni sensibili alle mutazioni BuildModel. La soglia identifica design anchors operativi; la verifica dell’energia di interazione è il successivo confronto WT-vs-Ala con AnalyseComplex descritto in §5.2.




Figura 5.4c — Profilo BuildModel della finestra storica D21–50, conservato per tracciabilità. Il seed ufficiale aggiornato è D22–51 (§5.3).

Interpretazione. Il grafico documenta l’origine della selezione e non il seed operativo aggiornato. D22–51 mantiene 29 residui della finestra storica ed è stato scelto dopo AnalyseComplex; la somma dei contributi residui non misura l’affinità del frammento.

5.4.2 Impostazione dei filtri

Nel notebook 03b, le **sequenze** generate sono sottoposte a un **ranking pre-docking** con uno score che considera:

- 35% conservazione dei design anchors BuildModel;
- 20% similarità chimico-fisica nelle posizioni d'interfaccia;
- 15% conservazione esatta dell'interfaccia;
- 10% similarità chimico-fisica globale;
- 20% bonus di novità;
- penalità per composizioni eccessive di Cys/Pro/Gly.

Questo ultimo punto riguarda la **penalizzazione di un'elevata presenza di cisteina, prolina e glicina**. Nel ranking, il codice riduce il punteggio delle sequenze nelle quali la presenza di questi amminoacidi supera le soglie previste dalla funzione di scoring. Cys, Pro e Gly indicano rispettivamente cisteina, prolina e glicina, rappresentate nelle sequenze dalle lettere C, P e G. Si tratta di un criterio euristico di composizione: la penalità contribuisce alla selezione dei candidati, ma non dimostra che una sequenza sia instabile, inadatta al legame o biologicamente inattiva. Il numero di varianti generate e quello delle **sequenze che** superano un filtro sono quantità distinte: nel ramo aggiornato le varianti non-seed sono 193, mentre le sequenze classificate high-priority sono 156.

Dopo vengono **ordinate per score** e il notebook esporta, per la validazione downstream, **seed + Top 10 candidati**.

Quindi: Seed D22-51 → dataset locale di mutazioni conservative → deduplicazione → training categorical diffusion → 1000 campionamenti (700 hard + 300 soft) → 194 sequenze uniche, incluso il seed → scoring e filtri → 10 candidati non-seed + seed.

Il numero del **training** descrive gli esempi usati per apprendere la ricostruzione; il numero dell'**output** descrive le sequenze uniche prodotte e ordinate dal generatore. Nessuno dei due dimostra affinità o attività.

Il filtro **aggiornato** conserva i candidati che rispettano i design anchors BuildModel, limitano le sostituzioni non conservative all'interfaccia e presentano rischio energetico contenuto. Il seed **viene** mantenuto separatamente dai 10 candidati selezionati, evitando che occupi uno dei posti della shortlist.

Integrazione visuale — Pipeline 1: diffusion e filtro pre-docking




Figura 5.4a — Curva di training storica del categorical diffusion; illustra il metodo e non certifica il training aggiornato D22-51.




Figura 5.4b — Composizione nel ramo storico: seed e candidato generato. La shortlist corrente è descritta in §5.4.

Interpretazione. Le figure storiche illustrano apprendimento locale e conservazione della composizione, non i risultati numerici del ramo aggiornato. Il diffusion esplora uno spazio vincolato dai design anchors e dalle regole di sostituzione; la loss non misura capacità di legame.




Figura 5.4c — Rischio energetico e score pre-docking nel ramo storico; confronto illustrativo del criterio.




Figura 5.4d — Ranking pre-docking storico. Il candidato aggiornato in testa è riportato in §5.4.

Interpretazione. Lo score penalizza il rischio energetico e favorisce il mantenimento dei design anchors. Nel ramo aggiornato D22–51 la selezione finale comprende 10 candidati non-seed più il riferimento; le figure storiche non ne rappresentano la nuova graduatoria.

5.5 Output e limite che apre la Pipeline 2

La Pipeline 1 dimostra che è possibile collegare in modo riproducibile struttura, contatti, hotspot, selezione di una finestra e ranking di varianti. Tuttavia il seed di 30 residui è ancora flessibile e potenzialmente complesso da sintetizzare, purificare e stabilizzare; il ranking non osserva direttamente la posa. Da qui nasce la necessità di miniaturizzare il frammento e di verificare il compromesso tra perdita di lunghezza e conservazione strutturale.

6. Transizione Pipeline 1 → Pipeline 2

Il seed ufficiale della Pipeline 1 è D22–51. Il ramo corto della Pipeline 2 conserva per riproducibilità la finestra storica D21–50 e i design anchors BuildModel usati per costruire la libreria. F0010, corrispondente a D38–48, è contenuto in entrambe le finestre: la revisione fatta non invalida automaticamente la sua selezione e non ridefinisce retroattivamente il dataset CLEAR.

Cambio di scala. La Pipeline 1 parte dall'interfaccia proteina–proteina e individua una finestra peptidica contigua da utilizzare per la generazione di varianti. La Pipeline 2 restringe l'attenzione a un seed peptidico più corto e alla costruzione di una libreria di varianti da sottoporre a validazione strutturale e docking.

7. Pipeline 2 — Miniaturizzazione, CLEAR e validazione strutturale

7.1 Frammenti annidati e selezione di F0010

La miniaturizzazione confronta frammenti annidati estratti dalla stessa regione della sequenza EGF. F0005, F0010 e F0001 costituiscono rispettivamente il riferimento lungo, il candidato selezionato di 11 aa e un controllo intermedio. Copertura e somme residue sono descrittori di priorità, non affinità del frammento.

Con **“frammenti annidati”** nella Pipeline 2 si intende che la miniaturizzazione non confronta peptidi corti scelti indipendentemente: parte da **una stessa regione peptidica di riferimento** e costruisce peptidi progressivamente più corti, mantenendo al loro interno la regione centrale ritenuta importante.

Sono **annidati** perché il frammento più corto è contenuto nel precedente. In questo modo, quando si accorcia il peptide, non si cambia completamente regione: si eliminano progressivamente residui alle estremità mantenendo il **core/hotspot centrale**. Lo scopo è rispondere a una domanda precisa: quanto possiamo accorciare il peptide senza perdere le interazioni importanti con EGFR?

Il deep refinement riporta valori circa 0,74 per F0005, 0,68 per F0010 e 0,21 per F0001. Nel successivo FlexPepDock N20 vengono generate 60 pose (3 candidati × 20), con RMSD medio top-5 inferiore a 1 Å e conservazione completa dei design anchors storici. Gli score medi top-5 Rosetta riportati sono circa 25,7 per F0005, 22,5 per F0010 e 31,4 per F0001, con valori inferiori considerati migliori nel confronto. F0010 viene scelto perché combina miniaturizzazione e qualità della posa, mentre F0005 resta un riferimento robusto e F0001 viene de-prioritizzato.

FlexPepDock N20 significa, nel contesto della Pipeline 2, che per quel candidato vengono generate/raffinate **20 pose strutturali** mediante **Rosetta FlexPepDock**.

Quindi N20 non indica 20 amminoacidi. Il motivo è che il docking non produce necessariamente un'unica soluzione. FlexPepDock esplora diverse conformazioni del peptide rispetto al recettore e restituisce più possibili complessi: per ciascuna posa Rosetta calcola degli score energetici. In questo modo non si giudica un candidato sulla base di **una sola geometria**, che potrebbe essere casualmente favorevole o sfavorevole, ma su un piccolo ensemble di possibili conformazioni.

Baseline della Pipeline 2 F0010 = IGERCQYRDLK: “11-aa reference peptide extracted from the native EGF sequence”. La regione sorgente è D38–48 nel full EGF; il peptide estratto è un’entità distinta e non è un ligando autonomo sperimentalmente validato.

7.2 CLEAR: razionale, rappresentazione e ruolo nella Pipeline 2

CLEAR viene utilizzato nella Pipeline 2 come framework per la ricerca di controfattuali molecolari interpretabili. Nel contesto di PEARL, l’obiettivo non è generare liberamente peptidi molto diversi dal candidato di partenza, ma rispondere a una domanda più circoscritta: quali modifiche minime della sequenza di F0010 possono aumentare il target computazionale predetto mantenendo il peptide il più possibile vicino al seed?

Punto di partenza. Il peptide miniaturizzato selezionato nella fase precedente è **F0010 = IGERCQYRDLK**, lungo 11 amminoacidi. Nel modello locale ogni peptide è rappresentato come un grafo lineare: i residui sono i nodi, i residui consecutivi sono collegati da archi e le feature dei nodi includono l'identità amminoacidica, la posizione nella sequenza e l'indicazione delle posizioni hotspot. La topologia della catena resta sostanzialmente fissa; ciò che CLEAR esplora sono soprattutto sostituzioni amminoacidiche locali e ammissibili.

Che cosa significa “controfattuale”. Un controfattuale risponde alla domanda: «qual è la modifica più piccola che devo apportare a questo peptide affinché il modello predica un risultato migliore?». Un esempio minimo emerso nel progetto è **IGERCQYRELK**, ottenuto da F0010 con la singola sostituzione **D9E**. Il valore interpretativo deriva proprio dalla minimalità: la differenza rispetto al seed è esplicita e può essere ricondotta a una o poche sostituzioni, anziché a una sequenza completamente differente.

CLEAR non misura direttamente il binding. La ricerca è guidata da un oracle predittivo, non da una misura sperimentale di affinità. In PEARL l'oracle è una GNN addestrata su uno spazio locale di 539 sequenze costruite intorno a F0010: 1 seed, 38 varianti singole e 500 varianti doppie. Il modello apprende il target composito disponibile nel progetto e CLEAR lo interroga per individuare varianti con valore predetto migliore. Di conseguenza, un miglioramento controfattuale significa inizialmente miglioramento secondo l'oracle locale, non dimostrazione di maggiore affinità per EGFR.

Equilibrio tra miglioramento e minimalità. La funzione controfattuale deve conciliare due obiettivi: aumentare il target predetto e limitare la distanza dal seed. La calibrazione di LAMBDA_DISTANCE è quindi sostanziale. Una penalizzazione troppo elevata impedisce al metodo di allontanarsi da F0010; una penalizzazione troppo debole riduce la leggibilità del controfattuale. Nel progetto la regolazione di questo termine ha permesso ai restart soft di convergere su D9E e al beam search di identificare combinazioni doppie, mantenendo la ricerca in uno spazio locale interpretabile.

FoldX 05c valuta esplicitamente le varianti, ma appartiene alla stessa information family già usata nel target composito dell'oracle: è soprattutto un controllo di coerenza computazionale, non una validazione indipendente. Rosetta/FlexPepDock e MD introducono assunzioni differenti. Il loro supporto rimane computazionale e non dimostra binding, inibizione o attività.

Ruolo di CLEAR in PEARL. CLEAR esplora localmente lo spazio delle sequenze e propone modifiche minime motivate dall'oracle. I successivi controlli strutturali ed energetici valutano queste ipotesi tenendo conto delle dipendenze tra dati, target e modelli. Un migliore score non sostituisce una verifica sperimentale.

Schema operativo: F0010 → dataset locale → oracle GNN → CLEAR → controfattuali minimi → FoldX → FlexPepDock/Rosetta → MD.

Rimando alle figure. La descrizione del metodo è accompagnata, nelle sezioni successive, dai grafici della distribuzione del target composito nel dataset locale (Figura 7.3e), del confronto tra valori predetti dalla GNN e valori di riferimento nel test set (Figura 7.3f) e del rapporto tra numero di mutazioni e miglioramento predetto dei controfattuali CLEAR (Figura 7.6a). Queste figure documentano il funzionamento del modello e i risultati della ricerca controfattuale. I valori di riferimento sono quelli del target computazionale utilizzato per addestrare e valutare l'oracle; non rappresentano misure sperimentali di affinità per EGFR.

7.3 Dataset locale e oracle GNN

Intorno a F0010 viene costruito uno spazio locale di 539 sequenze: il seed, 38 varianti singole e 500 doppie. Ogni peptide è rappresentato come un grafo lineare di 11 nodi collegati tra residui consecutivi; le feature includono identità amminoacidica, posizione e indicazione di hotspot. L'obiettivo non è apprendere una legge generale dell'affinità, ma un oracle locale che ordini varianti vicine al seed secondo il target composito disponibile. In sostanza è stata addestrata una GNN come oracle locale di CLEAR per predire il target composito dei peptidi. Sul test set l'oracle mostra buone prestazioni (R^2 0,801, Spearman 0,896 e MAE 0,0446). Una semplice regressione Ridge fornisce una baseline competitiva, indicando che la GNN non è scelta esclusivamente per un vantaggio predittivo, ma soprattutto perché può essere integrata come modello differenziabile nell'ottimizzazione controfattuale di CLEAR.

Metrica oracle	Valore	Lettura corretta
R^2 test	0,801	Capacità di regressione nel dominio locale
Spearman ρ	0,896	Buona conservazione del ranking locale
MAE	0,0446	Errore medio sul target composito

7.4 CLEAR come ricerca controfattuale interpretabile

Operativamente, sulla base del razionale descritto nel §7.2, CLEAR cerca modifiche minime e ammissibili capaci di aumentare il target predetto. Dal seed IGERCQYRDLK emerge il controfattuale minimo IGERCQYRELK, cioè D9E, con miglioramento predetto di circa +0,063. Sono identificati 36 controfattuali sopra soglia. Il migliore secondo l'oracle è CF02, IGERCQYRELK (C5S + D9E), con miglioramento previsto di circa +0,0958; CF01 (Q6E + R8K) è segnalato come l'unico controfattuale sopra soglia realmente nuovo rispetto al dataset locale.

Il parametro **LAMBDA_DISTANCE** regola il compromesso tra miglioramento del target predetto e conservazione della sequenza del peptide di partenza. Esso determina il peso della penalità associata alle modifiche rispetto al seed: valori elevati favoriscono una maggiore somiglianza con la sequenza iniziale, mentre valori più bassi consentono un'esplorazione più ampia. Nel protocollo CLEAR, la sua calibrazione serve quindi a individuare varianti che migliorino il target computazionale con un numero contenuto di sostituzioni, mantenendo interpretabile la differenza rispetto al peptide originale.

La calibrazione di **LAMBDA_DISTANCE** è parte sostanziale del metodo: una penalità inizialmente troppo forte impediva alla componente soft di allontanarsi dal seed. Dopo la correzione, i restart soft convergono su D9E e il beam search identifica combinazioni doppie. La minimalità non è quindi uno slogan, ma un termine esplicito in equilibrio con il miglioramento predetto.

Integrazione visuale — Pipeline 2: miniaturizzazione e oracle locale




Figura 7.4a — Numero medio/massimo di hotspot in funzione della lunghezza del frammento.




Figura 7.4b — Densità di hotspot e frazione di interfaccia nei frammenti annidati.

Interpretazione. La miniaturizzazione non seleziona sequenze corte indipendenti, ma frammenti annidati della stessa regione. Riducendo la lunghezza aumenta la concentrazione funzionale relativa, ma si rischia di perdere contributi e contatti. F0010 (11 aa) viene mantenuto come compromesso tra compattezza e conservazione del core riconoscitivo.




Figura 7.4c — Ranking di deep refinement FlexPepDock dei tre frammenti prioritari.




Figura 7.4d — Migliori pose: RMSD del peptide e ritenzione dei contatti nativi.

Interpretazione. Il deep refinement aggiunge una verifica della posa, non presente nel ranking puramente energetico. F0010 mantiene una qualità strutturale competitiva pur essendo più corto del riferimento lungo F0005, mentre il controllo F0001 viene de-prioritizzato.




Figura 7.4e— Distribuzione del target composto nel dataset locale.




Figura 7.4f — Oracle GNN: target predetto e target computazionale di riferimento nel test set.

Interpretazione. L’oracle è intenzionalmente locale: apprende a ordinare varianti vicine a F0010, non a predire un’affinità universale. La relazione predetto-vs-target computazionale è coerente con le metriche riportate nel testo (R^2 0,801; Spearman 0,896; MAE 0,0446) e giustifica l’uso della GNN come funzione differenziabile per CLEAR.

7.5 Controllo FoldX della coerenza delle proposte

Nel notebook 05c, FoldX BuildModel valuta la variazione energetica **delle** varianti rispetto al riferimento. Questa mutation-energy sensitivity, storicamente etichettata $\Delta\Delta G$ FoldX, non è $\Delta\Delta G_{\text{bind}}$. Valori più negativi sono più favorevoli nel modello; CF02 è il candidato favorito del pannello, mentre **CF01 ha valore positivo**. Poiché informazione FoldX contribuisce già al target dell’oracle, 05c non costituisce evidenza indipendente dalla stessa famiglia informativa.

Viene inoltre verificata la presenza di **clash sterici**, ossia contatti troppo ravvicinati tra atomi, che segnalano possibili incompatibilità geometriche nella struttura. Nei candidati prioritari non vengono rilevati clash secondo i criteri del controllo adottato: questo sostiene la plausibilità geometrica delle strutture, ma non dimostra che i peptidi si leghino efficacemente a EGFR. Anche il $\Delta\Delta G$ di FoldX rimane una stima computazionale e non costituisce una misura sperimentale dell’affinità di legame.

Candidato	Mutazioni principali	ΔE BuildModel (kcal/mol)
CF02	C5S + D9E	−1,97 circa
CF03	D9E	−1,80
CF05	Q6E + D9E	−1,77
CF06	D9E + K11R	−1,31
CF10	D9E + K11Q	−1,23
CF01	Q6E + R8K	+0,19

7.6 Verifica più severa della posa: FlexPepDock

Il confronto seed-vs-CLEAR comprende F0010 e cinque controfattuali, con 20 pose per candidato, per un totale di 120 pose. Il ranking composito Rosetta è CF06 0,80; CF10 0,76; CF02 0,67; CF05 0,45; F0010 0,43; CF03 0,18. Il risultato più istruttivo è CF03: D9E da sola è favorita da CLEAR e FoldX, ma termina ultima nel ranking Rosetta. La pipeline non cerca conferme automatiche dell'oracle; usa metodi successivi per eliminare ipotesi fragili.

La priorità a questo livello diventa CF06 (IGERCQYRELQ; D9E + K11R), seguita da CF10 (IGERCQYRELQ; D9E + K11Q), mentre CF02 rimane il lead più forte lungo il percorso CLEAR/FoldX. Le doppie mutazioni che contengono D9E appaiono più robuste della mutazione isolata.

7.7 Interpretabilità pairwise

L'adjacent-pair scoring assegna costi empirici e posizione-specifici alle coppie consecutive. Nel pannello storico CF05 è favorito dal pair score, mentre CF06 è primo secondo Rosetta. La correlazione con FoldX (Pearson 0,890) è descrittiva del piccolo campione. Il pair score deriva dal medesimo target locale usato dall'oracle: serve a interpretarne il comportamento, non costituisce un'energia fisica né una linea indipendente di evidenza. La Pipeline 3 confronta F0010, CF06 e CF02.

Integrazione visuale — Pipeline 2: CLEAR e valutazioni strutturali




Figura 7.7a — CLEAR: compromesso tra numero di mutazioni e miglioramento predetto.




Figura 7.7b — Mutazioni ricorrenti tra i migliori controfattuali.

Interpretazione. La minimalità rende leggibile il miglioramento predetto dall'oracle. Le sostituzioni ricorrenti indicano preferenze del target locale; FoldX 05c ne controlla la coerenza nella stessa famiglia informativa, mentre il refinement usa un diverso modello.




Figura 7.7c — Miglioramento CLEAR e sensibilità BuildModel ($\Delta\Delta G$ FoldX nell'etichetta storica): confronto entro la stessa famiglia informativa.




Figura 7.7d — Ranking FoldX-strutturale dei controfattuali CLEAR.

Interpretazione. FoldX fornisce un controllo esplicito di coerenza: CF02 risulta favorevole, CF01 sfavorevole. La componente FoldX è già presente nel target dell'oracle; la concordanza non va conteggiata come validazione indipendente né come dimostrazione di affinità.




Figura 7.7e — Ranking finale seed vs controfattuali dopo FlexPepDock.

Interpretazione. FlexPepDock introduce una verifica più severa della posa e porta CF06 e CF10 ai primi posti, con CF02 ancora competitivo. Il caso CF03 è particolarmente istruttivo: una proposta favorevole nelle fasi precedenti può essere de-prioritizzata quando la geometria del complesso viene raffinata. La pipeline usa quindi la discordanza tra metodi come filtro, non come anomalia da nascondere.

7.8 Output della Pipeline 2

Ruolo	Candidato	Motivo
Lead Rosetta	CF06	Miglior ranking composito; D9E + K11R
Secondo Rosetta	CF10	D9E + K11Q
Lead CLEAR/FoldX	CF02	C5S + D9E; variazione BuildModel più favorevole del pannello
Best pair score	CF05	Favorito dal costo empirico locale della Pipeline 2
Peptide di riferimento estratto	F0010	IGERCQYRDLK, 11 aa da EGF D38–48
Controllo negativo Rosetta	CF03	D9E isolata non confermata dal refinement

8. Transizione Pipeline 2 → Pipeline 3

Alla fine della Pipeline 2 il problema non è più generare molte sequenze, ma distinguere profili che vincono secondo criteri differenti. FoldX valuta cambiamenti energetici in strutture trattate essenzialmente in modo statico; Rosetta esplora e rifinisce pose; il pair score interpreta regolarità locali di sequenza. Nessuno di questi livelli descrive direttamente la permanenza dei contatti nel tempo in solvente esplicito.

La Pipeline 3 verifica dapprima l'interfaccia extracellulare B–D nel complesso con EGF completo; 07c esamina D38–48 in quel contesto. Solo 07d confronta il peptide estratto F0010 con CF02 e CF06. La sequenza principale termina con l'endpoint comparativo 07e.

9. Pipeline 3 — Verifica dinamica ed endpoint comparativo

9.1 Organizzazione dei notebook e protocollo OpenMM

La sequenza principale comprende solo 07a–07e: 07a prepara il complesso extracellulare EGF–EGFR B–D; 07b ne analizza MD e persistenza; 07c riusa la traiettoria per confrontare D38–48 nel full EGF con i design anchors FoldX; 07d confronta i peptidi estratti F0010, CF06 e CF02; 07e valuta il proxy energetico endpoint sulle loro traiettorie.

Parametro	Impostazione
Force field proteico	AMBER ff14SB
Solvente e ioni	TIP3P esplicito; 0,15 M
Condizioni	300 K; 1 bar
Timestep	2 fs
Durata prototipo	1 ns
Frame salvati	500

Con un timestep di 2 fs, 1 ns corrisponde a circa 500.000 step. Salvando 500 frame, si registra in media una configurazione ogni 1.000 step, circa ogni 2 ps. La traiettoria è quindi una successione di snapshot, non una collezione di step individuali.

9.2 Persistenza dei contatti dell'interfaccia B-D

Nel 07b si osservano 144 contatti B-D unici (cutoff heavy-atom 4,5 Å), di cui 78 persistenti in almeno il 50% dei 500 frame. Dei contatti persistenti, 67 appartengono all'insieme iniziale: la retention riportata è $67/78 = 0,858974$. Questa metrica non va confusa con la frazione rispetto agli 88 contatti cristallografici della Pipeline 1.

Il controllo di continuità PBC è PASS su tutti i 500 frame: la distanza minima B-D media è 2,669888 Å sia con coordinate dirette sia con minimum-image PBC. Non è stata necessaria alcuna ricostruzione della traiettoria. La persistenza sostiene il razionale computazionale dell'interfaccia nel prototipo da 1 ns.

9.3 07c — Regione D38–48 nel contesto di EGF completo

Il notebook 07c riusa la traiettoria 07b del complesso con full EGF: non simula il peptide F0010 estratto. Nella regione D38–48, 10 posizioni su 11 sono MD-persistent; 34 contatti persistenti con EGFR coinvolgono questa regione. Una stessa posizione può contattare più residui del recettore.

Sei residui FoldX-derived risultano anche MD-persistent: G39, R41, Q43, Y44, R45 e L47 (numerazione EGF). È supporto computazionale per la regione sorgente nel full EGF, non validazione sperimentale né prova di binding del peptide estratto F0010.

9.3.1 Concordanza tra design anchors FoldX e persistenza MD

Il confronto integra segnali **differenti**: i **design anchors storici** derivano dalla **mutation-energy sensitivity BuildModel**, mentre la **persistenza MD** descrive la **frequenza dei contatti**. La **verifica fatta con AnalyseComplex** riguarda separatamente la **interaction-energy sensitivity WT-vs-Ala**. Nessuno di questi segnali va identificato con un'affinità sperimentale.

La dinamica molecolare introduce invece la **dimensione temporale**. Il complesso non viene più considerato come una struttura rigida, ma viene osservato nei diversi frame della traiettoria. È quindi possibile verificare se i residui individuati come importanti nella struttura iniziale continuino effettivamente a partecipare alle interazioni durante la simulazione. In particolare, attraverso l'analisi della **persistenza dei contatti**, si determina con quale frequenza un determinato residuo partecipa alla rete di interazioni nel corso della traiettoria.

Nella **regione D38–48 del full EGF**, **G39, R41, Q43, Y44, R45 e L47** combinano il criterio storico FoldX-derived con la partecipazione a contatti persistenti. I vincoli del full EGF restano presenti nella traiettoria: l'estrazione del peptide cambia il contesto strutturale. La concordanza sostiene la scelta della regione sorgente come ipotesi di design. Non dimostra che F0010 isolato mantenga la stessa **conformazione, preorganizzazione o affinità**. La **valutazione del complesso recettore–peptide** estratto appartiene al successivo 07d.

Tale risultato deve tuttavia essere interpretato con cautela: la concordanza tra FoldX e MD rappresenta l'integrazione di **due evidenze computazionali**, non una dimostrazione sperimentale dell'importanza di questi residui né una misura diretta dell'affinità di binding. Una conferma definitiva richiederebbe ulteriori analisi e, soprattutto, una validazione sperimentale mediante opportuni saggi biofisici o biologici.

9.4 Confronto MD omogeneo: F0010, CF02 e CF06

I tre complessi recettore-peptide sono confrontati con lo stesso protocollo breve. RMSD descrive la deviazione dopo allineamento del recettore; RMSF la fluttuazione locale; i contatti persistenti superano la soglia del 50%. Il controllo PBC è PASS su tutti i 500 frame per F0010, CF06 e CF02: concordanza direct/minimum-image, nessuna ricostruzione della traiettoria.

Peptide	RMSD (Å)	RMSF (Å)	Contatti $\geq 50\%$	Mean persistence
CF02	0,901	0,737	43	0,603
CF06	1,293	0,904	45	0,529
F0010	1,966	1,164	43	0,541

CF02 presenta RMSD e RMSF più bassi e la mean persistence più alta tra i valori riportati: è il profilo più stabile conformazionalmente nel protocollo. CF06 mantiene 45 contatti persistenti, la rete più numerosa.

Integrazione visuale — Pipeline 3: persistenza dinamica dell'interfaccia




Figura 9.4a — Numero di contatti B-D durante la produzione MD da 1 ns.




Figura 9.4b — Heatmap della persistenza dei contatti B-D.

Interpretazione. La rete di interfaccia non resta identica alla struttura cristallografica: durante la MD alcuni contatti si perdono, altri si formano e molti persistono. La persistenza fornisce quindi un livello di evidenza dinamica complementare alla geometria statica iniziale.




Figura 9.4c — Supporto dinamico di D38–48 nel full EGF: 10/11 posizioni MD-persistent. Output aggiornato 07c.




Figura 9.4d — 34 contatti persistenti con EGFR che coinvolgono D38–48 nel full EGF. Output aggiornato 07c.

Interpretazione. La sovrapposizione FoldX-derived + MD comprende sei residui della regione D38–48 nel full EGF. Fornisce supporto computazionale al razionale di estrazione, senza validare sperimentalmente il binding o l'attività del peptide F0010.




Figura 9.4e – Rappresentazione del complesso F0010–EGFR utilizzato nella simulazione di dinamica molecolare. Il recettore è mostrato in rosa, con rappresentazione dei legami atomici e della struttura secondaria in cartoon; il peptide F0010 è evidenziato in giallo chiaro. La vista illustra la posizione del peptide rispetto alla struttura recettoriale. Solvente e ioni non sono rappresentati.




Figura 9.4f – Rappresentazione tridimensionale del complesso F0010–EGFR. Il recettore è mostrato in rappresentazione cartoon rosa salmone, mentre il peptide F0010 è evidenziato in rosso mediante una rappresentazione dei legami atomici nella regione di interazione.




Figura 9.4g – Rappresentazione del complesso CF02–EGFR utilizzato nella simulazione di dinamica molecolare. Il recettore è mostrato in rosa, con rappresentazione dei legami atomici e della struttura secondaria in cartoon; il peptide CF02 è evidenziato in giallo chiaro. La vista illustra la posizione del peptide rispetto alla struttura recettoriale. Solvente e ioni non sono rappresentati.




Figura 9.4h – Rappresentazione tridimensionale del complesso CF02–EGFR. Il recettore è mostrato in rappresentazione cartoon beige, mentre il peptide CF02 è evidenziato in rosso mediante una rappresentazione dei legami atomici nella regione di interazione.




Figura 9.4i – Rappresentazione del complesso CF06–EGFR utilizzato nella simulazione di dinamica molecolare. Il recettore è mostrato in rosa, con rappresentazione dei legami atomici e della struttura secondaria in cartoon; il peptide CF06 è evidenziato in giallo chiaro. La vista illustra la posizione del peptide rispetto alla struttura recettoriale. Solvente e ioni non sono rappresentati.




Figura 9.4j – Rappresentazione tridimensionale del complesso CF06–EGFR. Il recettore è mostrato in rappresentazione cartoon azzurro chiaro, mentre il peptide CF06 è evidenziato in rosso mediante una rappresentazione dei legami atomici.

9.4.1 Analisi dell'RMSD nel tempo

L'analisi dell'RMSD descrive la deriva conformazionale globale del peptide rispetto al primo frame della traiettoria. Valori più bassi indicano una maggiore conservazione della conformazione iniziale, pur senza costituire da soli una misura diretta dell'affinità di legame.




Figura 9.4.1 - RMSD degli atomi Cα del peptide F0010, CF02 e CF06 durante le traiettorie di dinamica molecolare, dopo allineamento del recettore. L'asse x riporta il tempo in ns e l'asse y il RMSD in Å. Le curve mostrano il comportamento dinamico dei tre peptidi lungo la simulazione.

9.4.2 Analisi dell'RMSF per residuo

L'RMSF consente di distinguere la stabilità globale dalla mobilità locale e di identificare le posizioni della sequenza maggiormente coinvolte nelle fluttuazioni.





Figura 9.4.2 – RMSF degli atomi Cα per ciascun residuo dei peptidi F0010, CF02 e CF06 durante la dinamica molecolare. L'asse x rappresenta la posizione nella sequenza peptidica e l'asse y la fluttuazione media in Å. I picchi identificano i residui con maggiore mobilità locale.

9.4.3 Persistenza dei contatti peptide-recettore

La persistenza dei contatti descrive il mantenimento dell'interfaccia durante la traiettoria. Il numero totale di contatti



persistenti e la loro persistenza media devono essere interpretati congiuntamente: una rete più numerosa non implica necessariamente che ogni contatto sia più stabile.

Figura 9.4.3 – Heatmap della persistenza dei contatti heavy-atom tra il recettore e i peptidi F0010, CF02 e CF06. Ogni riga rappresenta la coppia di residui tra la catena B del recettore e la catena D del peptide; il colore indica la frazione di frame in cui la distanza minima è risultata inferiore a 4,5 Å.

9.5 Endpoint energetico su snapshot

Il notebook 07e usa per tutti i candidati AMBER ff14SB + implicit/gbn2.xml e calcola un single-trajectory MM/GBSA-like endpoint proxy: $\Delta E_{\text{endpoint}} = E_{\text{complex}} - E_{\text{receptor}} - E_{\text{peptide}}$. Per **candidato** vengono selezionati 50 snapshot temporalmente correlati da una sola traiettoria 07d. Non sono 50 repliche indipendenti; il confronto dipende dal protocollo e non è una binding free energy assoluta.

L'idea è che si parte dalla stessa traiettoria del complesso peptide-recettore. Per ogni snapshot si considera schematicamente:

$$E_{\text{int}} \approx E_{\text{complesso}} - E_{\text{recettore}} - E_{\text{peptide}}.$$

Le tre quantità vengono ricavate a partire dalla **stessa configurazione/snapshot del complesso**. Da qui l'espressione **single-trajectory**. Complesso, recettore e peptide sono valutati a partire dalla stessa configurazione del complesso. Nel protocollo, valori più negativi sono interpretati come più favorevoli.

Peptide	Endpoint (kcal/mol)	Ranking nel proxy
CF06	$-65,66 \pm 6,80$	1
F0010	$-59,46 \pm 5,96$	2
CF02	$-56,62 \pm 4,63$	3

Limiti del proxy Le dispersioni $\pm$ riassumono gli snapshot della singola traiettoria, non l'incertezza fra repliche indipendenti. Mancano entropia conformazionale, rilassamento indipendente dei componenti, simulazioni replicate e calibrazione sperimentale. Questi valori non consentono di ricavare direttamente Kd, Ki o IC50.

9.6 Perché cambiano i ranking

I metodi interrogano proprietà differenti: FoldX la sensibilità energetica alla mutazione, Rosetta la posa rifinita, MD la dinamica dei peptidi estratti e l'endpoint le configurazioni campionate. CF02 presenta minori RMSD/RMSF; CF06 una rete persistente più numerosa e il proxy endpoint medio più favorevole. La complementarità non dimostra una graduatoria di affinità reale.

Metodo	Candidato favorito	Significato
CLEAR/FoldX	CF02	Target locale e variazione BuildModel favorevole
Rosetta	CF06	Posa rifinita e ranking composito
MD RMSD/RMSF	CF02	Stabilità conformazionale nel prototipo
Contatti persistenti	CF06	Rete sopra soglia più numerosa
Endpoint	CF06	Proxy medio più favorevole; 50 snapshot correlati

9.6.1 Follow-up CF05




Figura 9.6. Struttura iniziale del complesso CF05-EGFR utilizzata per il follow-up mediante dinamica molecolare di 1 ns. CF05 è evidenziato rispetto alla struttura del recettore. Il candidato, inizialmente favorito dal pair score, è stato sottoposto alla successiva valutazione dinamica ed energetica.

CF05 viene sottoposto a MD di 1 ns e a valutazione endpoint perché era il candidato favorito dal pair score. Il follow-up produttivo non conferma quel vantaggio. Il caso illustra il ruolo corretto di una pipeline multilivello: un candidato selezionato da uno score locale viene promosso a test più costosi, ma può essere de-prioritizzato se la previsione non si trasferisce alla dinamica e all'ensemble energetico.

9.7 Notebook supplementare per l'estensione 1→10 ns

07d_OpenMM_continue_from_1ns_to_10ns.ipynb è un notebook supplementare separato, predisposto per un'eventuale estensione delle traiettorie da 1 a 10 ns. Non appartiene alla sequenza principale 07a-07e e non è stato usato per i risultati correnti. Non è documentata qui alcuna sua esecuzione su Windows/NVIDIA.

9.8 Output della Pipeline 3

La priorità computazionale finale è mantenere CF02 e CF06 come lead complementari. CF02 rappresenta il profilo con migliore stabilità dinamica nel protocollo breve; CF06 combina il sostegno di Rosetta, la rete persistente più numerosa e l'endpoint più favorevole. Non esiste, sui dati disponibili, un vincitore universale né una dimostrazione della migliore affinità reale.

Integrazione visuale — Pipeline 3: confronto omogeneo dei lead e endpoint

Figure estratte dai notebook di produzione 07d e 07e




Figura 9.8c — Numero di contatti recettore-peptide con persistenza $\geq 50\%$ nelle tre simulazioni.

Interpretazione. La numerosità dei contatti persistenti non coincide necessariamente con il minor RMSD: CF06 conserva la rete persistente più numerosa, mentre CF02 eccelle nella stabilità conformazionale. La priorità finale nasce quindi dall'integrazione di proprietà complementari.




Figura 9.8d — Distribuzione del proxy energetico endpoint MM/GBSA-like.




Figura 9.8e — Proxy endpoint GBn2 sui 50 snapshot temporalmente correlati di ciascun candidato; una traiettoria per candidato.

Interpretazione. L'endpoint è usato come confronto energetico relativo sugli ensemble già campionati, non come stima rigorosa della ΔG di binding. CF06 presenta il valore medio più favorevole nel protocollo, mentre CF02 resta il candidato con la migliore stabilità dinamica. Il risultato sostiene la scelta di mantenere CF02 e CF06 come lead complementari anziché forzare un unico vincitore.

10.2 Limiti trasversali

- Il target implementato è EGF-EGFR extracellulare B-D; il comportamento della regione nel full EGF non dimostra quello del peptide estratto.
- I risultati dipendono da preparazione strutturale, starting pose, funzioni di scoring e parametrizzazione.
- L'oracle GNN è locale; target, FoldX 05c e pair score condividono informazione e non sono evidenze indipendenti.
- Le correlazioni su piccoli pannelli hanno valore descrittivo e non dimostrano generalizzabilità.
- Una MD di 1 ns senza repliche non dimostra convergenza né stabilità su tempi biologicamente rilevanti.
- Gli endpoint ff14SB/GBn2 sono proxy dipendenti dal protocollo; 50 snapshot correlati non costituiscono 50 repliche né una misura di energia libera assoluta.
- Mancano valutazioni sperimentali di binding, competizione, selettività, stabilità, solubilità e attività biologica.

11. Dalle Pipeline 1-3 all'ottimizzazione guidata da IA

Le Pipeline 1-3 costruiscono un razionale continuo. La prima riduce una struttura complessa a una regione peptidica motivata; la seconda comprime ulteriormente quella regione e utilizza apprendimento locale, controfattuali e refinement per produrre candidati interpretabili; la terza verifica quali priorità mantengono supporto quando l'interfaccia viene osservata come sistema dinamico e quando le configurazioni campionate vengono confrontate mediante un proxy energetico.

Al termine di questa prima parte del workflow, D22-51 costituisce il seed ufficiale dopo AnalyseComplex; F0010 è il peptide di riferimento di 11 aa derivato da EGF; CF02 presenta il profilo dinamico più stabile, mentre CF06 mostra la rete persistente più numerosa e il proxy endpoint medio più favorevole. La priorità computazionale attribuita a CF02 e CF06 integra quindi proprietà complementari nel protocollo 07a-07e e non costituisce dimostrazione di binding, competizione, inibizione o validazione sperimentale. Questi risultati forniscono il punto di partenza per la fase successiva del workflow, nella quale lo spazio delle sequenze viene ampliato mediante metodi di progettazione guidata da intelligenza artificiale.

12. Sintesi metodologica delle Pipeline 4 e 5

Dopo le Pipeline 1–3, dedicate all'analisi dell'interfaccia EGF–EGFR, alla generazione e selezione dei candidati peptidici e alla loro caratterizzazione strutturale e dinamica, le Pipeline 4 e 5 estendono il workflow PEARL lungo due direzioni complementari.

La Pipeline 4 verifica se modelli di linguaggio proteico e metodi di inverse folding possano generare e prioritizzare nuovi peptidi compatibili con l'interfaccia EGFR già studiata, sfruttando l'informazione di sequenza, struttura e interazione prodotta nelle fasi precedenti.

La Pipeline 5 compie invece un passaggio dal peptide al piccolo ligando: trasferisce l'informazione sulle interazioni persistenti osservate nelle traiettorie peptide–recettore in un modello farmacoforico e utilizza tale rappresentazione per lo screening e la successiva prioritizzazione di candidati small-molecule generati nella fase precedente..

In entrambi i casi, il risultato finale deve essere interpretato come una prioritizzazione computazionale dei candidati e non come una dimostrazione sperimentale di legame, affinità o attività biologica.

Pipeline	Domanda	Esito principale
4	Quali sequenze generate da IA conservano plausibilità, compatibilità strutturale e comportamento dinamico competitivo?	MPNN_NEW_01 offre il miglior equilibrio esplorativo; MPNN_NEW_05 conserva il miglior supporto energetico endpoint tra i nuovi peptidi.
5	Quali piccoli ligandi riproducono parte dell'ipotesi farmacoforica e mantengono proprietà chimiche e pose plausibili?	Il ranking storico o9g colloca MOL00583 al primo posto; il successivo audit della pertinenza alla vera interfaccia EGF–EGFR mostra tuttavia che la posa propagata di MOL00583 è off-site, mentre MOL00484 conserva supporto strutturale site-relevant. Non viene definito automaticamente un nuovo lead.

La selezione non forza una concordanza tra metodi. La dinamica favorisce MPNN_NEW_01, l'endpoint energetico favorisce MPNN_NEW_05, mentre i quattro finalisti della Pipeline 5 occupano regioni diverse dello spazio decisionale. Il report conserva queste divergenze perché descrivono l'incertezza reale del workflow.

12.1 Risultati chiave

- Pipeline 4: 100 campioni ProteinMPNN producono 24 sequenze uniche; cinque entrano nella validazione strutturale e due avanzano alla dinamica molecolare.
- Pipeline 4: MPNN_NEW_01 occupa il primo posto nei Tier 2 e 3; MPNN_NEW_05 conserva il supporto statico ed energetico più favorevole tra i nuovi peptidi. Il ciclo pilota BoTorch propone MPNN_POOL_023 come prossima sequenza da sottoporre a validazione strutturale.
- Pipeline 5: 17 feature farmacoforiche core vengono consolidate in 10 gruppi complessivi, nove dei quali partecipano direttamente alla regola di screening; 1.000 molecole sono analizzate e 996 incorporate con successo in 3D.
- Pipeline 5: i due hit farmacoforici stretti falliscono i criteri chimici; otto near-miss chimicamente accettabili costituiscono una rescue track esplicitamente tracciata.
- Pipeline 5: quattro finalisti ricevono supporto da DiffDock e Vina; nel ranking storico 09g MOL00583 ottiene quattro supporti top-2 su sei assi di valutazione. Tali assi sono tuttavia parzialmente dipendenti e i controlli mostrano che la configurazione MOL00583 propagata nelle analisi 09h–09k è off-site rispetto alla vera interfaccia EGF–EGFR.

13 Obiettivo e perimetro

Questo documento prosegue il rapporto dedicato alle Pipeline 1–3. Il sistema biologico è il complesso extracellulare EGF–EGFR rappresentato dalla struttura PDB 3NJP. Nell'implementazione PEARL, la catena B corrisponde alla componente extracellulare di EGFR e la catena D a EGF, il suo ligando naturale. Le sequenze peptidiche utilizzate nelle pipeline successive derivano dalla regione di EGF coinvolta nell'interfaccia con EGFR. Le sequenze F0010, CF02 e CF06 mantengono ruoli di riferimento distinti: F0010 è il riferimento naturale miniaturizzato, CF02 il riferimento di stabilità dinamica e CF06 il riferimento strutturale ed energetico della Pipeline 3. La Pipeline 4 introduce ESM-2 come prior di plausibilità di sequenza e ProteinMPNN come generatore condizionato dal backbone. Le sequenze selezionate vengono sottoposte a FoldX, Rosetta FlexPepDock, dinamica molecolare esplicita, confronto energetico endpoint, ESMFold e screening di sviluppabilità. La Pipeline 5 usa poi gli ensemble MD di CF02, CF06 e MPNN_NEW_05 per derivare un farmacoforo, selezionare molecole generate esternamente e integrare chimica, docking e rescoring locale.

13.1 Regole Interpretative

- Gli score ESM-2 e ProteinMPNN descrivono rispettivamente plausibilità di sequenza e compatibilità con il backbone; non misurano affinità per EGFR.
- FoldX, Rosetta e Vina usano funzioni di scoring differenti. I loro valori sono confrontabili solo entro protocolli omogenei.
- Il termine endpoint energy indica il proxy $E_{\text{complex}} - E_{\text{receptor}} - E_{\text{peptide}}$ e non una stima rigorosa di ΔG_{bind} .
- pLDDT, RMSD e persistenza dei contatti descrivono confidenza o geometria, non efficacia biologica.
- Le versioni test verificano l'esecuzione. Le tabelle e le conclusioni usano le versioni di produzione.

13.2 Architettura complessiva delle Pipeline 4 e 5

Fase	Input	Trasformazione	Output decisionale
o8a–o8c	FOO10, CF02, CF06 e struttura 3NJP	ESM-2, ProteinMPNN e score integrato	Cinque nuovi candidati
o8d–o8f	Cinque candidati e complessi strutturali	FoldX, FlexPepDock, MD ed endpoint energy	Due lead peptidici
o8g–o8j	Strutture ESMFold e descrittori di sequenza	Confronto strutturale e integrazione multi-dominio	MPNN_NEW_01 e MPNN_NEW_05
o9a–o9c	Ensemble MD di tre peptidi	Farmacoforo e screening 3D	Due hit stretti e near-miss
o9d–o9g	Candidati supportati dal farmacoforo	Filtri chimici, DiffDock, Vina e ranking	Quattro finalisti molecolari; MOL00583 è il lead computazionale storico selezionato da o9g
o9h	Configurazione storica MOL00583–EGFR propagata da o9f	MD di produzione (1 ns) e controllo della native EGF–EGFR interface	0/400 frame a contatto con i 43 residui dell'interfaccia EGF; distanza minima 9,167 Å. Configurazione off-site
o9i	Traiettoria off-site MOL00583–EGFR di o9h	Analisi endpoint GBn2/ACE su 50 snapshot	Proxy medio $\approx -20,10 \pm 2,37$ kcal/mol della configurazione off-site; non ΔG rigoroso, Kd o Ki
o9j	MOL00583 libero in acqua	MD CUDA di produzione, 3 repliche	Caratterizzazione conformazionale e di idratazione; il comparatore storico “bound” è la configurazione off-site di o9h
o9k	Stato finale condiviso della configurazione o9h	3×10 ns di MD CUDA e controllo della native EGF–EGFR interface	0/2400 frame a contatto con l'interfaccia EGF; distanze minime 9,04 / 7,73 / 9,80 Å. Persistenza/evoluzione off-site

Il collegamento tra le due pipeline passa attraverso la dinamica molecolare. MPNN_NEW_05 non è il vincitore unico della Pipeline 4, ma entra nell'estrazione farmacoforica perché rappresenta l'alternativa generata da IA con il miglior supporto energetico endpoint. CF02 e CF06 forniscono due riferimenti complementari già consolidati nelle fasi precedenti.

13.3 Pipeline 4 Progettazione peptidica guidata da modelli

13.3.1 ESM-2 e plausibilità delle sequenze

Il notebook 08a utilizza ESM-2, un modello di linguaggio addestrato su un ampio insieme di sequenze proteiche. La versione impiegata è `esm2_t6_8M_UR50D`: la sigla `t6` indica un modello Transformer composto da sei strati, `8M` indica una dimensione di circa otto milioni di parametri e `UR50D` identifica il dataset della famiglia UniRef50 utilizzato per l'addestramento. Si tratta di una versione relativamente compatta di ESM-2, scelta per valutare le brevi sequenze peptidiche del progetto.

Per stimare quanto ciascuna sequenza sia coerente con le regolarità apprese dal modello, il notebook nasconde a turno un residuo e chiede a ESM-2 di prevederlo usando tutti gli altri residui come contesto. Viene quindi registrata la probabilità assegnata all'amminoacido realmente presente.

Ripetendo l'operazione per tutte le posizioni si ottiene una misura complessiva chiamata pseudo-log-likelihood mascherata.

Un valore medio di pseudo-log-likelihood più alto, cioè meno negativo, indica che la sequenza è considerata relativamente più plausibile dal modello. La pseudo-perplessità esprime la stessa informazione in forma trasformata: in questo caso, valori più bassi indicano una maggiore plausibilità relativa.

L'analisi comprende anche il supporto posizione per posizione, che permette di individuare i residui più o meno coerenti con il contesto della sequenza. Gli embedding trasformano inoltre ogni peptide in una rappresentazione numerica; la similarità coseno e la PCA vengono utilizzate per confrontare queste rappresentazioni e visualizzare la vicinanza tra i candidati.

Queste misure descrivono la plausibilità statistica delle sequenze secondo ESM-2. Non valutano direttamente il legame con EGFR, l'affinità, la stabilità del complesso o l'attività biologica.

Candidato	Mean masked PLL	Pseudo-perplessità	Lettura
CFo2	-3,120	22,65	Migliore plausibilità relativa
CFo6	-3,232	25,32	Intermedio
Fo010	-3,240	25,54	Molto vicino a CFo6




Figura 13.1 – Supporto ESM-2 posizione per posizione per F0010, CF02 e CF06. Le differenze locali non costituiscono una misura di binding.

CF02 ottiene il punteggio medio più favorevole, ma la differenza rispetto a CF06 e F0010 non è ampia. Secondo ESM-2, quindi, le tre sequenze presentano livelli di plausibilità complessivamente simili.

La PCA rappresenta graficamente le somiglianze e le differenze tra le sequenze sulla base degli embedding prodotti dal modello. Poiché il confronto comprende soltanto tre peptidi molto simili, la loro posizione nel grafico deve essere interpretata in modo descrittivo. La PCA può mostrare quale sequenza risulta numericamente più vicina o più distante dalle altre, ma non dimostra che i peptidi appartengano a gruppi biologici differenti o che abbiano proprietà funzionali diverse.

13.3.2 ProteinMPNN e progettazione vincolata della sequenza

Il notebook 08b utilizza ProteinMPNN per progettare nuove sequenze peptidiche a partire dalla struttura tridimensionale del complesso EGFR–peptide. Questo procedimento è chiamato *inverse folding*: invece di prevedere la struttura che potrebbe assumere una sequenza già nota, il modello parte da una struttura definita e cerca le sequenze di amminoacidi compatibili con quella forma.

Nel complesso peptidico utilizzato per la progettazione, la catena B corrisponde alla componente extracellulare di EGFR e viene mantenuta invariata, svolgendo il ruolo di recettore. La catena D della struttura nativa 3NJP corrisponde a EGF; nelle fasi di progettazione peptidica viene utilizzata come riferimento strutturale per il frammento peptidico derivato da EGF, la cui sequenza viene modificata da ProteinMPNN. Il modello può intervenire soltanto sulle posizioni dichiarate designabili.

Sei posizioni del peptide vengono mantenute fisse perché le precedenti analisi con FoldX e dinamica molecolare le avevano indicate come rilevanti per l'interazione con il recettore. Questi residui protetti conservano quindi l'identità originaria. Le altre cinque posizioni possono essere sostituite dal modello, che esplora diverse combinazioni di amminoacidi compatibili con la geometria del backbone e con la presenza della catena B.

L'esecuzione di produzione genera 100 sequenze campionate. Alcune vengono proposte più volte e, dopo la rimozione dei duplicati, rimangono 24 peptidi distinti. Tra le soluzioni generate ricorre frequentemente il motivo TGPRNQYRDLX, nel quale X indica una posizione che può contenere amminoacidi differenti. La sequenza TGPRNQYRDLP riceve il miglior risultato nell'analisi iniziale di ProteinMPNN.

La frequenza con cui una sequenza viene generata indica quanto spesso ProteinMPNN la considera compatibile con la struttura e con i vincoli impostati. Non rappresenta la probabilità che il peptide si leghi a EGFR e non misura direttamente affinità, stabilità o attività biologica. Per questo motivo le sequenze generate vengono successivamente valutate con ESM-2, FoldX, Rosetta, dinamica molecolare e confronto energetico.




Figura 13.2 – Preferenze di ProteinMPNN nelle cinque posizioni designabili del peptide. L'intensità del colore indica la frequenza con cui ciascun amminoacido è stato selezionato nei 100 campionamenti di produzione. Il modello mostra preferenze particolarmente nette per T in posizione 1, P in posizione 3, N in posizione 5 e D in posizione 9, mentre la posizione 11 ammette una maggiore variabilità. Le frequenze descrivono la compatibilità delle scelte con la struttura e con i vincoli applicati; non rappresentano probabilità di legame con EGFR.

La mappa deve essere letta per colonne. L'asse orizzontale riporta le cinque posizioni della sequenza F0010 che ProteinMPNN era autorizzato a modificare: 1, 3, 5, 9 e 11. Le altre sei posizioni erano protette e non compaiono nel grafico. L'asse verticale indica, mediante il codice a una lettera, gli amminoacidi osservati nei campionamenti. Il colore rappresenta la frequenza di selezione: il giallo indica una scelta molto frequente, il verde una frequenza elevata, il blu una frequenza intermedia e il viola scuro una frequenza bassa o nulla. Per ogni posizione, la somma delle frequenze corrisponde al 100% dei 100 campionamenti eseguiti.

ProteinMPNN mostra preferenze particolarmente nette in quattro delle cinque posizioni. In posizione 1 seleziona soprattutto la treonina T, presente nell'81% dei campioni. In posizione 3 sceglie quasi esclusivamente la prolina P, con una frequenza del 99%, mentre in posizione 5 favorisce l'asparagina N nel 95% dei casi. In posizione 9 conserva quasi sempre l'acido aspartico D già presente in F0010. La posizione 11 è invece più variabile: il modello propone principalmente prolina P, asparagina N e glicina G. Questa distribuzione spiega la comparsa ricorrente del motivo TGPRNQYRDLX, nel quale X rappresenta il residuo variabile in posizione 11, e conduce alla sequenza TGPRNQYRDLP quando vengono considerate le scelte più frequenti.

Le frequenze sono calcolate sui 100 campionamenti originari, prima della rimozione dei duplicati che ha prodotto 24 peptidi distinti. La figura rappresenta inoltre le preferenze di ciascuna posizione

separatamente e non mostra quali residui siano stati selezionati insieme nella stessa sequenza. Una frequenza elevata indica che ProteinMPNN considera quella scelta compatibile con il backbone e con i vincoli strutturali impostati; non indica la probabilità che il peptide si leghi a EGFR.

La frequenza di una sequenza non viene interpretata come probabilità di legame. Essa indica quanto spesso il modello ricostruisce una soluzione compatibile con i vincoli, il backbone e la temperatura di campionamento selezionati.

13.3.3 Selezione integrata dei nuovi peptidi

Il notebook 08c confronta le 24 sequenze uniche generate da ProteinMPNN e assegna a ciascuna uno score integrato. Lo scopo è combinare informazioni complementari, evitando che la selezione dipenda da un solo modello.

Lo score considera quattro componenti:

- **30% score ProteinMPNN:** valuta quanto la sequenza sia compatibile con il backbone e con i vincoli strutturali. In questo caso, valori più bassi sono considerati migliori;
- **25% plausibilità ESM-2:** valuta quanto la sequenza sia coerente con i pattern appresi dal modello di linguaggio proteico. Valori di pseudo-log-likelihood più alti, cioè meno negativi, sono considerati migliori;
- **20% frequenza di campionamento:** favorisce le sequenze generate più volte nei 100 campionamenti ProteinMPNN;
- **25% somiglianza con F0010:** favorisce i peptidi che conservano una maggiore vicinanza alla sequenza di riferimento. La distanza è misurata contando il numero di posizioni nelle quali le due sequenze differiscono.

Prima della combinazione, le quattro misure vengono trasformate su una scala comune. Lo **Score IA** finale è quindi un indice di priorità relativo alle 24 sequenze analizzate: valori più alti indicano un migliore equilibrio tra compatibilità strutturale, plausibilità di sequenza, ricorrenza e vicinanza a F0010. Lo score non possiede un'unità fisica e non rappresenta una probabilità di legame, una misura di affinità o una percentuale di successo.

Rank	ID	Sequenza	Score IA
1	MPNN_NEW_01	TGPRNQYRDLP	0,601
2	MPNN_NEW_02	IGPRNQYRDLG	0,551
3	MPNN_NEW_04	IGPRNQYRDLN	0,514
4	MPNN_NEW_05	IGPRHQYRDLP	0,509
5	MPNN_NEW_03	PGPRNQYRDLP	0,402

La shortlist non viene costruita limitandosi alle cinque sequenze con lo score integrato più alto. Il notebook conserva intenzionalmente candidati con caratteristiche complementari: il migliore in assoluto, una variante relativamente vicina a F0010, la nuova sequenza favorita da ESM-2 e altri candidati con un buon risultato complessivo. Per questo motivo MPNN_NEW_03 viene incluso nonostante uno Score IA inferiore: il suo contributo alla shortlist consiste soprattutto nell'elevata plausibilità assegnata da ESM-2.

Le cinque sequenze rappresentano quindi ipotesi prioritarie da sottoporre alle analisi successive. Il ranking riduce da 24 a 5 il numero di candidati da valutare con FoldX e Rosetta, ma non dimostra ancora che le sequenze possiedano una struttura stabile o una buona interazione con EGFR.




Figura 13.3 – Confronto tra compatibilità strutturale secondo ProteinMPNN e plausibilità di sequenza secondo ESM-2. Ogni punto rappresenta uno dei 24 peptidi unici generati da ProteinMPNN. Sull'asse orizzontale sono riportati gli score ProteinMPNN, per i quali valori più bassi sono considerati migliori; sull'asse verticale è riportata la pseudo-log-likelihood media di ESM-2, per la quale valori più alti, cioè meno negativi, indicano una maggiore plausibilità della sequenza. Otto punti sono accompagnati dalla sequenza per facilitarne l'identificazione. La shortlist finale di cinque candidati viene definita successivamente integrando anche frequenza di campionamento e vicinanza a F0010.

Il grafico mette a confronto due criteri differenti. La posizione più favorevole si trova idealmente nella parte superiore sinistra: verso sinistra aumenta il supporto di ProteinMPNN, mentre verso l'alto aumenta la plausibilità assegnata da ESM-2. Un peptide collocato in questa zona presenta quindi un buon compromesso tra compatibilità con il backbone e coerenza con i pattern delle sequenze proteiche appresi da ESM-2.

I punti non formano però un gruppo unico nella regione superiore sinistra e i due modelli non favoriscono sempre le stesse sequenze. Per esempio, PGPRNQYRDLP, successivamente denominato MPNN_NEW_03, si trova vicino alla parte superiore perché riceve il miglior punteggio ESM-2 tra le

nuove sequenze, ma il suo score ProteinMPNN è meno favorevole rispetto a quello di altri candidati. TGPRNQYRDLP, denominato MPNN_NEW_01, è invece collocato più a sinistra e mantiene un buon valore ESM-2: questa combinazione contribuisce al suo primo posto nello score integrato.

La figura, da sola, non determina la shortlist definitiva. Il notebook 08c aggiunge infatti altri due criteri non rappresentati nel grafico: la frequenza con cui ogni sequenza è stata generata e il numero di differenze rispetto a F0010. La selezione finale comprende quindi candidati con caratteristiche complementari e non soltanto i punti apparentemente più vicini all'angolo superiore sinistro.

Le cinque sequenze selezionate non erano presenti né nel dataset locale utilizzato in 04c né nello spazio di sequenze CLEAR considerato nelle Pipeline precedenti. In questo contesto, il termine “nuove” indica esclusivamente l'assenza di una corrispondenza nei dati locali impiegati per il confronto. Non dimostra che le stesse sequenze non siano mai state osservate, registrate o studiate in altri database.

13.3.4 Validazione strutturale con FoldX e Rosetta

Il notebook 08d sottopone i cinque peptidi selezionati in 08c a una prima validazione basata sulla struttura tridimensionale. Per ciascun candidato viene costruito un nuovo complesso EGFR-peptide: la catena B del recettore viene mantenuta invariata, mentre nella catena D vengono introdotte le sostituzioni amminoacidiche specifiche della nuova sequenza.

La valutazione utilizza due strumenti con funzioni differenti:

- **FoldX** ricostruisce le catene laterali modificate e stima l'energia di interazione tra il recettore e il peptide. Nell'ambito dello stesso protocollo, un valore più negativo indica un'interazione prevista come relativamente più favorevole;
- **Rosetta FlexPepDock** raffina la posizione del peptide e l'orientamento delle sue catene laterali all'interno dell'interfaccia. Il programma genera diverse possibili strutture raffinate e assegna a ciascuna uno score di interfaccia indicato come **I_SC**. Anche in questo caso, valori più negativi sono considerati più favorevoli.

Per ogni candidato Rosetta produce 20 **decoy**, per un totale di 100 strutture. Il termine decoy non indica una struttura necessariamente errata: identifica una delle conformazioni alternative generate durante il raffinamento. Tra le 20 conformazioni di ciascun peptide viene selezionata quella con il valore **I_SC** più favorevole.

I candidati vengono ordinati separatamente secondo FoldX e Rosetta. Il ranking strutturale complessivo deriva dalla somma delle due posizioni in classifica: un candidato ottiene quindi una priorità elevata quando riceve un buon risultato con entrambi i metodi.

Ranking strutturale FoldX e Rosetta

Rank statico	Candidato	Energia FoldX	Rank FoldX	Miglior I_sc Rosetta	Rank Rosetta	Somma dei rank	Decisione
1	MPNN_NEW_05	-13,75 kcal/mol	1	-56,12	1	2	Avanza alla MD
2	MPNN_NEW_01	-11,74 kcal/mol	3	-54,17	2	5	Avanza alla MD
3	MPNN_NEW_02	-12,71 kcal/mol	2	-53,35	4	6	Non avanza
4	MPNN_NEW_04	-11,31 kcal/mol	4	-53,92	3	7	Non avanza
5	MPNN_NEW_03	-9,44 kcal/mol	5	-51,56	5	10	Non avanza

MPNN_NEW_05 occupa il primo posto con entrambi i metodi: presenta l'energia di interazione FoldX più negativa e il miglior I_{sc} Rosetta. Per questo motivo ottiene una somma dei rank pari a 2 e risulta il candidato con il supporto strutturale statico più consistente.

MPNN_NEW_01 non è il secondo candidato secondo FoldX, dove occupa il terzo posto, ma raggiunge la seconda posizione nel ranking Rosetta. La combinazione dei due risultati lo colloca al secondo posto complessivo. MPNN_NEW_02 riceve invece un buon risultato con FoldX, ma un supporto inferiore dopo il raffinamento Rosetta. MPNN_NEW_04 e MPNN_NEW_03 mostrano un risultato complessivamente meno favorevole.

Sulla base di questa graduatoria, MPNN_NEW_05 e MPNN_NEW_01 vengono selezionati per la successiva simulazione di dinamica molecolare. Il termine "ranking statico" indica che la valutazione si basa su strutture singole o su conformazioni raffinate, senza ancora osservare l'evoluzione del complesso nel tempo.

I valori di FoldX e Rosetta sono score computazionali ottenuti con funzioni empiriche differenti. La convergenza dei due metodi rafforza la priorità assegnata ai primi candidati, ma non costituisce una misura sperimentale dell'affinità e non dimostra che il complesso sia stabile in condizioni biologiche. I risultati dipendono inoltre dalla struttura iniziale, dal campionamento delle conformazioni e dalle impostazioni adottate durante il raffinamento.

13.3.5 Dinamica molecolare dei lead ProteinMPNN

Il notebook 08e verifica il comportamento dinamico dei due candidati selezionati nella fase precedente, MPNN_NEW_01 e MPNN_NEW_05. A differenza delle analisi FoldX e Rosetta, basate su strutture statiche, la dinamica molecolare simula il movimento degli atomi del complesso EGFR-peptide nel tempo.

La simulazione viene eseguita in solvente esplicito: le molecole d'acqua e gli ioni sono rappresentati direttamente nel sistema. Il protocollo utilizza il campo di forze AMBER ff14SB per la componente proteica, il modello TIP3P per l'acqua e una concentrazione salina di 0,15 M NaCl. La temperatura è mantenuta a 300 K e la pressione a 1 bar. Le coordinate atomiche vengono aggiornate ogni 2 femtosecondi.

Prima della fase analizzata, il sistema viene sottoposto a due periodi di equilibratura:

- 100 ps in condizioni NVT, con numero di particelle, volume e temperatura controllati;
- 100 ps in condizioni NPT, con numero di particelle, pressione e temperatura controllati.

Segue 1 ns di produzione, dal quale vengono salvati 500 frame, cioè 500 configurazioni del complesso distribuite lungo la traiettoria. Le simulazioni complete vengono eseguite in 08e soltanto per MPNN_NEW_01 e MPNN_NEW_05. I valori di F0010, CF02 e CF06 sono invece importati dalle analisi della Pipeline 3 per consentire un confronto con riferimenti già valutati mediante lo stesso tipo di metriche.

La tabella riporta quattro indicatori:

- **RMSD medio:** misura quanto la conformazione complessiva del peptide si allontana dalla struttura iniziale. Valori più bassi indicano una minore deviazione;
- **RMSF medio:** misura quanto le singole posizioni del peptide oscillano durante la simulazione. Valori più bassi indicano una minore flessibilità media;
- **contatti $\geq 50\%$:** indica il numero di contatti tra recettore e peptide presenti in almeno metà dei frame analizzati;
- **persistenza media:** indica la frequenza media con cui i contatti vengono mantenuti durante la traiettoria. Valori più alti indicano una rete di interazioni più continua nel tempo.

Candidato	RMSD medio Å	RMSF medio Å	Contatti $\geq 50\%$	Persistenza media
CF02	0,901	0,737	43	0,603
MPNN_NEW_01	1,268	0,920	41	0,599
CF06	1,293	0,904	45	0,529
MPNN_NEW_05	1,417	0,831	40	0,535
F0010	1,966	1,164	43	0,541

CF02 mostra il comportamento complessivamente più stabile: presenta il valore più basso sia di RMSD sia di RMSF e la persistenza media dei contatti più elevata. Conferma quindi il proprio ruolo di riferimento per la stabilità dinamica.

Tra i due nuovi candidati ProteinMPNN, MPNN_NEW_01 presenta un RMSD inferiore e una persistenza media dei contatti superiore rispetto a MPNN_NEW_05. Questo indica che, nel corso della simulazione, la sua conformazione si allontana meno dalla struttura iniziale e la rete di contatti con il recettore viene mantenuta con maggiore continuità. MPNN_NEW_05 mostra invece un RMSF medio più basso, segno di minori oscillazioni locali, ma ottiene risultati meno favorevoli per deviazione complessiva e persistenza dei contatti.

CF06 possiede il maggior numero di contatti persistenti, pari a 45, ma la sua persistenza media è la più bassa tra i candidati riportati. Questo risultato mostra perché le due colonne non devono essere confuse: un peptide può mantenere molti contatti diversi senza che ciascuno di essi sia presente con la stessa continuità lungo la traiettoria. F0010 presenta il valore più alto di RMSD e di RMSF. Nel confronto adottato risulta quindi il peptide con la maggiore deviazione dalla struttura iniziale e con la maggiore flessibilità media.

Considerando insieme le quattro metriche, il confronto tra i due candidati generati da ProteinMPNN favorisce MPNN_NEW_01. La simulazione dura tuttavia soltanto 1 ns e descrive il comportamento del sistema su una scala temporale breve. I risultati indicano stabilità dinamica relativa e persistenza dei contatti nel protocollo utilizzato, ma non costituiscono una misura sperimentale dell'affinità di legame.




Figura 13.5a – Andamento dell'RMSD dei due peptidi ProteinMPNN durante la simulazione di produzione. Le curve mostrano la deviazione degli atomi C α di MPNN_NEW_01 e MPNN_NEW_05 rispetto alla conformazione iniziale, dopo l'allineamento del recettore. L'asse orizzontale riporta i 500 frame salvati durante 1 ns di produzione, mentre l'asse verticale esprime l'RMSD in ångström. Valori più bassi indicano una minore deviazione dalla conformazione iniziale. Sono rappresentati soltanto i due nuovi candidati perché il notebook 08e esegue nuove simulazioni MD esclusivamente per MPNN_NEW_01 e MPNN_NEW_05.

Considerando insieme le metriche riportate nella tabella, MPNN_NEW_01 riceve un supporto dinamico complessivamente più favorevole rispetto a MPNN_NEW_05. Durante la simulazione si allontana meno dalla conformazione iniziale, come indica il minore RMSD medio, e mantiene con maggiore continuità i contatti con il recettore, come mostra la persistenza media più elevata. MPNN_NEW_05 presenta invece oscillazioni locali mediamente più contenute, indicate dal minore RMSF, ma una deviazione complessiva e una persistenza dei contatti meno favorevoli.

CFo2 rimane il riferimento con il comportamento dinamico più stabile, perché presenta i valori più bassi di RMSD e RMSF e la persistenza media dei contatti più elevata. Questo confronto deve comunque essere interpretato con cautela: la produzione dura soltanto 1 ns e permette di osservare soprattutto variazioni conformazionali rapide e locali. Non è sufficientemente lunga per descrivere eventuali riarrangiamenti lenti del peptide o dell'interfaccia. I risultati costituiscono quindi un confronto computazionale preliminare tra i candidati e non una dimostrazione della loro stabilità a lungo termine o dell'affinità per EGFR.

13.3.6 Confronto energetico endpoint

Il notebook o8f aggiunge una valutazione energetica ai risultati strutturali e dinamici ottenuti nelle fasi precedenti. Per MPNN_NEW_01 e MPNN_NEW_05 vengono selezionate 50 configurazioni, chiamate snapshot, distribuite uniformemente lungo le rispettive traiettorie di dinamica molecolare. Ogni snapshot rappresenta la disposizione degli atomi del complesso in un determinato momento della simulazione.

Per ciascuna configurazione viene calcolata la seguente differenza energetica:

$$\Delta E_{\text{endpoint}} = E_{\text{complex}} - E_{\text{receptor}} - E_{\text{peptide}}$$

dove:

- **E_{complex}** è l'energia calcolata per l'intero complesso EGFR-peptide;
- **E_{receptor}** è l'energia della sola componente recettoriale;
- **E_{peptide}** è l'energia del peptide considerato separatamente.

Il calcolo segue un approccio **single-trajectory**. Le energie del complesso, del recettore e del peptide vengono ricavate dalla stessa configurazione della traiettoria, mantenendo invariate le coordinate atomiche. Il recettore e il peptide non vengono quindi simulati separatamente per questa analisi.

Il modello energetico utilizza il campo di forze AMBER ff14SB e una rappresentazione implicita del solvente. Per ogni candidato viene calcolata la media dei 50 valori di $\Delta E_{\text{endpoint}}$. Nell'ambito di questo protocollo, un valore medio più negativo indica un supporto energetico relativo più favorevole.

Rank	Candidato	Media kcal/mol	Deviazione standard
1	CFo6	-65,66	6,80
2	FO010	-59,46	5,96
3	CFo2	-56,62	4,63
4	MPNN_NEW_05	-53,67	6,43
5	MPNN_NEW_01	-46,41	4,66

CFo6 presenta il valore medio più negativo, pari a $-65,66$ kcal/mol, e riceve quindi il supporto energetico più favorevole nel confronto. F0010 e CFo2 occupano rispettivamente la seconda e la terza posizione. I risultati di questi tre peptidi provengono dalla Pipeline 3 e vengono riportati perché erano stati ottenuti con lo stesso protocollo comparativo.

Tra i due nuovi candidati generati da ProteinMPNN, MPNN_NEW_05 ottiene un risultato più favorevole: il suo $\Delta E_{\text{endpoint}}$ medio è pari a $-53,67$ kcal/mol, rispetto a $-46,41$ kcal/mol per MPNN_NEW_01. Secondo questa specifica analisi energetica, MPNN_NEW_05 è quindi il migliore dei due nuovi peptidi, pur rimanendo dietro ai tre riferimenti già stabiliti.

La deviazione standard descrive quanto i valori energetici cambiano tra i 50 snapshot. Una deviazione più elevata indica una maggiore variabilità lungo la traiettoria. Non rappresenta però l'incertezza di 50 esperimenti indipendenti, perché gli snapshot provengono dalla stessa simulazione e sono temporalmente correlati.

Il risultato energetico non coincide completamente con quello della dinamica molecolare. La dinamica breve favorisce MPNN_NEW_01 per RMSD e persistenza media dei contatti, mentre il calcolo endpoint favorisce MPNN_NEW_05. Questa differenza non costituisce necessariamente una contraddizione: le due analisi misurano aspetti diversi. La dinamica descrive il comportamento e la stabilità geometrica del complesso nel tempo; il calcolo endpoint confronta invece un proxy energetico ricavato da configurazioni selezionate.

$\Delta E_{\text{endpoint}}$ non deve essere interpretato come una vera energia libera di legame o come una misura sperimentale dell'affinità. Il calcolo non include in modo completo tutti i contributi termodinamici, in particolare quelli entropici, e si basa su una singola traiettoria relativamente breve. I valori sono quindi utilizzati esclusivamente per confrontare i candidati all'interno dello stesso protocollo.




Figura 13.6 – Confronto del proxy energetico endpoint tra i peptidi di riferimento e i nuovi candidati ProteinMPNN. Le barre rappresentano il valore medio di $\Delta E_{\text{endpoint}}$ calcolato sugli snapshot delle traiettorie, mentre le linee nere indicano la deviazione standard. Nell'ambito dello stesso protocollo, valori medi più negativi corrispondono a un supporto energetico relativo più favorevole. CFo6 presenta il valore più negativo; tra i nuovi candidati, MPNN_NEW_05 ottiene un risultato più favorevole rispetto a MPNN_NEW_01. $\Delta E_{\text{endpoint}}$ è un indicatore comparativo e non una stima rigorosa dell'energia libera di legame.

La figura mostra che CFo6 riceve il supporto energetico più favorevole, seguito da F0010 e CFo2. I due nuovi candidati ProteinMPNN occupano invece la quarta e la quinta posizione. Tra questi,

MPNN_NEW_05 presenta un valore medio più negativo rispetto a MPNN_NEW_01 ed è quindi il candidato generato da ProteinMPNN favorito dal confronto energetico endpoint.

Le linee nere mostrano la variabilità dei valori tra gli snapshot. La loro parziale sovrapposizione indica che le differenze tra alcuni candidati devono essere interpretate con cautela. Gli snapshot provengono infatti da singole traiettorie brevi e non costituiscono repliche sperimentali o simulazioni statisticamente indipendenti. Il grafico deve quindi essere letto come un confronto descrittivo all'interno dello stesso protocollo, non come una dimostrazione di differenze significative nell'affinità.

L'ordine energetico non coincide con quello ottenuto dall'analisi dinamica. MPNN_NEW_01 era risultato più favorevole per RMSD e persistenza media dei contatti, mentre MPNN_NEW_05 è favorito dal proxy energetico endpoint. Le due analisi descrivono aspetti differenti del complesso e forniscono informazioni complementari. Per questo motivo entrambi i candidati vengono mantenuti nelle successive fasi di valutazione, senza individuare in questa fase un vincitore definitivo.

.

13.3.7 Validazione strutturale ESMFold

Il notebook o8g valuta la plausibilità strutturale di MPNN_NEW_01 e MPNN_NEW_05 mediante ESMFold. Le strutture tridimensionali erano state generate esternamente e vengono importate nel notebook sotto forma di file PDB. Prima dell'analisi viene verificato che ciascuna struttura contenga la sequenza corretta, tutti gli 11 residui previsti e gli atomi necessari per il confronto.

ESMFold predice la conformazione dei due peptidi considerandoli isolatamente, cioè senza includere il recettore EGFR. Le strutture previste vengono successivamente confrontate con la conformazione del peptide di riferimento osservata nel complesso legato. Questo confronto permette di valutare se la forma proposta da ESMFold sia geometricamente simile alla conformazione assunta dal peptide nell'interfaccia.

La valutazione utilizza quattro indicatori:

- **pLDDT medio:** esprime la confidenza media di ESMFold nella geometria locale prevista. Valori più alti indicano una maggiore confidenza del modello;
- **RMSD globale:** misura la differenza complessiva tra la struttura prevista e la conformazione legata di riferimento, dopo aver sovrapposto nel modo migliore gli atomi Ca degli 11 residui. Valori più bassi indicano una maggiore somiglianza;
- **RMSD delle posizioni protette:** misura la deviazione dei soli residui mantenuti fissi durante la progettazione con ProteinMPNN, dopo l'allineamento globale dell'intero peptide. Anche in questo caso, valori più bassi sono più favorevoli;
- **mappatura:** indica quanti residui della struttura prevista sono stati correttamente associati alle corrispondenti posizioni del peptide di riferimento.

Candidato	pLDDT medio	RMSD globale Å	RMSD protetto Å	Mappatura
MPNN_NEW_01	72,56	4,49	3,67	11/11
MPNN_NEW_05	67,27	5,07	3,83	11/11

La mappatura 11/11 conferma che tutti i residui dei due peptidi sono presenti e possono essere confrontati posizione per posizione. Non significa che le strutture siano identiche o che tutti gli amminoacidi coincidano con quelli del riferimento.

MPNN_NEW_01 ottiene un pLDDT medio di 72,56, superiore al valore di 67,27 di MPNN_NEW_05. ESMFold assegna quindi a MPNN_NEW_01 una maggiore confidenza strutturale media. Anche il confronto geometrico favorisce MPNN_NEW_01: il suo RMSD globale è pari a 4,49 Å, rispetto a 5,07 Å per MPNN_NEW_05.

La stessa tendenza si osserva nelle sei posizioni protette durante la progettazione con ProteinMPNN. MPNN_NEW_01 presenta un RMSD di 3,67 Å, mentre MPNN_NEW_05 raggiunge 3,83 Å. La differenza è contenuta, ma entrambi gli indicatori collocano MPNN_NEW_01 leggermente più vicino alla conformazione legata di riferimento.

I valori di RMSD rimangono relativamente elevati per entrambi i candidati. Questo risultato deve essere interpretato considerando che ESMFold ha predetto la struttura di peptidi isolati. Un peptide corto può essere molto flessibile e assumere in soluzione una conformazione diversa da quella stabilizzata dal contatto con il recettore. La distanza dalla conformazione legata non dimostra quindi, da sola, che il peptide sia strutturalmente inadeguato.

Nel complesso, l'analisi ESMFold fornisce un supporto comparativo più favorevole a MPNN_NEW_01, che presenta sia una maggiore confidenza media sia una minore deviazione dal riferimento. pLDDT e RMSD restano tuttavia descrittori strutturali: non misurano l'affinità per EGFR e non sostituiscono la valutazione del peptide nel complesso recettoriale.




Figura 13.7a – Confidenza ESMFold nelle singole posizioni delle sequenze MPNN_NEW_01 e MPNN_NEW_05. L'asse orizzontale riporta le 11 posizioni del peptide, mentre l'asse verticale mostra il valore pLDDT assegnato da ESMFold a ciascun residuo. Valori più alti indicano una maggiore confidenza del modello nella geometria locale prevista. La linea blu rappresenta MPNN_NEW_01 e la linea arancione MPNN_NEW_05. Le bande gialle identificano le sei posizioni 2, 4, 6, 7, 8 e 10, mantenute fisse durante la progettazione con ProteinMPNN.

Nel confronto tra i due candidati, MPNN_NEW_01 riceve un supporto strutturale relativamente più favorevole: ESMFold assegna alla sua struttura una maggiore confidenza media e il confronto geometrico mostra una minore deviazione dalla conformazione di riferimento.

Questa conclusione deve essere interpretata con cautela. Le strutture ESMFold sono state generate per peptidi isolati di soli 11 amminoacidi, senza includere il recettore EGFR. Un peptide così corto può essere molto flessibile e assumere conformazioni differenti quando è libero in soluzione e quando interagisce con una proteina.

Il pLDDT indica quanto ESMFold considera affidabile la geometria locale prevista, mentre l'RMSD misura la differenza rispetto alla conformazione del peptide legato al recettore. Nessuno dei due parametri dimostra che il peptide assuma realmente quella struttura nel complesso con EGFR o che possieda una maggiore affinità di legame. I risultati permettono quindi un confronto strutturale preliminare tra MPNN_NEW_01 e MPNN_NEW_05, ma non sostituiscono l'analisi del complesso peptide-recettore.

13.3.8 Valutazione preliminare della sviluppabilità

Il notebook o8h valuta alcune proprietà delle sequenze peptidiche che possono influenzarne il comportamento in soluzione e la futura gestione sperimentale. La versione finale, denominata *FULL_COHORT-2*, estende l'analisi ai 24 peptidi unici generati da ProteinMPNN e ai tre riferimenti Foo10, CFo2 e CFo6, per un totale di 27 sequenze.

Il termine **sviluppabilità** indica, in questo contesto, una valutazione preliminare di proprietà quali idrofilia, carica e solubilità intrinseca prevista. Non implica che un peptide sia già idoneo allo sviluppo terapeutico e non fornisce informazioni dirette sulla sua capacità di legarsi a EGFR o di produrre un effetto biologico.

Per ogni sequenza vengono calcolati tre descrittori fisicochimici:

- **GRAVY:** rappresenta l'idropatia media della sequenza. Valori positivi indicano una maggiore componente idrofobica, mentre valori negativi indicano una maggiore componente idrofila. Un valore più negativo suggerisce una migliore compatibilità relativa con l'ambiente acquoso, ma non costituisce una misura sperimentale della solubilità;
- **carica prevista a pH 7:** stima la carica elettrica netta del peptide in condizioni prossime alla neutralità;
- **punto isoelettrico teorico (pI):** indica il valore di pH al quale la carica netta prevista del peptide è pari a zero. Al di sotto del proprio pI il peptide tende ad avere carica positiva, mentre al di sopra tende ad avere carica negativa.

La versione finale integra inoltre risultati ottenuti con **CamSol**, uno strumento computazionale specifico per la previsione della solubilità. L'analisi è stata eseguita in modalità intrinseca, che valuta la solubilità a partire dalla sequenza senza utilizzare una particolare struttura tridimensionale o la posa del peptide nel complesso con EGFR.

I risultati CamSol sono stati importati nel notebook e associati alle rispettive sequenze mediante il controllo di identificativi e hash. Tutte le 27 sequenze dispongono di un risultato validato. Per il punteggio CamSol utilizzato in questa analisi, valori più elevati indicano una solubilità intrinseca prevista relativamente più favorevole.

Candidato	GRAVY	Carica prevista a pH 7	pl teorico	CamSol
MPNN_NEW_01	-1,94	+0,40	8,41	2,185
MPNN_NEW_05	-1,44	+0,85	8,75	1,981

MPNN_NEW_01 presenta un valore GRAVY più negativo rispetto a MPNN_NEW_05 e risulta quindi relativamente più idrofilo. Anche il risultato CamSol è più favorevole per MPNN_NEW_01: il suo punteggio è pari a 2,185, rispetto a 1,981 per MPNN_NEW_05. I due indicatori, pur basandosi su metodi differenti, concordano quindi nel favorire MPNN_NEW_01 nel confronto preliminare della solubilità basata sulla sequenza.

Nel confronto esteso a tutte le 27 sequenze, MPNN_NEW_01 occupa il settimo posto secondo CamSol, mentre MPNN_NEW_05 presenta il punteggio più basso della coorte. Questo risultato non esclude MPNN_NEW_05 dalle fasi successive, perché il candidato conserva un supporto energetico e strutturale favorevole; segnala però una possibile criticità relativa nella solubilità intrinseca prevista.

Entrambi i finalisti presentano una carica netta positiva prevista a pH 7. MPNN_NEW_05 è più positivo, con una carica stimata di +0,85, mentre MPNN_NEW_01 raggiunge +0,40. I rispettivi punti isoelettrici, pari a 8,75 e 8,41, sono coerenti con questa osservazione: a pH 7 entrambi i peptidi si trovano al di sotto del proprio punto isoelettrico e tendono pertanto a mantenere una carica positiva.

Il notebook applica anche regole euristiche destinate a segnalare possibili caratteristiche sfavorevoli delle sequenze. Nessuno dei due candidati produce alert nel sistema adottato. L'assenza di segnalazioni indica soltanto che non sono state rilevate le condizioni previste dalle regole implementate; non garantisce solubilità, stabilità o assenza di difficoltà sperimentali.

Nelle successive fasi di integrazione viene utilizzato il punteggio CamSol validato, e non più il solo GRAVY, come indicatore principale del dominio di sviluppabilità. MPNN_NEW_01 riceve pertanto il supporto più favorevole sia per la maggiore idrofilia relativa indicata dal GRAVY sia per la migliore solubilità intrinseca prevista da CamSol.

Questi risultati restano comunque previsioni computazionali. Il punteggio CamSol non costituisce una misura sperimentale della solubilità e non rappresenta una valutazione completa della sviluppabilità. Aspetti quali stabilità chimica, aggregazione, degradazione proteolitica, producibilità e comportamento nelle condizioni sperimentali dovranno essere verificati mediante analisi dedicate.

13.3.9 Integrazione evidenze e ottimizzazione bayesiana BoTorch

L'analisi o8i è stata sviluppata in due fasi. La prima versione integra i risultati energetici, strutturali e di sviluppabilità dei due candidati arrivati alle fasi finali, MPNN_NEW_01 e MPNN_NEW_05. La versione successiva, denominata *FULL_COHORT*, applica invece BoTorch all'intero insieme dei 24 peptidi unici generati da ProteinMPNN.

Nella prima fase, il notebook controlla che i risultati provenienti dalle analisi o8f, o8g e o8h appartengano agli stessi candidati, confrontando identificativi, sequenze e hash. Energia endpoint, struttura e sviluppabilità vengono quindi trasformate in punteggi relativi orientati nella stessa direzione, per i quali un valore più alto indica un risultato più favorevole all'interno della coorte analizzata.

Il pLDDT e l'RMSD vengono prima riuniti in un unico punteggio strutturale. In questo modo la componente strutturale riceve complessivamente lo stesso peso dell'energia e della sviluppabilità, anziché essere conteggiata due volte.

Scenario di ponderazione	Energia	Struttura	Sviluppabilità	Esito
Pesi uguali	33,3%	33,3%	33,3%	MPNN_NEW_01
Priorità alla struttura	25%	50%	25%	MPNN_NEW_01
Priorità alla sviluppabilità	25%	25%	50%	MPNN_NEW_01
Priorità all'energia	50%	25%	25%	Parità

MPNN_NEW_01 è favorito dalla valutazione strutturale e dalla sviluppabilità, mentre MPNN_NEW_05 presenta l'energia endpoint più favorevole. Per questo motivo MPNN_NEW_01 prevale nello scenario a pesi uguali e negli scenari che privilegiano struttura o sviluppabilità. Quando all'energia viene assegnato il 50% del peso complessivo, il vantaggio energetico di MPNN_NEW_05 compensa i vantaggi di MPNN_NEW_01 e si ottiene una parità.

Nella versione finale del notebook, BoTorch viene effettivamente utilizzato per scegliere quale peptide del pool ProteinMPNN valutare successivamente con i metodi strutturali più costosi. Un modello probabilistico **SingleTaskGP** viene addestrato utilizzando i cinque candidati per i quali sono già disponibili risultati reali di FoldX e Rosetta. L'obiettivo strutturale combina, con uguale peso, l'energia d'interazione FoldX e lo score di interfaccia Rosetta.

Il modello utilizza come informazioni di ingresso tre descrittori disponibili per tutti i 24 peptidi: score ProteinMPNN, plausibilità di sequenza ESM-2 e punteggio CamSol validato. Successivamente stima il possibile risultato strutturale dei 19 candidati non ancora analizzati con FoldX e Rosetta. La funzione di acquisizione *Log Expected Improvement* bilancia il risultato strutturale previsto e l'incertezza del modello, assegnando una priorità alle successive verifiche.

Il candidato proposto al primo posto è **MPNN_POOL_023**, con sequenza **VGARNQYRDLN**. Esso non è un nuovo peptide generato da BoTorch, ma una sequenza già presente nel pool originale di ProteinMPNN che il modello suggerisce di sottoporre alla successiva validazione strutturale.

L'analisi deve essere considerata un esperimento pilota, perché il modello è addestrato su appena cinque osservazioni strutturali. BoTorch non dimostra quindi che MPNN_POOL_023 leghi EGFR e non ne predice direttamente l'affinità: indica soltanto che, sulla base dei dati disponibili, questo candidato rappresenta la successiva valutazione potenzialmente più informativa.

Nella versione finale del notebook, BoTorch viene effettivamente eseguito sull'intera coorte dei 24 peptidi unici generati da ProteinMPNN. Il modello **SingleTaskGP** viene addestrato utilizzando i risultati FoldX e Rosetta dei cinque candidati già sottoposti a validazione strutturale. Lo score ProteinMPNN, la plausibilità di sequenza ESM-2 e il punteggio CamSol validato sono utilizzati come descrittori disponibili per tutta la coorte.




Figura 13.9 – Priorità assegnate da BoTorch ai dieci candidati più promettenti tra i 19 peptidi non ancora sottoposti alla validazione strutturale. Le barre rappresentano il *Log Expected Improvement*: valori più elevati, cioè meno negativi e più vicini a zero, indicano una maggiore priorità per la successiva valutazione con FoldX e Rosetta. MPNN_POOL_023 occupa il primo posto.

La funzione di acquisizione *Log Expected Improvement* assegna quindi una priorità ai 19 peptidi non ancora analizzati con FoldX e Rosetta. Il candidato selezionato per la successiva valutazione strutturale è **MPNN_POOL_023**, con sequenza **VGARNQYRDLN**.

BoTorch non genera in questa fase una nuova sequenza e non predice direttamente l'affinità per EGFR. Seleziona, tra le sequenze già prodotte da ProteinMPNN, quella la cui successiva valutazione potrebbe offrire il miglior equilibrio tra risultato strutturale atteso e informazione aggiuntiva. Poiché il modello è addestrato su soltanto cinque osservazioni strutturali, il risultato deve essere considerato un esperimento pilota e una priorità esplorativa, non una dimostrazione di legame o attività biologica.

13.3.10 Decisione multi-obiettivo finale basata sui livelli di evidenza

Il notebook 08j integra i risultati conclusivi della Pipeline 4 evitando di confrontare direttamente candidati analizzati con livelli di approfondimento differenti. Non tutte le 24 sequenze generate da ProteinMPNN, infatti, dispongono di risultati FoldX, Rosetta, dinamica molecolare, energia endpoint ed ESMFold. Attribuire valori favorevoli alle analisi mancanti produrrebbe una graduatoria artificiale.

Per questo motivo, la versione finale del notebook organizza i candidati in tre livelli distinti. All'interno di ogni livello vengono confrontate soltanto sequenze per le quali sono disponibili le stesse categorie di evidenza. I punteggi ottenuti nei diversi livelli non devono quindi essere confrontati direttamente tra loro.

Tabella 1 Livelli di evidenza e risultati principali

Livello	Candidati	Evidenze utilizzate	Pesi	Primo classificato
Tier 1 - Screening completo	24	ProteinMPNN, ESM-2 e CamSol	33,3% ciascuno	MPNN_POOL_016
Tier 2 - Validazione strutturale	5	FoldX e Rosetta; score IA; CamSol	50%; 25%; 25%	MPNN_NEW_01
Tier 3 - Valutazione completa	2	Struttura, MD, endpoint, ESMFold e CamSol	20% ciascuno	MPNN_NEW_01

Nel **Tier 1** vengono considerate tutte le 24 sequenze uniche prodotte da ProteinMPNN. Poiché per l'intera coorte sono disponibili score ProteinMPNN, plausibilità ESM-2 e risultati CamSol validati, questi tre indicatori ricevono lo stesso peso. Il primo classificato è **MPNN_POOL_016**, con sequenza **PGPRNQYRDLP**, corrispondente a MPNN_NEW_03 nella shortlist. Questo risultato rappresenta soltanto una priorità di screening basata sui dati disponibili per tutta la coorte. Le successive analisi FoldX e Rosetta mostrano infatti che lo stesso candidato non mantiene il primo posto quando vengono considerate evidenze strutturali più approfondite.

Nel **Tier 2** vengono confrontati i cinque candidati già analizzati con FoldX e Rosetta. La componente strutturale riceve il 50% del peso complessivo, mentre lo score IA integrato e CamSol contribuiscono ciascuno per il 25%. In questo confronto MPNN_NEW_01 occupa il primo posto con uno score di 0,493, seguito da MPNN_NEW_05 con 0,427.

Nel **Tier 3** vengono confrontati soltanto MPNN_NEW_01 e MPNN_NEW_05, gli unici nuovi peptidi per i quali sono disponibili tutte le cinque categorie di evidenza: struttura statica, stabilità dinamica, energia endpoint, confidenza ESMFold e solubilità intrinseca prevista da CamSol. Ogni categoria riceve il 20% del peso complessivo.

I due candidati mostrano profili complementari. MPNN_NEW_05 è favorito dalla struttura statica, valutata con FoldX e Rosetta, e dall'energia endpoint. MPNN_NEW_01 è invece favorito dalla dinamica molecolare, dalla valutazione ESMFold e dal punteggio CamSol. Con pesi uguali, MPNN_NEW_01 prevale quindi in tre delle cinque categorie e ottiene il primo posto nella graduatoria finale.

Poiché il Tier 3 contiene soltanto due candidati, i componenti standardizzati esprimono soprattutto quale peptide risulta migliore in ciascun dominio. Lo score finale non misura l'affinità di legame e la distanza tra 0,200 e -0,200 non deve essere interpretata come una differenza quantitativa di efficacia biologica.

La selezione di **MPNN_NEW_01** rappresenta pertanto il miglior compromesso tra le evidenze disponibili, mentre **MPNN_NEW_05** rimane un'alternativa rilevante grazie al supporto strutturale ed energetico. Entrambi conservano valore scientifico perché occupano profili decisionali differenti.

Separatamente, l'analisi BoTorch di o8i propone **MPNN_POOL_023**, con sequenza **VGARNQYRDLN**, come candidato da sottoporre alla prossima valutazione strutturale. Questa proposta non entra nel punteggio finale del Tier 3, perché MPNN_POOL_023 non dispone ancora delle analisi strutturali, dinamiche ed energetiche richieste per il confronto con i due candidati completamente valutati nel workflow computazionale

Le graduatorie prodotte da o8j sono strumenti trasparenti di supporto alla decisione. Non costituiscono stime di affinità, misure sperimentali di solubilità o dimostrazioni di attività biologica.

Tabella 2 Graduatoria Tier 2

Rank	Candidato	Sequenza	Score Tier 2
1	MPNN_NEW_01	TGPRNQYRDLP	0,493
2	MPNN_NEW_05	IGPRHQYRDLP	0,427
3	MPNN_NEW_02	IGPRNQYRDLG	0,086
4	MPNN_NEW_04	IGPRNQYRDLN	-0,180
5	MPNN_NEW_03	PGPRNQYRDLP	-0,826

Tabella 3 Graduatoria finale Tier 3

Candidato	Rank finale	Score Tier 3
MPNN_NEW_01	1	0,200
MPNN_NEW_05	2	-0,200

Nella valutazione finale del Tier 3, MPNN_NEW_01 presenta il miglior equilibrio complessivo tra le cinque categorie di evidenza considerate: struttura statica, dinamica molecolare, energia endpoint, confidenza ESMFold e solubilità intrinseca prevista da CamSol. Il candidato è favorito dalla dinamica molecolare, da ESMFold e da CamSol.

MPNN_NEW_05 rimane un'alternativa rilevante perché riceve un supporto più favorevole dalla struttura statica, valutata con FoldX e Rosetta, e dall'energia endpoint. I due peptidi mostrano quindi profili complementari: MPNN_NEW_01 è il candidato prioritario nel bilancio complessivo, mentre MPNN_NEW_05 conserva interesse come lead sostenuto soprattutto dalle evidenze strutturali ed energetiche.

14 Transizione dalla Pipeline 4 alla Pipeline 5

La Pipeline 5 non trasforma direttamente la sequenza di un peptide in una piccola molecola. Utilizza invece le traiettorie di dinamica molecolare per individuare le interazioni con EGFR che si mantengono più frequentemente nel tempo. Queste informazioni vengono convertite in un modello farmacoforico, cioè in una rappresentazione tridimensionale delle caratteristiche chimiche considerate importanti per il riconoscimento del recettore.

La costruzione del farmacoforo utilizza le traiettorie di tre complessi peptide-EGFR: CFo2, CFo6 e MPNN_NEW_05. CFo2 e CFo6 collegano questa fase ai candidati selezionati nelle Pipeline 2 e 3, mentre MPNN_NEW_05 introduce l'informazione proveniente dalla progettazione con ProteinMPNN sviluppata nella Pipeline 4. La scelta di MPNN_NEW_05 conserva nel farmacoforo il contributo del nuovo peptide che ha ottenuto il supporto statico ed energetico più favorevole, anche se MPNN_NEW_01 presenta il miglior bilancio multi-obiettivo complessivo.

Il passaggio al farmacoforo permette di separare la sequenza specifica dei peptidi dalla geometria delle loro interazioni con EGFR. Non viene quindi cercata una piccola molecola che assomigli al peptide nella sua interezza. Si cercano invece composti capaci di riprodurre, nello spazio tridimensionale, alcune delle stesse funzioni chimiche coinvolte nell'interazione con il recettore.

Caratteristiche come donatori e accettori di legami a idrogeno, regioni idrofobiche, gruppi aromatici e centri carichi vengono rappresentate come punti o regioni dello spazio, accompagnati da una tolleranza geometrica. Molecole con strutture chimiche anche molto diverse dai peptidi possono soddisfare questi requisiti se dispongono i propri gruppi funzionali nelle posizioni compatibili con il modello. La Pipeline 5 trasferisce quindi un'ipotesi di interazione ricavata dai complessi peptide-EGFR verso lo screening di piccoli ligandi. Il farmacoforo rappresenta un insieme di vincoli per la selezione e il posizionamento delle molecole, non una dimostrazione che i composti selezionati mantengano realmente tutte le interazioni osservate nelle simulazioni.

15 Pipeline 5 Farmacoforo e scoperta piccoli ligandi

15.1 Estrazione del farmacoforo dagli ensemble MD

Il notebook 09a analizza le traiettorie di dinamica molecolare dei complessi formati da EGFR con CFo2, CFo6 e MPNN_NEW_05. Per ciascun complesso vengono esaminati 100 frame, cioè 100 configurazioni strutturali distribuite lungo la traiettoria. L'obiettivo è individuare le caratteristiche chimiche del peptide che interagiscono con il recettore in maniera ricorrente, evitando di basare il farmacoforo su una singola struttura istantanea.

Le caratteristiche considerate sono suddivise in sei categorie:

- **HBD:** gruppi capaci di donare un legame a idrogeno;
- **HBA:** gruppi capaci di accettare un legame a idrogeno;
- **HYD:** regioni idrofobiche;
- **ARO:** gruppi aromatici;
- **POS:** centri con carica positiva;
- **NEG:** centri con carica negativa.

Nel complesso, l'analisi registra 5.330 osservazioni di queste caratteristiche nei frame esaminati. Questo numero non corrisponde a 5.330 feature farmacoforiche differenti: comprende tutte le volte in cui una determinata caratteristica viene rilevata nelle diverse configurazioni delle tre traiettorie.

Il notebook determina quindi quali caratteristiche ricorrono con sufficiente frequenza nella traiettoria di ciascun peptide. Questa selezione produce 59 feature persistenti a livello di singolo candidato. Feature dello stesso tipo che occupano regioni tridimensionali vicine vengono successivamente raggruppate, ottenendo 32 cluster spaziali.

Il confronto tra i tre complessi identifica infine 17 feature core di consenso. Queste rappresentano le caratteristiche chimiche e geometriche maggiormente condivise o sostenute dagli ensemble analizzati e costituiscono la base del modello farmacoforico trasferito alle fasi successive. Il procedimento riduce quindi migliaia di osservazioni dipendenti dai singoli frame a un insieme più compatto di vincoli spaziali utilizzabili per lo screening molecolare.

Tutti i controlli di qualità previsti dal notebook risultano superati. Le 17 feature core rappresentano tuttavia un'ipotesi computazionale ricavata dalle traiettorie disponibili e non dimostrano, da sole, che ogni caratteristica sia indispensabile per il legame con EGFR.





Figura 15.1 – Distribuzione delle feature farmacoforiche persistenti nei complessi di EGFR con CF02, CF06 e MPNN_NEW_05. Le barre indicano quante caratteristiche di ciascun tipo persistono nelle traiettorie dei singoli peptidi prima del raggruppamento spaziale e della costruzione del farmacoforo di consenso. HBD e HBA indicano rispettivamente donatori e accettori di legami a idrogeno; HYD regioni idrofobiche; ARO gruppi aromatici; POS e NEG centri con carica positiva e negativa.



I tre peptidi mostrano una componente comune dominata da donatori e accettori di legami a idrogeno, accompagnata da regioni idrofobiche e centri carichi. CF02 e CF06 presentano profili complessivamente simili, mentre MPNN_NEW_05 mostra un contributo relativamente maggiore delle caratteristiche idrofobiche e aromatiche e un numero inferiore di feature negative. Le barre descrivono le feature persistenti rilevate separatamente per ogni peptide e non devono essere sommate per ottenere le 17 feature core finali. Queste ultime derivano dal successivo raggruppamento delle feature per tipo e posizione tridimensionale e dalla selezione dei cluster sostenuti dal criterio di consenso.

Figura 15.1b – Distribuzione tridimensionale delle 17 feature core del farmacoforo di consenso ricavato dalle traiettorie MD di CF02, CF06 e MPNN_NEW_05. Ogni punto rappresenta il centro di una proprietà chimica persistente: donatore di legame a idrogeno (HBD), accettore (HBA), regione idrofobica (HYD), aromatica (ARO), positiva (POS) o negativa (NEG). Le coordinate sono espresse in ångström. Alcune feature risultano sovrapposte nella proiezione e non sono quindi distinguibili singolarmente.

La figura mostra dove si trovano nello spazio le proprietà chimiche considerate importanti per l'interazione con EGFR.

Ogni punto colorato rappresenta una proprietà, per esempio:

- una zona che può formare un legame a idrogeno;
- una zona idrofobica;
- una zona aromatica;
- una zona con carica positiva o negativa.

In altre parole, è una specie di **mappa tridimensionale** che indica quali caratteristiche dovrebbe avere una piccola molecola e dove dovrebbe collocarle per riprodurre alcune interazioni osservate nei peptidi.

Non rappresenta una molecola specifica né la struttura di EGFR: rappresenta il **modello farmacoforico** usato per cercare potenziali ligandi.

Una piccola molecola può risultare compatibile con il modello se colloca gruppi funzionali appropriati in alcune di queste regioni, anche quando la sua struttura è molto diversa da quella dei peptidi di partenza.

Le 17 feature sono state selezionate considerando sia la loro persistenza nel tempo sia il supporto fornito dai diversi complessi peptide–EGFR. I punti rappresentano i centri dei cluster spaziali e non la posizione immutabile di singoli atomi. A ciascuna feature è infatti associata una tolleranza geometrica, necessaria per rappresentare le variazioni osservate durante la dinamica molecolare.

Il farmacoforo deve quindi essere interpretato come una sintesi delle geometrie campionate nelle traiettorie disponibili, non come una struttura rigida o come una descrizione completa del sito di legame. Inoltre, la durata limitata delle simulazioni restringe l'insieme delle conformazioni utilizzate per costruire il consenso.

15.2 Consolidamento del modello di screening

Il notebook 09b trasforma le 17 feature core ottenute in 09a in un modello più compatto e utilizzabile per lo screening molecolare. Alcune feature dello stesso tipo occupano infatti posizioni molto vicine e possono descrivere sostanzialmente la stessa regione di interazione.

Le 17 feature core vengono riunite in 10 gruppi farmacoforici complessivi. Nove gruppi entrano nella regola operativa di screening — cinque obbligatori e quattro opzionali — mentre il decimo, PGO6, conserva una funzione esclusivamente contestuale.

Per ridurre questa ridondanza, le feature compatibili vengono unite quando i loro centri si trovano entro una distanza di circa 1,25 Å. Il consolidamento non elimina l'informazione chimica principale, ma evita che una molecola debba soddisfare più volte vincoli quasi coincidenti. Le 17 feature core vengono così riunite in 10 gruppi farmacoforici.

A ogni gruppo viene assegnato un ruolo nella regola di screening:

Ruolo	Numero di gruppi	Funzione nella selezione
Obbligatorio	5	Tutti i gruppi devono essere soddisfatti per ottenere un hit
Opzionale	4	Deve essere soddisfatto almeno uno dei quattro gruppi
Contestuale	1	Fornisce informazione aggiuntiva, ma non determina l'accettazione della molecola

I cinque gruppi obbligatori definiscono il nucleo minimo richiesto dal modello. Una molecola deve collocare gruppi funzionali compatibili in tutte e cinque le regioni per superare la selezione farmacoforica più stringente. I quattro gruppi opzionali rappresentano interazioni alternative o complementari: non devono essere soddisfatti tutti, ma la molecola deve corrispondere ad almeno uno di essi.

Il gruppo contestuale viene invece conservato per descrivere un'ulteriore caratteristica dell'ambiente di interazione, senza trasformarla in un requisito di esclusione. La sua mancata corrispondenza non impedisce quindi a una molecola di superare lo screening.

La regola complessiva per definire un **hit farmacoforico stretto** è pertanto:

tutti e cinque i gruppi obbligatori + almeno uno dei quattro gruppi opzionali.

Questa classificazione rende il farmacoforo sufficientemente selettivo, ma mantiene un certo grado di flessibilità per consentire a scaffold chimici differenti di soddisfare il modello. I termini “obbligatorio” e “opzionale” descrivono esclusivamente la regola computazionale adottata: non dimostrano che una determinata interazione sia biologicamente indispensabile o dispensabile.




Figura 15.2 – Distribuzione tridimensionale dei nove gruppi farmacoforici utilizzati nella regola di screening. In blu sono rappresentati i cinque gruppi obbligatori, che devono essere soddisfatti contemporaneamente; in arancione i quattro gruppi opzionali, dei quali deve essere soddisfatto almeno uno. Il decimo gruppo, PG06, ha funzione contestuale e non è mostrato perché non determina l'accettazione o l'esclusione delle molecole. Gli assi riportano le coordinate spaziali in ångström.

Ogni punto rappresenta il centro di un gruppo ottenuto fondendo feature dello stesso tipo collocate entro circa 1,25 Å. Il consolidamento evita che caratteristiche quasi sovrapposte vengano conteggiate come vincoli indipendenti e rende il modello più semplice da applicare allo screening delle molecole.

I colori non indicano il tipo di interazione chimica, ma il ruolo del gruppo nella regola di selezione. Una molecola viene classificata come hit farmacoforico stretto soltanto se soddisfa tutti i cinque gruppi blu e almeno uno dei quattro gruppi arancioni. Il gruppo contestuale PGo6 conserva un'informazione descrittiva sull'ambiente di interazione, ma non contribuisce alla decisione di accettazione.

I punti mostrano i centri delle regioni farmacoforiche e non rappresentano singoli atomi né posizioni assolutamente rigide. Nello screening, ciascun gruppo è associato a una tolleranza spaziale entro la quale può essere riconosciuta una funzione chimica compatibile.

15.3 Generazione molecolare e screening farmacoforico

Il notebook o9c valuta una libreria di piccole molecole generata esternamente con REINVENT4. REINVENT4 produce le strutture molecolari sotto forma di SMILES, cioè stringhe testuali che descrivono la composizione e i legami di ciascuna molecola. La verifica della compatibilità con il farmacoforo viene però effettuata successivamente dal notebook o9c, mediante una procedura indipendente basata su RDKit.

Nell'esecuzione di produzione vengono acquisiti 1.000 SMILES unici. Per ogni molecola, il notebook tenta di costruire fino a dieci conformeri tridimensionali, ossia differenti disposizioni spaziali plausibili della stessa struttura chimica. La generazione 3D riesce per 996 molecole; le quattro molecole rimanenti non producono un conformero utilizzabile e non possono quindi essere sottoposte al confronto geometrico con il farmacoforo.

Per ciascun conformero vengono individuate le funzioni chimiche compatibili con i gruppi farmacoforici definiti in o9b. Il notebook cerca quindi un'assegnazione tra le feature della molecola e i cinque gruppi obbligatori del farmacoforo. Quando questa assegnazione è possibile, il conformero viene sovrapposto al modello e viene calcolato l'RMSD delle feature obbligatorie, che misura lo scostamento geometrico tra le funzioni della molecola e le rispettive regioni farmacoforiche.

Una molecola supera lo screening più stringente soltanto se:

- dispone di funzioni compatibili con tutti i cinque gruppi obbligatori;
- può essere allineata con un RMSD non superiore a 2,50 Å;
- soddisfa almeno uno dei quattro gruppi opzionali.

Tra le 996 molecole incorporate in 3D, 83 presentano un'assegnazione completa delle feature obbligatorie. Soltanto due soddisfano anche il requisito relativo ai gruppi opzionali e vengono quindi classificate come hit farmacoforici stretti:

Rank	Molecola	RMSD farmacoforico	Gruppo opzionale soddisfatto
1	MOL00570	1,562 Å	PG09
2	MOL00336	1,779 Å	PG07

La riduzione da 1.000 molecole a due hit avviene in più passaggi. Quattro molecole non producono una rappresentazione tridimensionale utilizzabile. Tra le 996 strutture rimanenti, 83 possiedono funzioni chimiche che possono essere assegnate a tutti i cinque gruppi obbligatori del farmacoforo. Soltanto due molecole soddisfano anche almeno uno dei gruppi opzionali e superano quindi la regola completa di screening.

Passaggio	Conteggio
SMILES unici acquisiti dalla libreria REINVENT4	1.000
Molecole con embedding 3D riuscito	996
Molecole con assegnazione completa dei cinque gruppi obbligatori	83
Hit che soddisfano anche almeno un gruppo opzionale	2

MOL00570 e MOL00336 sono quindi le due molecole che riproducono più completamente la regola geometrica definita in 09b. Il superamento dello screening indica una compatibilità tra le loro funzioni chimiche e la disposizione spaziale del farmacoforo, ma non dimostra che le molecole si leghino realmente a EGFR.

Lo score farmacoforico non è infatti un punteggio di docking, un'energia di legame o una misura di attività biologica. I candidati selezionati devono essere sottoposti alle successive verifiche di qualità chimica, proprietà molecolari, potenziali criticità, docking e analisi delle interazioni.




Figura 15.3 – Distribuzione dell'RMSD farmacoforico per le 83 molecole con assegnazione completa dei cinque gruppi obbligatori. L'RMSD misura lo scostamento tra le funzioni chimiche della molecola e le posizioni previste dal farmacoforo dopo l'allineamento tridimensionale. La linea tratteggiata indica la soglia massima di 2,50 Å applicata al contributo obbligatorio. Valori più bassi corrispondono a una migliore sovrapposizione geometrica.

La maggior parte delle 83 molecole con un'assegnazione completa dei gruppi obbligatori presenta un RMSD inferiore alla soglia di 2,50 Å. Il superamento di questa soglia geometrica non è però l'unico requisito previsto dalla regola di screening. Per essere classificata come hit farmacoforico stretto, una molecola deve anche soddisfare almeno uno dei quattro gruppi opzionali.

Soltanto MOL00570 e MOL00336 rispettano entrambe le condizioni: presentano un allineamento dei gruppi obbligatori entro la soglia e soddisfano rispettivamente i gruppi opzionali PGO9 e PGO7. Per

questo motivo il numero degli hit finali è molto più basso rispetto al numero di molecole collocate a sinistra della linea tratteggiata.

Le molecole sono state generate esternamente con REINVENT⁴ senza utilizzare il farmacoforo come vincolo diretto durante la generazione. Il notebook 09c applica il modello farmacoforico soltanto in un secondo momento, come filtro tridimensionale sulla libreria già prodotta. Il workflow deve quindi essere descritto come **generazione molecolare de novo seguita da screening farmacoforico**, e non come reinforcement learning guidato o condizionato dal farmacoforo.

L'RMSD riportato nella figura valuta esclusivamente la corrispondenza geometrica con il modello. Non rappresenta un'energia di legame, uno score di docking o una previsione dell'attività biologica.

15.4 Filtri chimici e rescue track

Il notebook 09d valuta la qualità chimica delle 83 molecole che in 09c erano riuscite a soddisfare tutti i cinque gruppi farmacoforici obbligatori. Questa popolazione comprende i due hit stretti MOL00570 e MOL00336 e 81 *near-miss*, cioè molecole compatibili con i gruppi obbligatori ma incapaci di soddisfare almeno uno dei gruppi opzionali.

Per ogni molecola vengono calcolate proprietà fisicochimiche che possono influenzare la successiva selezione sperimentale, tra cui:

- peso molecolare;
- lipofilia prevista mediante cLogP;
- superficie polare TPSA;
- numero di donatori e accettori di legami a idrogeno;
- numero di legami rotabili;
- carica formale e numero di anelli;
- QED, usato come indicatore sintetico di somiglianza con lo spazio dei farmaci;
- Fsp3, che descrive il contributo di atomi di carbonio con geometria tridimensionale;
- rispetto dei criteri descrittivi di Lipinski e Veber;
- possibili alert strutturali PAINS e Brenk;
- synthetic accessibility score, calcolato in questa esecuzione con il metodo RDKit.

Il notebook assegna quindi a ciascuna molecola una classe di priorità chimica. La categoria **CHEM_PASS** richiede il rispetto dell'intervallo chimico definito per il docking, l'assenza di alert PAINS e Brenk e un synthetic accessibility score non superiore alla soglia stabilita. La categoria **CHEM_WARN** segnala molecole che rientrano nell'intervallo generale, ma presentano almeno una criticità euristica. La categoria **CHEM_FAIL** identifica invece molecole esterne ai limiti stabiliti per il successivo docking.

I due hit farmacoforici stretti non superano questa valutazione:

Valutazione chimica degli hit farmacoforici stretti

Molecola	Esito chimico	Principali criticità
MOL00336	CHEM_FAIL	Peso molecolare e cLogP molto elevati, tre alert Brenk, synthetic accessibility sfavorevole
MOL00570	CHEM_FAIL	Peso molecolare, TPSA, numero di donatori, accettori e legami rotabili superiori ai limiti; due alert Brenk

MOL00336 ha un peso molecolare di circa 958 Da e un cLogP pari a 11,38, mentre MOL00570 ha un peso molecolare di circa 669 Da, una TPSA di 251 Å², 8 donatori, 16 accettori e 21 legami rotabili. Nessuna delle due molecole viene pertanto ammessa al percorso primario di docking. Il fatto che soddisfino il farmacoforo resta registrato come evidenza geometrica, ma non compensa le criticità chimiche rilevate. Per evitare che l'intero percorso di selezione si interrompa, il workflow applica una **rescue track esplorativa** alle 81 molecole classificate come *near-miss*. Queste molecole soddisfano tutti i gruppi farmacoforici obbligatori, ma non il requisito aggiuntivo di almeno un gruppo opzionale. Non vengono quindi riclassificate come hit stretti: il loro livello di evidenza farmacoforica rimane esplicitamente inferiore. Le molecole della rescue track vengono ordinate considerando qualità chimica, compatibilità con i gruppi obbligatori e diversità strutturale. La diversità viene valutata mediante fingerprint Morgan, similarità di Tanimoto e clustering Butina. Questo passaggio riduce il rischio di selezionare molte molecole quasi identiche e favorisce l'esplorazione di scaffold differenti. Dopo una preselezione dei 30 *near-miss* con il profilo più favorevole, vengono scelti otto candidati classificati CHEM_PASS e appartenenti a cluster di diversità distinti:

Shortlist della rescue track destinata al docking

Rank docking	Candidato	RMSD obbligatorio	Classe chimica
1	MOL00053	1,356 Å	CHEM_PASS
2	MOL00484	1,653 Å	CHEM_PASS
3	MOL00273	1,924 Å	CHEM_PASS
4	MOL00600	1,212 Å	CHEM_PASS
5	MOL00294	1,151 Å	CHEM_PASS
6	MOL00857	1,495 Å	CHEM_PASS
7	MOL00583	1,341 Å	CHEM_PASS
8	MOL00489	1,578 Å	CHEM_PASS

Questi otto candidati costituiscono la shortlist destinata al docking. La loro selezione rappresenta un compromesso controllato: possiedono un profilo chimico più favorevole e riproducono il nucleo obbligatorio del farmacoforo, ma non soddisfano la regola farmacoforica completa.

La rescue track non deve quindi essere interpretata come una promozione retroattiva dei *near-miss* a hit stretti. Mantiene aperta una linea esplorativa alternativa, nella quale il supporto farmacoforico incompleto viene valutato insieme alla migliore trattabilità chimica. PAINS, Brenk, QED e synthetic accessibility restano indicatori computazionali di priorità e non misure sperimentali di tossicità, sintesi o sviluppabilità.




Figura 15.4a – Distribuzione del peso molecolare e del cLogP per le 83 molecole con assegnazione completa dei gruppi farmacoforici obbligatori. In blu sono indicati i due hit farmacoforici stretti; in arancione gli 81 near-miss che soddisfano soltanto i gruppi obbligatori. Le linee tratteggiate corrispondono ai valori convenzionali di riferimento di Lipinski per peso molecolare (500 Da) e cLogP (5). Queste soglie hanno funzione descrittiva e non coincidono, da sole, con la classificazione CHEM_PASS utilizzata dal notebook.

I due hit farmacoforici stretti occupano regioni estreme del grafico. MOL00336 presenta contemporaneamente peso molecolare e cLogP molto elevati, mentre MOL00570 presenta un peso molecolare superiore ai limiti adottati e un cLogP molto basso. La classificazione chimica considera anche TPSA, carica, legami rotabili, alert strutturali e accessibilità sintetica; il grafico mostra quindi soltanto due delle proprietà responsabili della selezione.




Figura 15.4c – Strutture chimiche bidimensionali dei due hit farmacoforici stretti. MOL00336 e MOL00570 soddisfano la regola farmacoforica completa, ma non superano i filtri chimici adottati.




Figura 15.4b – Punteggio di priorità chimica degli otto candidati selezionati nella rescue track per il docking. Valori più elevati indicano un profilo relativamente più favorevole secondo i descrittori e le regole di triage applicate in 09d. Tutti gli otto candidati sono classificati CHEM_PASS, ma rimangono near-miss farmacoforici perché non soddisfano alcun gruppo opzionale.

MOL00053 e MOL00484 ottengono i punteggi di priorità chimica più elevati, ma le differenze all'interno della shortlist sono contenute. Il punteggio serve a ordinare molecole che hanno già superato i filtri chimici e non rappresenta una previsione dell'affinità, dell'attività biologica o del risultato del docking. La selezione finale tiene conto anche della diversità strutturale, in modo da non concentrare il docking su molecole troppo simili.

Nei notebook successivi, tutti gli otto candidati mantengono l'etichetta di provenienza **NEAR_MISS_RESCUE**. Questa tracciabilità conserva la distinzione tra i due hit che avevano soddisfatto l'intera regola farmacoforica e le molecole recuperate attraverso il percorso esplorativo. Gli otto candidati ammessi al docking non vengono quindi riclassificati retrospettivamente come hit farmacoforici stretti: possiedono un profilo chimico più favorevole, ma soddisfano soltanto la componente obbligatoria del modello.

15.5 DiffDock e valutazione delle pose

Il notebook 09e valuta come gli otto candidati provenienti dalla rescue track possano disporsi nello spazio rispetto alla catena B di EGFR della struttura 3NJP. A questo scopo prepara il recettore e i ligandi per un'esecuzione esterna di DiffDock e successivamente importa e analizza le pose generate. Il docking eseguito in 09e è un docking globale sull'intera catena B di EGFR e non uno screening vincolato alla native EGF-EGFR interface. Di conseguenza, la selezione delle pose effettuata originariamente dal notebook identifica geometrie favorevoli rispetto al recettore nel suo complesso, ma non garantisce che la posa selezionata ricada nella regione biologica dell'interfaccia EGF. Una **posa di docking** è una possibile posizione e orientazione tridimensionale del ligando rispetto al recettore. Per ciascuna molecola DiffDock genera 10 pose alternative mediante 20 passaggi di inferenza. Sono state quindi ottenute e analizzate complessivamente 80 pose, senza file mancanti rispetto al numero previsto.

Per ciascuna delle dieci pose generate per ogni candidato, il notebook considera:

- la **confidence DiffDock**, che indica quanto il modello ritiene plausibile la geometria proposta. In questa analisi, valori più alti, cioè meno negativi, esprimono una maggiore confidenza, ma non rappresentano un'energia o un'affinità di legame;
- il **numero di residui di EGFR contattati** dal ligando;
- la **percentuale di atomi pesanti del ligando in contatto** con il recettore;
- la **distanza minima** tra gli atomi del ligando e quelli del recettore;
- la presenza di eventuali **clash severi**, cioè sovrapposizioni steriche incompatibili tra gli atomi.


Il controllo dei clash severi verifica la presenza di sovrapposizioni atomiche incompatibili tra ligando e recettore. Il risultato è registrato per ciascuna posa come indicatore sì/no, ma non è riportato nella tabella riepilogativa.

Questi parametri contribuiscono alla selezione di una posa rappresentativa per ciascun candidato. La tabella seguente riporta, per le otto pose selezionate, la confidence DiffDock, il pose-support score, il numero di residui di EGFR contattati e la percentuale di atomi pesanti del ligando coinvolti nei contatti. La distanza minima e il controllo dei clash severi, pur essendo considerati nella valutazione, non sono riportati nella tabella per mantenerla compatta.

Il notebook combina la confidence di DiffDock e le informazioni sui contatti in uno score interno di supporto della posa. Questo score serve a confrontare le geometrie ottenute e non deve essere interpretato come una previsione dell'affinità di legame. La posa selezionata per una molecola può pertanto non coincidere con la prima posa proposta da DiffDock: una posa con confidence leggermente inferiore può essere preferita se presenta contatti più estesi e una geometria complessivamente più plausibile.

Rank 09e	Candidato	Posa DiffDock selezionata	Confidence DiffDock	Supporto della posa	Residui EGFR contattati	Atomi del ligando in contatto
1	MOL00273	1	-0,880	0,850	7	82,6%
2	MOL00583	1	-2,020	0,827	12	93,3%
3	MOL00600	4	-1,890	0,795	9	91,2%
4	MOL00484	4	-3,000	0,770	14	100,0%
5	MOL00857	3	-2,970	0,692	12	78,1%
6	MOL00053	3	-2,730	0,644	9	65,2%

7	MOL00489	3	-2,330	0,642	7	58,6%
8	MOL00294	10	-5,970	0,031	0	0,0%

A Posizione della posa rispetto alla catena B di EGFR**B Dettaglio dei residui entro 4,5 Å**

Posa DiffDock selezionata in 09e. Le linee arancioni indicano contatti atomici $\leq 3,5$ Å, non legami a idrogeno assegnati.

Figura 15.5 – Posa DiffDock selezionata di MOL00583 rispetto alla catena B di EGFR 3NJP. Il pannello A mostra la posizione complessiva del ligando rispetto al recettore; il pannello B evidenzia i residui con almeno un atomo entro 4,5 Å. Le linee arancioni rappresentano contatti atomici entro 3,5 Å e non identificano necessariamente legami a idrogeno. La posa costituisce un'ipotesi strutturale computazionale e non una struttura sperimentale del complesso.

Nella posa selezionata, MOL00583 entra in contatto con 12 residui della catena B: GLU3, LYS4, VAL6, GLU60, ALA62, ARG84, ASN86, ARG231, GLU233, ALA265, THR266 e CYS267. Il 93,3% degli atomi pesanti del ligando partecipa ad almeno un contatto con il recettore. Questi dati descrivono un coinvolgimento geometrico esteso, ma non permettono da soli di stabilire la forza, la specificità o la stabilità sperimentale dell'interazione.

Nessuna delle pose selezionate presenta un clash severo. MOL00273 occupa il primo posto grazie alla combinazione più favorevole tra confidence DiffDock e contatti con il recettore. MOL00583 mostra un supporto particolarmente equilibrato, con 12 residui di EGFR contattati e oltre il 93% degli atomi pesanti del ligando coinvolti nel contatto. MOL00484 raggiunge il coinvolgimento recettoriale più esteso: la posa selezionata contatta 14 residui e tutti gli atomi pesanti del ligando partecipano almeno a un contatto.

MOL00294 riceve invece un supporto molto debole. Sebbene la posa selezionata non presenti sovrapposizioni steriche severe, non stabilisce contatti con il recettore e non costituisce quindi una geometria convincente per le analisi successive.

La successiva verifica site-specifica ha confrontato le pose selezionate in 09e con i 43 residui della catena B che definiscono l'interfaccia nativa con EGF. Tra le otto pose originariamente selezionate, soltanto

MOL00484 e MOL00857 risultano site-relevant rispetto a tale interfaccia. Le pose selezionate di MOL00273, MOL00583, MOL00600, MOL00053, MOL00489 e MOL00294 non risultano invece site-relevant. In particolare, la posa di MOL00583 successivamente propagata nelle analisi 09f–09k è quindi una configurazione off-site rispetto alla native EGF–EGFR interface.

L'analisi delle pose alternative mostra che per sette degli otto candidati esistono pose con almeno una parziale pertinenza all'interfaccia EGF, generalmente associate però a un supporto DiffDock meno favorevole; MOL00600 non presenta invece una posa site-relevant tra le dieci pose analizzate. Queste pose alternative non vengono sostituite retrospettivamente alle pose originariamente selezionate, perché ciò modificherebbe a posteriori il workflow eseguito. I controlli effettuati vengono pertanto utilizzati come controllo interpretativo della pertinenza biologica delle pose, mantenendo separati il ranking storico whole-receptor di 09e e la successiva valutazione site-specifica.

I risultati del docking non modificano la provenienza dei candidati: tutte le otto molecole restano **near-miss della rescue track** e non diventano retrospettivamente hit farmacoforici stretti. DiffDock fornisce un ulteriore livello di priorità strutturale, ma non dimostra né il legame con EGFR né l'attività biologica.




Figura 15.6 – Confidence DiffDock della posa selezionata per ciascun candidato. Valori più alti, cioè meno negativi, indicano una maggiore confidenza del modello nella geometria proposta. La confidence è un indice interno di DiffDock e non rappresenta un'energia o una previsione dell'affinità di legame.

MOL00273 presenta la confidence DiffDock più favorevole, seguito da MOL00600 e MOL00583. MOL00294 mostra invece un valore nettamente più basso e la sua posa selezionata non stabilisce contatti con il recettore.

La confidence non è stata utilizzata isolatamente per scegliere le pose. Il *pose-support score* la combina con la frazione degli atomi del ligando in contatto con EGFR, il numero di residui recettoriali coinvolti e l'assenza di sovrapposizioni steriche severe. Questo indicatore serve esclusivamente a selezionare e ordinare le geometrie ottenute: non è un'energia fisica, non misura l'affinità di legame e non trasforma i candidati della rescue track in hit farmacoforici stretti.

15.5.1 Pertinenza delle pose alla native EGF–EGFR interface

Il docking 09e è stato eseguito sull'intera superficie della catena B di EGFR. Le pose selezionate sono state pertanto successivamente confrontate con i 43 residui della native EGF–EGFR interface, così da valutarne separatamente la pertinenza site-specifica. Tra gli otto candidati, le pose selezionate di MOL00484 e MOL00857 risultano site-relevant, mentre quelle di MOL00273, MOL00583, MOL00600,

MOL00053, MOL00489 e MOL00294 non mostrano overlap con l'interfaccia secondo il criterio adottato. Tra i quattro candidati successivamente raffinati in 09f, soltanto la posa selezionata di MOL00484 conserva pertinenza site-specifica. Per diversi candidati sono state individuate pose alternative con almeno una parziale pertinenza all'interfaccia; tali pose non sono state tuttavia sostituite retroattivamente alle pose originariamente selezionate, per non modificare a posteriori il workflow eseguito. Il ranking prodotto da 09e deve pertanto essere interpretato come ranking whole-receptor/full-surface e non come ranking specifico della native EGF-EGFR interface.

15.6 Rescoring locale con AutoDock Vina

Il notebook 09f approfondisce l'analisi dei quattro candidati meglio classificati nella fase DiffDock: MOL00273, MOL00583, MOL00600 e MOL00484. Tutti mantengono la provenienza **NEAR_MISS_RESCUE** e lo stato farmacoforico **NEAR_MISS_MANDATORY_ONLY**.

È importante precisare che 09f utilizza le pose originariamente selezionate da 09e senza sostituirle con pose alternative maggiormente pertinenti all'interfaccia. Tra i quattro candidati sottoposti al raffinamento Vina — MOL00273, MOL00583, MOL00600 e MOL00484 — soltanto la posa selezionata di MOL00484 risulta pertinente alla native EGF-EGFR interface. Le pose di MOL00273, MOL00583 e MOL00600 propagate in 09f risultano invece off-site rispetto a tale interfaccia.

In questa fase AutoDock Vina non effettua un nuovo docking globale e non cerca una regione di legame diversa. Per ciascun candidato, il procedimento parte dalla posa selezionata nel notebook 09e e comprende due passaggi:

1. Vina calcola lo score della posa DiffDock senza modificarne la geometria;
2. la stessa posa viene sottoposta a una breve ottimizzazione locale, durante la quale il ligando può compiere piccoli aggiustamenti nelle vicinanze della posizione iniziale.

Al termine dell'ottimizzazione vengono ricalcolati lo score Vina e l'RMSD degli atomi pesanti rispetto alla posa DiffDock iniziale. Lo score Vina è una funzione empirica espressa in unità simili alle kcal/mol: valori più negativi indicano una configurazione relativamente più favorevole secondo Vina, ma non costituiscono una misura rigorosa dell'energia libera o dell'affinità di legame.

Candidato	Vina prima	Vina dopo	Δ ottimizzazione	RMSD locale Å
MOL00600	1,998	-5,791	-7,789	0,190
MOL00583	0,384	-4,314	-4,698	0,586
MOL00484	-0,556	-4,267	-3,711	0,057
MOL00273	-2,982	-3,937	-0,955	0,203

La **variazione dello score** è calcolata sottraendo lo score iniziale da quello ottenuto dopo l'ottimizzazione. Un valore negativo indica quindi un miglioramento secondo la funzione di scoring di Vina. L'**RMSD locale** originariamente riportato da 09f confronta invece le geometrie del ligando dopo sovrapposizione e deve essere interpretato principalmente come indicatore della variazione conformazionale del ligando, non come misura dello spostamento assoluto della posa rispetto al recettore. Per valutare quest'ultimo aspetto, le pose prima e dopo il raffinamento sono state confrontate mantenendo fisso il sistema di riferimento recettoriale. Nel confronto receptor-frame, gli RMSD degli atomi pesanti risultano pari a **1,494 Å per MOL00600, 1,418 Å per MOL00583, 1,272 Å per MOL00484 e 1,118 Å per MOL00273**. Gli spostamenti dei centroidi sono rispettivamente **0,384 Å, 0,523 Å, 0,612 Å e 0,787 Å**. Questi valori descrivono lo spostamento della posa nel riferimento del recettore e completano l'informazione fornita dagli RMSD conformazionali originariamente riportati da 09f. MOL00600 raggiunge lo score finale più favorevole, pari a **-5,791**, mentre il suo RMSD conformazionale originariamente riportato da 09f è pari a **0,190 Å**. Il forte miglioramento dello score

rispetto al valore iniziale indica che l'ottimizzazione locale produce una configurazione più favorevole secondo Vina. Nel riferimento del recettore, il confronto prima/dopo il raffinamento restituisce un RMSD di **1,494 Å** e uno spostamento del centroide di **0,384 Å**.

MOL00583 occupa il secondo posto secondo lo score Vina finale, pari a **-4,314**. Il valore di **0,586 Å** è il più elevato tra gli RMSD conformazionali originariamente riportati per i quattro candidati; nel confronto receptor-frame, MOL00583 presenta invece un RMSD di **1,418 Å** e uno spostamento del centroide di **0,523 Å**.

MOL00484 presenta il più piccolo RMSD conformazionale originariamente riportato da 09f, pari a **0,057 Å**. Tale valore indica una limitata variazione della geometria interna del ligando dopo sovrapposizione, ma non misura direttamente lo spostamento della posa rispetto al recettore. Nel confronto receptor-frame, MOL00484 mostra infatti un RMSD di **1,272 Å** e uno spostamento del centroide di **0,612 Å**. Il raffinamento rimane locale, ma la conservazione della posa non deve quindi essere dedotta dal solo valore di 0,057 Å.

MOL00273, primo nella valutazione DiffDock, parte dallo score Vina iniziale più favorevole e dopo il raffinamento raggiunge uno score finale meno favorevole rispetto agli altri tre candidati. Nel confronto receptor-frame presenta un RMSD di **1,118 Å** e uno spostamento del centroide di **0,787 Å**. Il cambiamento dell'ordine mostra che DiffDock e Vina valutano aspetti differenti delle pose e non devono necessariamente produrre lo stesso ranking.

Nel complesso, **MOL00600 riceve lo score energetico locale più favorevole secondo Vina**, mentre i valori RMSD originariamente riportati da 09f descrivono principalmente variazioni conformazionali e non devono essere utilizzati da soli per stabilire la conservazione della posa rispetto al recettore. Inoltre, soltanto MOL00484 tra i quattro candidati raffinati deriva da una posa selezionata pertinente alla native EGF-EGFR interface. I risultati di 09f costituiscono pertanto un confronto relativo delle configurazioni propagate da 09e e non dimostrano né il legame con EGFR, né il legame specifico all'interfaccia EGF, né l'attività biologica.




Figura 15.7 – Confronto tra lo score Vina della posa DiffDock iniziale e quello ottenuto dopo l'ottimizzazione locale. Valori più negativi indicano una valutazione relativamente più favorevole secondo la funzione di scoring di Vina. MOL00600 raggiunge lo score finale migliore, ma richiede anche la correzione energetica più ampia rispetto alla posa iniziale.

15.6.1 Spostamento delle pose nel riferimento del recettore

Il valore GetBestRMS precedentemente ottenuto dopo l'allineamento del solo ligando non misura direttamente la stabilità della posa rispetto al recettore. Utilizzando le strutture già generate, lo spostamento è stato pertanto ricalcolato nel sistema di riferimento di EGFR. Gli RMSD risultano pari a 1,494 Å per MOL00600, 1,418 Å per MOL00583, 1,272 Å per MOL00484 e 1,118 Å per MOL00273; gli spostamenti dei centroidi sono rispettivamente 0,384, 0,523, 0,612 e 0,787 Å. Questi valori indicano riarrangiamenti locali limitati durante il raffinamento Vina, ma non costituiscono una dimostrazione di stabilità nella native EGF-EGFR interface. Per MOL00583 rimane determinante la verifica site-specifica: la posa raffinata utilizzata nel successivo follow-up risulta off-site rispetto alla native EGF-EGFR interface.

15.7 Selezione integrata dei lead

Il notebook 09g conclude la Pipeline 5 integrando i risultati prodotti nelle fasi precedenti per i quattro finalisti: MOL00583, MOL00484, MOL00600 e MOL00273. Il confronto considera sei assi di valutazione:

- **adattamento al farmacoforo:** misura quanto bene la molecola riproduce nello spazio i gruppi farmacoforici obbligatori; un RMSD inferiore è considerato più favorevole;
- **profilo chimico:** riassume le proprietà fisicochimiche, la drug-likeness e l'assenza delle criticità considerate nel filtro chimico;
- **supporto strutturale DiffDock:** deriva dal ranking delle pose ottenuto nel notebook 09e;
- **coinvolgimento del recettore:** considera principalmente la frazione degli atomi del ligando in contatto con EGFR e, come criterio secondario, il numero di residui recettoriali coinvolti;
- **supporto energetico Vina:** utilizza lo score ottenuto dopo l'ottimizzazione locale; valori più negativi sono considerati più favorevoli;
- **variazione conformazionale locale:** utilizza l'RMSD degli atomi pesanti originariamente calcolato in 09f dopo sovrapposizione del ligando. Questo indicatore descrive principalmente la variazione conformazionale del ligando durante il raffinamento e non deve essere interpretato come misura diretta dello spostamento della posa rispetto al recettore. Queste grandezze hanno significati e scale differenti. Il notebook evita quindi di sommarne direttamente i valori, perché il risultato non avrebbe un'unità fisica interpretabile. Per ciascun asse, i quattro candidati vengono invece ordinati dal più al meno favorevole.

Un candidato riceve un **supporto top-2** ogni volta che si colloca nelle prime due posizioni di uno dei sei assi. Il conteggio finale indica pertanto in quanti ambiti il candidato appartiene alla metà superiore del gruppo dei finalisti. Non rappresenta un'energia, una probabilità di legame o uno score biologico. I sei assi devono essere interpretati come criteri complementari di ranking e non come sei evidenze statisticamente o metodologicamente indipendenti. Alcuni derivano infatti dalla stessa catena computazionale: il supporto strutturale DiffDock e il coinvolgimento del recettore sono entrambi ricavati dalle pose selezionate in 09e, mentre lo score Vina e la variazione conformazionale locale derivano dal raffinamento delle stesse pose in 09f. Il conteggio dei supporti top-2 descrive pertanto una convergenza multi-criterio interna al workflow, ma non equivale al numero di conferme indipendenti di un medesimo evento di legame.




Figura 15.8 – Strutture chimiche bidimensionali dei quattro finalisti della Pipeline 5. MOL00583 è il lead computazionale primario; MOL00484, MOL00600 e MOL00273 sono mantenuti come alternative ortogonali. Tutti provengono dalla rescue track.

Rank finale	Candidato	Livello di priorità	Supporti top-2	Principali evidenze
1	MOL00583	MOL00583 — TIER 1 – lead computazionale storico (ranking 09g)	4/6	Farmacoforo, DiffDock, coinvolgimento del recettore e Vina
2	MOL00484	TIER 2 – lead ortogonale di follow-up	3/6	Profilo chimico, coinvolgimento del recettore e stabilità geometrica
3	MOL00600	TIER 2 – lead ortogonale di follow-up	3/6	Adattamento farmacoforico, Vina e stabilità geometrica
4	MOL00273	TIER 2 – lead ortogonale di follow-up	2/6	Supporto DiffDock e profilo chimico

Il ranking storico prodotto da 09g integra sei assi di valutazione e viene qui mantenuto come risultato originario del workflow, distinguendolo dalle successive verifiche site-specifiche rispetto alla native EGF–EGFR interface.

MOL00583 occupa il primo posto perché riceve un supporto top-2 in quattro dei sei assi: adattamento farmacoforico, supporto DiffDock, coinvolgimento del recettore e score Vina. Questa classificazione descrive l'esito dell'integrazione multi-criterio disponibile al momento dell'esecuzione del notebook. La successiva verifica della pertinenza delle pose mostra tuttavia che tali criteri sono parzialmente dipendenti e, soprattutto, che la posa di MOL00583 propagata da 09g e raffinata in 09f è off-site rispetto alla native EGF–EGFR interface. MOL00583 deve quindi essere descritto come lead computazionale storico selezionato da 09g, e non come candidato attualmente supportato da una posa site-relevant rispetto all'interfaccia EGF–EGFR.

MOL00484 e MOL00600 ottengono entrambi tre supporti top-2, ma attraverso profili differenti. MOL00484 è favorito dal profilo chimico, dall'estensione dei contatti con il recettore e dal più basso RMSD conformazionale originariamente riportato in 09f; inoltre, tra i quattro candidati raffinati con Vina, è l'unico la cui posa selezionata risulta pertinente alla native EGF-EGFR interface. MOL00600 presenta invece il miglior adattamento farmacoforico e il miglior score Vina finale, ma la posa propagata in 09f risulta off-site rispetto all'interfaccia EGF. Il secondo posto storico di MOL00484 deriva dai criteri di spareggio applicati dal notebook, in particolare dal miglior rango mediano ottenuto sui sei assi. La verifica site-specifica ne rafforza l'interesse strutturale per un eventuale follow-up focalizzato sull'interfaccia EGF, ma non determina automaticamente la sua promozione a nuovo lead.

MOL00273 riceve due supporti top-2. È il candidato maggiormente favorito da DiffDock e occupa il secondo posto nel dominio chimico, ma ottiene risultati meno favorevoli negli altri assi. Il suo supporto è quindi più specifico e meno distribuito tra i diversi metodi.

Tutti e quattro i candidati risultano Pareto non dominati nello spazio decisionale adottato: nessuno risulta migliore di tutti gli altri contemporaneamente nei sei domini. MOL00484, MOL00600 e MOL00273 vengono pertanto mantenuti nel workflow originario come alternative di TIER 2 rispetto a MOL00583. Le verifiche successive sulla pertinenza delle pose rispetto alla native EGF-EGFR interface modificano l'interpretazione biologica di alcune delle evidenze utilizzate, ma non vengono impiegate per ricalcolare retroattivamente il ranking di 09g. Il risultato originario viene conservato per tracciabilità e provenance del workflow, mentre la valutazione site-specifica viene riportata separatamente per orientare eventuali analisi successive.

La classificazione non modifica la provenienza delle molecole. Tutti i finalisti rimangono candidati NEAR_MISS_RESCUE, perché soddisfano i gruppi farmacoforici obbligatori ma non il requisito opzionale previsto per gli hit stretti. MOL00583 mantiene la qualifica di lead computazionale storico della rescue track in quanto candidato selezionato originariamente da 09g; tale etichetta documenta la provenance del workflow e non costituisce una validazione della sua posa rispetto alla native EGF-EGFR interface. La conferma della localizzazione del sito di interazione richiederebbe ulteriori analisi computazionali site-specifiche, mentre la dimostrazione del legame e dell'attività biologica richiederebbe soprattutto una successiva validazione sperimentale.




Figura 15.9 – Ranking storico dei quattro finalisti nei sei assi di valutazione utilizzati da 09g. Il rank 1 indica il risultato più favorevole e il rank 4 quello meno favorevole all'interno del gruppo. La figura documenta il criterio multi-dominio che ha determinato la selezione originaria di MOL00583, ma i sei assi non rappresentano sei evidenze indipendenti né costituiscono un ranking specifico per la native EGF-EGFR interface. Le successive verifiche site-specifiche mostrano infatti che la posa di MOL00583 propagata nel follow-up è off-site, mentre MOL00484 conserva supporto strutturale pertinente all'interfaccia EGF.

La figura documenta la complementarità dei quattro finalisti secondo i criteri utilizzati originariamente da 09g. MOL00583 non è primo in nessun singolo asse, ma si colloca tra i primi due in quattro dimensioni: adattamento farmacoforico, supporto strutturale DiffDock, coinvolgimento del recettore e supporto energetico Vina. Questa distribuzione dei supporti spiega la sua selezione storica come lead computazionale nel workflow 09g; non deve tuttavia essere interpretata come quattro conferme indipendenti del legame né come dimostrazione della pertinenza della posa alla native EGF–EGFR interface.»

«Gli altri candidati presentano profili differenti. Nel ranking storico, MOL00484 riceve un supporto favorevole dal profilo chimico, dal coinvolgimento del recettore e dal più basso RMSD conformazionale originariamente riportato in 09f; MOL00600 presenta il miglior adattamento farmacoforico e il miglior score Vina finale; MOL00273 riceve il miglior supporto strutturale da DiffDock. La successiva valutazione site-specifica aggiunge tuttavia un'informazione essenziale: tra i quattro candidati raffinati in 09f, soltanto la posa selezionata di MOL00484 risulta pertinente alla native EGF–EGFR interface. Questo risultato ne mantiene l'interesse per un eventuale follow-up site-specifico, senza determinarne automaticamente la promozione a nuovo lead.»

«Tutti e quattro risultano Pareto non dominati nello spazio decisionale originariamente adottato da 09g. Tale risultato e il ranking associato vengono conservati come documentazione del processo decisionale storico e non vengono ricalcolati retroattivamente sulla base delle verifiche successive. La valutazione originaria multi-criterio e la successiva verifica della pertinenza rispetto all'interfaccia EGF devono pertanto essere considerate come due livelli distinti di interpretazione.

15.7.1 Reinterpretazione del ranking storico

I sei assi utilizzati da 09g non devono essere interpretati come sei evidenze indipendenti, poiché farmacoforo, docking, coinvolgimento del recettore, Vina e geometria condividono in parte gli stessi candidati, input strutturali o pose e presentano quindi una parziale dipendenza. Il ranking storico viene preservato come provenance della decisione originaria (MOL00583: 4/6 supporti top-2; MOL00484: 3/6; MOL00600: 3/6; MOL00273: 2/6), ma non viene trasformato retroattivamente in un nuovo ranking specifico per la native EGF–EGFR interface. MOL00583 mantiene pertanto la qualifica di lead computazionale storico selezionato da 09g, pur richiedendo una rivalutazione strutturale site-relevant; MOL00484 conserva invece una catena di supporto strutturale pertinente alla native EGF–EGFR interface. Tale osservazione non determina automaticamente la promozione di MOL00484 a nuovo lead.

15.8 Follow-up mediante dinamica molecolare della configurazione MOL00583–EGFR

A seguito della selezione di MOL00583 come **TIER_1_PRIMARY_COMPUTATIONAL_LEAD** nel notebook 09g, la Pipeline 5 è stata estesa con il notebook **09h**, dedicato alla valutazione dinamica del complesso con EGFR. La simulazione è partita dalla posa raffinata localmente con Vina in 09f, utilizzando il recettore EGFR di 3NJP, catena B. È stato eseguito un test preliminare di 50 ps, seguito da una simulazione di produzione di 1 ns, entrambi in solvente esplicito e senza restrizioni di posizione durante la produzione. Entrambe le esecuzioni hanno superato tutti i controlli tecnici previsti. Dopo lo scarto del primo 20% della produzione, l'analisi ha incluso rispettivamente 20 e 400 frame. L'RMSD medio degli atomi pesanti del ligando, calcolato dopo allineamento del recettore rispetto al complesso iniziale preparato dalla posa 09f, è risultato pari a **1,90 Å nel test e 2,09 Å nel run da 1 ns**. Il criterio originariamente denominato “permanenza nel sito” è stato soddisfatto nel 100% dei frame analizzati in entrambe le esecuzioni rispetto alla regione locale definita attorno alla posa iniziale proveniente da 09f; i

residui EGFR con contatti persistenti in almeno il 50% dei frame sono stati rispettivamente 14 e 11. Tale regione non deve tuttavia essere identificata con la native EGF–EGFR interface, poiché la posa MOL00583 propagata da 09f risulta off-site rispetto a tale interfaccia. La traiettoria di produzione 09h è stata inoltre rianalizzata rispetto ai 43 residui della catena B che definiscono la native EGF–EGFR interface. Tutti i 43 residui sono stati mappati correttamente. Nei 400 frame analizzati dopo lo scarto iniziale non è stato osservato alcun contatto tra MOL00583 e l'interfaccia (0/400 frame; contact fraction = 0). La distanza minima osservata tra MOL00583 e l'interfaccia è pari a 9,167 Å; la distanza minima media è 11,382 Å e la mediana 11,386 Å. Nel run da 1 ns si osserva tuttavia una riorganizzazione delle interazioni: tra la prima e la seconda metà dell'intervallo analizzato, la frazione media dei contatti iniziali mantenuti scende da circa **85% a 74%**, mentre l'RMSD medio del ligando aumenta da **1,95 a 2,24 Å**. I tre candidati geometrici di legame a idrogeno rilevati nel run lungo presentano occupanze basse, comprese tra **0,25% e 2,5%**, e non costituiscono pertanto una rete persistente di legami H. Nel complesso, 09h documenta la persistenza e il riarrangiamento locale di MOL00583 nella regione occupata dalla posa storica proveniente da 09f. La verifica rispetto alla native EGF–EGFR interface mostra tuttavia che tale regione è off-site: nessuno dei 400 frame analizzati entra in contatto con i 43 residui dell'interfaccia. La traiettoria non supporta quindi la permanenza o il binding di MOL00583 nel sito EGF. MOL00583 conserva la provenienza NEAR_MISS_MANDATORY_ONLY / NEAR_MISS_RESCUE e la qualifica storica derivata dal ranking 09g, senza validazione sperimentale. Questo risultato non esclude che la molecola possa adottare altri binding mode in condizioni o preparazioni differenti.

15.8.1 Verifica site-specifica della traiettoria 09h

La traiettoria di produzione 09h già esistente è stata successivamente riesaminata rispetto ai 43 residui della native EGF–EGFR interface, senza rieseguire la dinamica molecolare. Dopo lo scarto iniziale del 20%, nessuno dei 400 frame analizzati mostra contatti con tali residui (contact fraction = 0,000000). La distanza minima osservata tra ligando e interfaccia è pari a 9,167 Å; la distanza minima media è 11,382 Å e la mediana 11,386 Å. La traiettoria 09h documenta pertanto la persistenza e la riorganizzazione della configurazione nella regione off-site ereditata da 09f, e non la ritenzione di MOL00583 nella native EGF–EGFR interface. Questo risultato delimita l'interpretazione della traiettoria effettivamente simulata e non esclude che MOL00583 possa adottare modalità di legame differenti in altre preparazioni strutturali.

A | EGFR e MOL00583

Complesso finale dopo 1 ns

**B | MOL00583: confronto delle pose**

Posa iniziale 09f e snapshot finale dopo 1 ns




Figura 15.10. Confronto strutturale di MOL00583 nel complesso con EGFR prima e dopo la simulazione di dinamica molecolare da 1 ns. (A) Vista generale del modello di EGFR derivato da PDB 3NJP, catena B, rappresentato in cartoon azzurro-grigio nello snapshot finale, con MOL00583 evidenziata nel sito occupato durante la simulazione. (B) Dettaglio della sovrapposizione tra la posa iniziale preparata a partire dal raffinamento Vina del notebook 09f (viola) e la configurazione finale a 1 ns (carboni arancio, azoti blu e ossigeni rossi). Le strutture sono state allineate sulle C α di EGFR, senza un allineamento indipendente del ligando, preservando quindi gli spostamenti di MOL00583 rispetto al recettore. In grigio sono mostrati i quattro residui geometricamente più vicini al ligando nello snapshot finale: Arg84, Asn86, Arg231 e Thr266 della catena B, secondo la numerazione del modello utilizzato. La loro visualizzazione non implica necessariamente contatti persistenti o legami a idrogeno. Acqua, ioni e idrogeni sono omessi per chiarezza; i due pannelli hanno ingrandimenti differenti. La figura illustra la riorganizzazione della posa tra due configurazioni e non rappresenta una struttura media dell'insieme simulato. La permanenza nel sito è valutata separatamente mediante l'analisi della traiettoria; questo confronto non dimostra convergenza, affinità o attività biologica. MOL00583 rimane un lead computazionale non validato sperimentalmente

15.9 Analisi energetica endpoint del complesso MOL00583–EGFR

A completamento della valutazione dinamica, il notebook **09i** ha eseguito un'analisi energetica **single-trajectory MM/GBSA-like**, utilizzando il modello di solvente implicito **GBn2** e il termine superficiale **ACE**, coerentemente con la famiglia metodologica adottata nella Pipeline 3. Dopo un test tecnico su tre snapshot, l'analisi completa ha considerato **50 configurazioni distribuite nell'intervallo 202–1.000 ps** della produzione MD di 09h, escludendone il primo 20% e conservando cariche e parametri del sistema simulato. Tutti i controlli tecnici sono stati superati. Il proxy energetico endpoint medio è risultato pari a **–20,10 kcal/mol**, con una **deviazione standard di 2,37 kcal/mol tra gli snapshot campionati**. I contributi medi elettrostatico diretto (**–14,29 kcal/mol**), van der Waals (**–33,96 kcal/mol**) e superficiale ACE (**–8,52 kcal/mol**) risultano favorevoli nel modello adottato, mentre la solvatazione polare GB introduce un contributo sfavorevole (**+36,67 kcal/mol**). L'analisi temporale evidenzia tuttavia un'attenuazione della favorevolezza energetica: la media passa da **–21,42 kcal/mol nella prima metà dell'intervallo analizzato** a **–18,79 kcal/mol nella seconda**. Questo andamento, insieme alla riorganizzazione dei contatti osservata in 09h, invita a non considerare dimostrata la convergenza. Nel complesso, il valore endpoint medio di circa $-20,10 \pm 2,37$ kcal/mol caratterizza, secondo il protocollo GBn2/ACE adottato, la configurazione off-site campionata nella traiettoria 09h. Questo risultato non deve essere interpretato come supporto energetico al binding di MOL00583 nella native EGF–EGFR interface. Non costituisce inoltre una misura rigorosa della ΔG di binding né può essere convertito direttamente in Kd o Ki: il calcolo non include entropia, rilassamento indipendente dei componenti o repliche della

simulazione. La deviazione standard descrive inoltre snapshot temporalmente correlati e non rappresenta l'incertezza della media. MOL00583 conserva pertanto la qualifica storica di lead computazionale selezionato dal ranking 09g come provenance del workflow; l'endpoint 09i riguarda la configurazione off-site propagata da 09h e non costituisce una validazione energetica del binding alla native EGF-EGFR interface.




Figura 15.11. Analisi energetica endpoint del complesso MOL00583-EGFR mediante il protocollo MM/GBSA-like GBn2/ACE. A sinistra, andamento del proxy energetico su 50 snapshot distribuiti nell'intervallo 202–1.000 ps della produzione MD, dopo esclusione del primo 20% della traiettoria. A destra, contributi medi elettrostatico diretto (Coulomb), van der Waals (vdW), solvatazione polare GB e superficiale ACE. Il valore complessivo medio è $-20,10$ kcal/mol, con deviazione standard di $2,37$ kcal/mol tra gli snapshot. Nella parte finale il proxy tende a diventare meno negativo; il risultato non dimostra pertanto convergenza raggiunta. I valori descrivono una stima endpoint senza contributo entropico e non equivalgono a un'energia libera rigorosa di binding o a un'affinità sperimentale. Gli snapshot provengono da una singola traiettoria, sono temporalmente correlati e non costituiscono repliche indipendenti.




Figura 15.12. Variazione temporale del proxy energetico endpoint di MOL00583-EGFR. I 50 snapshot analizzati nell'intervallo 202–1.000 ps sono suddivisi in cinque blocchi temporali consecutivi di 10 snapshot ciascuno. Le energie medie risultano rispettivamente pari a $-21,21$, $-21,74$, $-20,36$, $-18,67$ e $-18,53$ kcal/mol. Il passaggio a valori meno negativi nei blocchi finali evidenzia una variazione temporale del supporto energetico e suggerisce cautela nell'assumere convergenza. Le linee collegano le medie per facilitarne la lettura; i blocchi appartengono alla stessa traiettoria e non rappresentano repliche indipendenti. Il grafico non dimostra dissociazione né misura un'affinità sperimentale.

L'analisi 09i costituisce un primo approfondimento energetico successivo alla dinamica molecolare, nella direzione discussa durante l'incontro dell'11 settembre. Il protocollo single-trajectory MM/GBSA-like non comprende tuttavia simulazioni indipendenti della molecola libera in acqua né una valutazione di stati alternativi di protonazione. Questi aspetti, insieme all'eventuale impiego di un metodo di energia libera più rigoroso, rimangono sviluppi successivi.

15.9.1 Interpretazione dell'endpoint energetico 09i

Il valore medio di circa $-20,10 \pm 2,37$ kcal/mol rimane il risultato del protocollo GBn2/ACE applicato ai 50 snapshot della traiettoria 09h. Alla luce della successiva verifica site-specifica, tale valore deve tuttavia essere riferito alla configurazione off-site EGFR–MOL00583 effettivamente simulata. Non rappresenta una ΔG rigorosa, non può essere convertito in K_d o K_i e non costituisce evidenza energetica di legame alla native EGF–EGFR interface.

15.10 Dinamica di MOL00583 libera in acqua e confronto conformazionale

Dopo l'analisi endpoint 09i, il notebook 09j estende lo studio a MOL00583 libera in acqua. Questo passaggio affronta la componente relativa al ligando non legato discussa nell'incontro dell'11 settembre, attraverso un confronto conformazionale con lo stato nel complesso. Non costituisce un calcolo di energia libera di legame. Sono state eseguite su GPU tre repliche da 10 ns ciascuna, per 30 ns complessivi, con semi differenti e la stessa posa iniziale. Il protocollo mantiene il microstato neutro e i parametri del ligando di 09h (OpenFF e cariche AM1-BCC), in acqua TIP3P con NaCl 0,15 M, a 300 K e 1 bar, con timestep di 2 fs. Ogni replica comprende minimizzazione, 100 ps NVT e 200 ps NPT prima della produzione. Il test preliminare da 50 ps verifica l'esecuzione ed è escluso dai risultati scientifici qui riportati. La produzione è campionata ogni 10 ps; lo scarto iniziale del 20% lascia 800 frame per replica, da 2,01 a 10 ns. L'RMSD conformazionale è calcolato sugli atomi pesanti mediante fit del solo ligando alla posa di riferimento 09f. Il raggio geometrico misura l'estensione degli atomi pesanti rispetto al loro centro geometrico, senza pesatura per massa. Entrambe le misure sono distinte dall'RMSD del ligando dopo allineamento di EGFR.

09j	RMSD conformazionale (Å)	Raggio geometrico (Å)
Replica 1	$1,95 \pm 0,44$	$5,47 \pm 0,11$
Replica 2	$1,96 \pm 0,47$	$5,37 \pm 0,12$
Replica 3	$2,00 \pm 0,42$	$5,48 \pm 0,13$

I valori sono media $\pm$ deviazione standard dei frame; le deviazioni standard non rappresentano l'incertezza delle medie. Tutte le repliche superano i controlli tecnici: temperature medie fra 299,85 e 300,41 K e densità fra 0,99575 e 0,99651 g/mL.

Rispetto alla traiettoria iniziale di 09h da 1 ns, il ligando libero presenta distribuzioni più ampie dell'RMSD e un'estensione media maggiore (Figura 5.10A). Questo primo confronto è limitato dalle diverse durate e viene approfondito con le repliche del complesso descritte nel paragrafo 5.11. La somiglianza degli RMSD medi delle tre repliche libere non dimostra, da sola, convergenza; la seconda replica mostra un raggio geometrico medio inferiore alle altre due.

09j mantiene un solo microstato neutro: non determina pK_a o popolazioni di protonazione e tautomeria. La simulazione del ligando libero realizza quindi una parte dell'approfondimento proposto, mentre la valutazione termodinamica rigorosa rimane distinta. Non si sottraggono le energie totali dei diversi sistemi solvatati.

La simulazione free-water mantiene pieno valore come caratterizzazione conformazionale e di idratazione di MOL00583, indipendentemente dalla successiva reinterpretazione della configurazione associata a EGFR. Il confronto tra MOL00583 libero e la configurazione associata a EGFR è pertanto descrittivo e conformazionale. Non costituisce un ciclo termodinamico, non fornisce una stima convergente dell'energia libera di binding e non dimostra un vantaggio di affinità della configurazione associata a EGFR rispetto al ligando libero




Figura 15.13A. Confronto preliminare tra MOL00583 libera in acqua (tre repliche 09j da 10 ns) e nel complesso della simulazione 09h da 1 ns. A sinistra, distribuzione dell'RMSD con fit del ligando rispetto a 09f; a destra, raggio geometrico degli atomi pesanti. È escluso il primo 20% di ciascuna produzione. Le finestre di campionamento differiscono: gli istogrammi descrivono le traiettorie disponibili e non costituiscono un test di significatività o di convergenza.




Figura 15.13B. Idratazione geometrica di MOL00583 libera in acqua nelle tre repliche 09j. È riportato, dopo lo scarto iniziale, il numero di molecole d'acqua il cui ossigeno si trova entro 3,5 Å da almeno un atomo pesante del ligando. Le tracce mostrano fluttuazioni ampiamente sovrapposte senza una deriva evidente a vista. La misura non identifica legami a idrogeno e non quantifica energia di solvatazione o tempi di residenza delle acque.

15.10.1 Interpretazione del confronto libero/associato

Le repliche 09j rimangono valide come caratterizzazione conformazionale e di idratazione di MOL00583 libero. Alla luce della successiva verifica site-specifica, il termine *bound* utilizzato nel confronto originario deve tuttavia essere inteso come riferimento alla configurazione EGFR–MOL00583 simulata in 09h, successivamente riconosciuta come off-site rispetto alla native EGF–EGFR interface, e non come indicazione di uno stato legato alla vera interfaccia EGF. Il confronto 09j/09h–09k deve pertanto essere interpretato come **confronto descrittivo tra il ligando libero e la configurazione associata a EGFR effettivamente simulata**, e non come confronto termodinamico tra stati *free* e *bound* al sito EGF

15.11 Repliche del complesso e confronto con il ligando libero

Il notebook 09k estende la dinamica del complesso EGFR–MOL00583 a tre repliche da 10 ns ciascuna su CUDA. Tutte partono dallo stesso snapshot finale di 09h, dopo 1 ns, con nuovi semi, nuove velocità e 100 ps di riequilibrio NPT senza restrizioni posizionali. Si tratta di rami stocastici da una struttura condivisa, non di tre preparazioni strutturali indipendenti. Sistema, microstato e parametri restano quelli di 09h.

Nel seguito, le espressioni “complesso”, “configurazione associata a EGFR” ed eventuali riferimenti alla condizione “legata” sono mantenuti come denominazioni operative del sistema EGFR–MOL00583 simulato in 09h/09k. Non devono essere interpretati come indicazione di binding alla native EGF–EGFR interface, poiché la configurazione associata a EGFR deriva dalla posa off-site propagata da 09h.

Il confronto comprende pertanto 30 ns della configurazione EGFR–MOL00583 ereditata da 09h e 30 ns del ligando libero, oltre al precedente run 09h. I 30 ns associati a EGFR rappresentano quindi l'evoluzione di tre rami stocastici della configurazione off-site iniziale e non una simulazione del ligando nella native EGF–EGFR interface. Anche per 09k si analizzano 800 frame per replica dopo lo scarto del primo 20%. Tutte le repliche superano i controlli tecnici, con temperature medie di circa 300,3 K e densità di circa 1,002 g/mL. Il superamento dei controlli non equivale a convergenza del campionamento.

09k	RMSD conformazionale (Å)	Raggio geometrico (Å)
Replica 1	1,95 ± 0,29	5,27 ± 0,06
Replica 2	1,21 ± 0,21	5,31 ± 0,09
Replica 3	1,41 ± 0,54	5,28 ± 0,11

Nel complesso, i raggi geometrici medi delle tre repliche sono tutti inferiori a quelli delle tre repliche libere, pur con sovrapposizione delle distribuzioni. L'RMSD conformazionale mostra invece eterogeneità: la prima replica legata ha una media simile alle repliche libere, mentre le altre due risultano più vicine al riferimento. La minore deviazione dalla posa di riferimento non è dunque uniforme tra le repliche.




Figura 15.14A. Distribuzioni conformazionali nelle tre repliche del complesso 09k (linee continue) e nelle tre repliche del ligando libero 09j (linee tratteggiate), tutte da 10 ns. I colori identificano il numero della replica, senza implicare un accoppiamento statistico tra condizioni. RMSD con fit del ligando e raggio geometrico sono calcolati sui pesanti dopo lo scarto del primo 20%. Sono usati intervalli comuni per ciascun istogramma. Le deviazioni tra repliche richiedono una lettura separata e non dimostrano differenze di affinità

Queste differenze di RMSD conformazionale e raggio geometrico descrivono il comportamento conformazionale di MOL00583 nelle traiettorie considerate, ma non forniscono informazioni sulla pertinenza della configurazione rispetto alla native EGF–EGFR interface. In particolare, una minore deviazione dalla posa di riferimento indica soltanto una maggiore somiglianza conformazionale con la configurazione di partenza e non dimostra né la permanenza nel sito EGF né un binding più stabile a tale interfaccia. Le tre traiettorie di produzione 09k sono state inoltre rianalizzate rispetto ai 43 residui della catena B che definiscono la native EGF–EGFR interface. Dopo lo scarto del primo 20% di ciascuna traiettoria sono stati analizzati complessivamente 2.400 frame, 800 per replica. Non è stato osservato alcun contatto tra MOL00583 e l'interfaccia EGF in nessuna delle tre repliche (0/2.400 frame; contact fraction = 0). Le distanze minime osservate tra MOL00583 e l'interfaccia sono pari rispettivamente a 9,04 Å nella replica 1, 7,73 Å nella replica 2 e 9,80 Å nella replica 3.

15.11.1 Permanenza nel sito e andamento temporale

Il centro geometrico del ligando rimane entro 8 Å dal centro degli atomi pesanti di EGFR inizialmente entro 5 Å dal ligando in tutti i frame analizzati. Le distanze medie sono 1,02, 3,63 e 2,43 Å; i massimi sono 4,73, 4,98 e 4,30 Å. Questa soglia è una diagnostica geometrica e va letta insieme alla persistenza dei contatti. L'RMSD medio del ligando dopo fit globale sui Ca di EGFR è 4,34, 3,03 e 3,54 Å. Questi valori indicano che la permanenza locale non comporta conservazione esatta della posa iniziale. L'RMSD medio dei Ca del recettore è rispettivamente 4,48, 4,93 e 3,80 Å: il fit globale può includere movimenti relativi

di regioni del recettore e non isola automaticamente la deformazione locale del sito.




Figura 15.14B. Andamento dell’RMSD del ligando dopo fit globale di EGFR (sopra) e della distanza tra il centro del ligando e il centro del sito definito dalla geometria iniziale (sotto). Sono mostrati i frame analizzati fra 2,01 e 10 ns. Le linee sottili riportano i valori per frame; le linee marcate sono medie mobili centrate su 20 frame, pari a circa 0,2 ns, con finestre ridotte ai margini. Lo smoothing facilita la lettura e non entra nel calcolo delle statistiche.

Nella terza replica l’RMSD conformazionale con fit del ligando aumenta da 1,12 Å nella prima metà analizzata (2,01–6 ns) a 1,71 Å nella seconda (6,01–10 ns). Le rispettive medie sono 2,05 e 1,85 Å nella prima replica, 1,16 e 1,26 Å nella seconda. La variazione temporale, insieme all’origine strutturale condivisa, impedisce di considerare il sistema dimostrato convergente.

15.11.2 Contatti persistenti e significato complessivo

ARG84, ARG231, ALA265 e THR266 mantengono contatti con occupazione superiore all’82% in ciascuna replica. Anche GLU3 e GLU233 superano il 50% in tutte e tre. Il criterio è geometrico: almeno una coppia di atomi pesanti ligando–residuo entro 4 Å. Le etichette riportano la numerazione resSeq dei file simulati e non costituiscono una mappatura automatica alla numerazione canonica di EGFR.




Figura 15.14C. Occupazione percentuale dei contatti ligando–EGFR nelle tre repliche 09k, dopo lo scarto iniziale. Sono inclusi i residui che raggiungono almeno il 50% in una replica; sono riportati anche i valori inferiori alla soglia nelle altre repliche. I contatti sono definiti dalla distanza minima tra atomi pesanti inferiore a 4 Å. Non equivalgono necessariamente a legami a idrogeno né a contributi energetici favorevoli.

La RMSF media dei 17 Cα del sito iniziale è 1,62, 1,80 e 1,75 Å, con massimi di 2,09, 2,25 e 2,38 Å. Queste fluttuazioni sono misurate dopo fit globale del recettore e possono comprendere movimenti relativi delle sue regioni. La successiva verifica site-specifica è stata condotta esclusivamente sulle tre traiettorie di produzione 09k già esistenti, senza rieseguire MD, docking o Vina. Dopo lo scarto del primo 20% di ciascuna traiettoria, sono stati analizzati 800 frame per replica, per un totale di 2.400 frame. In tutte e tre le repliche, la frazione di frame con almeno un contatto verso i 43 residui della native EGF–EGFR interface è pari a 0,000000 e nessun residuo dell'interfaccia viene contattato. Le distanze minime osservate tra ligando e interfaccia sono rispettivamente 9,04 Å, 7,73 Å e 9,80 Å nelle repliche 1, 2 e 3. Nel loro insieme, 09j e 09k documentano quindi il comportamento conformazionale di MOL00583 libero e l'evoluzione di tre rami stocastici della configurazione associata a EGFR ereditata da 09h. I risultati mostrano che le repliche 09k supportano la persistenza e l'evoluzione della configurazione off-site ereditata da 09e/09f/09h, ma non la ritenzione o la migrazione spontanea di MOL00583 verso il sito EGF. Questo risultato delimita ciò che le traiettorie effettivamente simulate possono sostenere e non dimostra che MOL00583 non possa adottare modalità di legame differenti in altre preparazioni strutturali. La provenienza NEAR_MISS_RESCUE e l'etichetta storica TIER_1_PRIMARY_COMPUTATIONAL_LEAD vengono pertanto conservate esclusivamente come provenance del workflow originario.

Provenienza delle produzioni: 09j, run 20260914T085625_154393Z; 09k, run 20260914T100036_153833Z. Il test da 50 ps di 09j è escluso dal confronto. Le statistiche 09k e il confronto 09j/09k derivano dai CSV esportati; non rappresentano un ricalcolo delle traiettorie.

Nel complesso, il workflow documenta perché MOL00583 fu selezionato storicamente da 09g e successivamente propagato nelle analisi 09h–09k. Le successive verifiche site-specifiche modificano tuttavia in modo sostanziale l'interpretazione di tale percorso: la configurazione di MOL00583 utilizzata nel follow-up è off-site rispetto alla native EGF–EGFR interface. Il razionale per eventuali verifiche successive deve quindi distinguere la provenance del ranking storico dalla validazione site-specifica, che per MOL00583 non è stata ottenuta. Tra i quattro finalisti raffinati in 09f, MOL00484 conserva invece una catena di supporto strutturale site-relevant. Tale osservazione ne giustifica l'interesse per un eventuale follow-up focalizzato sulla native EGF–EGFR interface, ma non equivale a una promozione automatica a nuovo lead né sostituisce una nuova valutazione strutturale comparativa.

Più in generale, i risultati evidenziano la necessità di distinguere tra favorevolezza di una posa ottenuta mediante docking globale sull'intera superficie del recettore e pertinenza della stessa posa rispetto al sito biologico di interesse. Una posa favorevole nel ranking whole-receptor non implica necessariamente localizzazione nella native EGF–EGFR interface. Nel presente workflow questa distinzione è essenziale per interpretare correttamente la transizione da 09e alle successive fasi di affinamento, dinamica molecolare e analisi energetica.

16 Lettura integrata del workflow PEARL

Le Pipeline 4 e 5 non producono un unico punteggio conclusivo, ma organizzano evidenze provenienti da metodi differenti. Ogni metodo risponde a una domanda specifica: la plausibilità della sequenza, la compatibilità con la struttura di EGFR, il comportamento dinamico, il supporto energetico, le proprietà chimiche o la plausibilità delle pose di docking. L'integrazione conserva anche i disaccordi tra i metodi. Un candidato può essere favorito perché mostra un comportamento complessivamente equilibrato, perché eccelle in un singolo dominio oppure perché rappresenta un'alternativa complementare rispetto al candidato principale.

Livello del workflow	Evidenze considerate	Risultato della selezione
Peptidi di riferimento	F0010 come riferimento naturale miniaturizzato; CF02 come riferimento di stabilità dinamica; CF06 come riferimento strutturale ed energetico della Pipeline 3	Nessun peptide di riferimento prevale in tutte le metriche
Progettazione peptidica assistita dall'IA	Plausibilità ESM-2, generazione ProteinMPNN, validazione strutturale, dinamica molecolare, confronto energetico endpoint e sviluppabilità preliminare	MPNN_NEW_01 mostra il miglior equilibrio complessivo; MPNN_NEW_05 mantiene il supporto energetico più favorevole tra i nuovi peptidi
Trasferimento farmacoforico	Persistenza e distribuzione spaziale delle interazioni negli ensemble MD di CF02, CF06 e MPNN_NEW_05	Le 17 feature core vengono consolidate in 10 gruppi: 5 obbligatori, 4 opzionali e 1 contestuale non vincolante
Screening dei piccoli ligandi	Adattamento farmacoforico, proprietà chimiche, DiffDock, contatti con EGFR, rescoring Vina e stabilità geometrica locale	MOL00583 è il lead computazionale primario; MOL00484, MOL00600 e MOL00273 restano alternative ortogonali

Nella Pipeline 4, MPNN_NEW_01 e MPNN_NEW_05 emergono per ragioni differenti. MPNN_NEW_01 presenta il miglior equilibrio tra struttura e sviluppabilità preliminare e mostra un comportamento dinamico più favorevole nel confronto tra i nuovi peptidi. MPNN_NEW_05 ottiene invece il supporto energetico endpoint più favorevole tra le nuove sequenze. Nessuno dei due domina l'altro in tutti i domini: la loro conservazione riflette quindi una reale complementarità delle evidenze.

La Pipeline 5 trasferisce l'informazione dai peptidi alle piccole molecole senza tentare di trasformare direttamente una sequenza peptidica in un composto chimico. Le interazioni persistenti osservate nelle traiettorie MD vengono tradotte in un modello farmacoforico, cioè in una disposizione tridimensionale di proprietà chimiche che molecole strutturalmente diverse possono cercare di riprodurre.

Questo trasferimento mette però in evidenza un limite importante. Le due molecole che soddisfano integralmente la regola farmacoforica stretta, MOL00570 e MOL00336, non superano i filtri chimici adottati. Di conseguenza, nessun hit farmacoforico stretto e chimicamente idoneo raggiunge il docking.

Per proseguire l'esplorazione, il workflow introduce una rescue track composta da molecole che soddisfano i cinque gruppi farmacoforici obbligatori, ma non il requisito relativo ai gruppi opzionali. Gli otto candidati ammessi a DiffDock e i quattro finalisti analizzati con Vina provengono tutti da questa categoria. La loro origine viene mantenuta esplicitamente fino alla selezione finale.

Nel **ranking storico 09g**, MOL00583 riceve il supporto più distribuito tra i sei assi ed è quindi designato come lead computazionale primario **del workflow originario**. Le successive verifiche site-specifiche mostrano tuttavia che la posa propagata nelle analisi successive è off-site rispetto alla native EGF-EGFR interface. MOL00484, MOL00600 e MOL00273 vengono conservati come alternative ortogonali perché presentano vantaggi specifici e sono tutti Pareto non dominati. Questa classificazione stabilisce una priorità per le verifiche successive, ma non dimostra il legame con EGFR né l'attività biologica.

Il principale risultato del workflow è quindi duplice. Da un lato, PEARL dimostra la fattibilità tecnica di un percorso che collega progettazione peptidica, dinamica molecolare, farmacoforo e selezione di piccoli ligandi. Dall'altro, mostra che il trasferimento non ha ancora prodotto una molecola capace di soddisfare simultaneamente la regola farmacoforica stretta e i criteri chimici adottati.

La selezione finale deve pertanto essere interpretata come una graduatoria computazionale per il follow-up. Il valore metodologico del workflow risiede nella tracciabilità: per ogni candidato rimangono visibili l'origine, i criteri superati, le evidenze favorevoli e i limiti che ne accompagnano l'avanzamento.

17 Limiti e verifiche successive

I risultati delle Pipeline 4 e 5 costituiscono priorità computazionali e devono essere interpretati alla luce dei limiti dei dati e dei metodi impiegati. Le verifiche successive dovrebbero sia aumentare la robustezza del confronto computazionale sia stabilire se i candidati selezionati possiedano effettivamente capacità di legame e attività biologica.

17.1 Limiti della Pipeline 4

- Le simulazioni di dinamica molecolare dei nuovi peptidi hanno una durata di 1 ns. Sono adeguate per confrontare la stabilità locale nel protocollo adottato, ma potrebbero non campionare riarrangiamenti lenti, dissociazioni parziali o transizioni conformazionali che si manifestano su scale temporali maggiori.

- Per ogni candidato è stata analizzata una singola traiettoria breve. L'assenza di repliche indipendenti limita la possibilità di distinguere un comportamento riproducibile da una fluttuazione legata alle condizioni iniziali della simulazione.
- Il confronto energetico endpoint utilizza un approccio single-trajectory e trascura contributi rilevanti, in particolare l'entropia e una descrizione rigorosa degli effetti di solvatazione. I valori ottenuti sono indicatori proxy comparativi e non equivalgono a una stima MM/GBSA, MM/PBSA o dell'energia libera di legame.
- Le strutture ESMFold sono predette per peptidi isolati di soli 11 residui. Il pLDDT e l'RMSD rispetto al peptide legato dipendono fortemente dall'assenza del recettore e non dimostrano che la stessa conformazione venga assunta nel complesso con EGFR.
- CamSol è stato eseguito nella versione più recente sull'intera coorte di sequenze e i risultati sono stati importati con verifica della corrispondenza tra candidato, sequenza e output. Rimane tuttavia una previsione computazionale di solubilità e non sostituisce misure sperimentali di solubilità, aggregazione, stabilità o comportamento in soluzione.
- L'ottimizzazione bayesiana con BoTorch è stata effettivamente eseguita sulla coorte completa di 24 sequenze ProteinMPNN. Il modello è stato addestrato utilizzando soltanto cinque candidati dotati di valutazione strutturale FoldX/Rosetta e ha ordinato le 19 sequenze non ancora valutate.
- A causa del numero ridotto di osservazioni strutturali, il modello BoTorch deve essere considerato un esperimento pilota di selezione sequenziale. La proposta MPNN_POOL_023, con sequenza VGARNQYRDLN, indica quale candidato sarebbe informativo valutare successivamente; non rappresenta una previsione di affinità, una nuova sequenza generata dal modello o un lead già validato.

17.2 Limiti della Pipeline 5

- Il farmacoforo deriva dalle traiettorie MD di tre peptidi, CFo2, CFo6 e MPNN_NEW_05. La sua composizione dipende dalla durata delle simulazioni e dalle soglie adottate per persistenza temporale, clustering spaziale e consolidamento delle feature.
- Le traiettorie brevi potrebbero non rappresentare l'intera variabilità dell'interfaccia peptide-EGFR. Di conseguenza, alcune feature farmacoforiche potrebbero essere sovrarappresentate o non osservate a causa del campionamento temporale limitato.
- REINVENT4 è stato utilizzato per generare una libreria molecolare non condizionata direttamente dal farmacoforo. Il modello farmacoforico è stato applicato soltanto successivamente come filtro tridimensionale; il workflow non costituisce quindi un processo di reinforcement learning guidato dal farmacoforo.
- Soltanto 1.000 delle 5.000 molecole uniche richieste al generatore sono state analizzate nel ciclo di produzione considerato. L'esplorazione dello spazio chimico rimane pertanto parziale.
- I due hit che soddisfano la regola farmacoforica stretta, MOL00336 e MOL00570, non superano i criteri chimici adottati. Tutte le molecole sottoposte a DiffDock e Vina provengono invece dalla rescue track e soddisfano soltanto i gruppi farmacoforici obbligatori.
- La confidence DiffDock e il pose-support score valutano la plausibilità relativa delle pose, ma non misurano direttamente l'affinità di legame. Anche lo score Vina è una funzione empirica adatta al confronto interno tra molecole analizzate con lo stesso protocollo e non rappresenta una misura rigorosa della ΔG di legame.

- Il raffinamento Vina è locale: parte dalla posa selezionata da DiffDock e ne consente soltanto un aggiustamento nelle vicinanze. Non verifica se esistano pose globalmente differenti e più favorevoli in altre regioni del recettore o della stessa interfaccia.
- Le valutazioni di docking dipendono dalla preparazione del recettore e dei ligandi, dagli stati di protonazione e tautomeria e dalla conformazione recettoriale utilizzata. Queste variabili non sono esplorate sistematicamente nel protocollo corrente.
- Il fatto che tutti e quattro i finalisti siano Pareto non dominati dipende dai sei assi e dalle regole di ranking adottate. Non implica che possiedano efficacia equivalente né che tutti mostrino legame sperimentale con EGFR.

Una limitazione specifica della Pipeline 5 deriva dall'impiego, in 09e, di un docking globale sull'intera catena B di EGFR senza un vincolo esplicito alla native EGF-EGFR interface. La selezione originaria delle pose è stata quindi guidata dalla favorevolezza whole-receptor e non dalla pertinenza al sito biologico di interesse. Nel caso di MOL00583, la posa off-site selezionata in 09e è stata successivamente propagata nel raffinamento 09f e nelle analisi 09h-09k. Di conseguenza, la coerenza dei risultati ottenuti lungo queste fasi non deve essere interpretata come validazione indipendente del binding alla native EGF-EGFR interface.

Più in generale, la convergenza di più criteri computazionali all'interno del workflow non equivale alla disponibilità di evidenze indipendenti. Diversi criteri condividono infatti gli stessi input strutturali o derivano sequenzialmente dagli stessi risultati: le pose selezionate da 09e alimentano il raffinamento 09f e, nel caso di MOL00583, le successive analisi dinamiche ed energetiche. La concordanza tra questi livelli aumenta la coerenza interna del percorso computazionale, ma non moltiplica automaticamente il numero di conferme indipendenti di un medesimo evento di binding.

17.3 Priorità sperimentali e computazionali

Priorità	Azione proposta	Obiettivo
Alta	Eseguire repliche MD indipendenti e più lunghe per MPNN_NEW_01 e MPNN_NEW_05	Verificare la riproducibilità della stabilità, dei contatti e delle differenze osservate nelle traiettorie di 1 ns
Alta	Sottoporre MPNN_POOL_023 a FoldX e Rosetta, secondo lo stesso protocollo usato per i cinque candidati osservati	Valutare computazionalmente la proposta BoTorch e aggiungere una nuova osservazione strutturale al modello
Alta	Misurare sperimentalmente legame e attività dei peptidi prioritari	Stabilire se la plausibilità computazionale corrisponda a interazione con EGFR e a un effetto funzionale
Alta	Verificare identità, disponibilità o sintetizzabilità dei quattro piccoli ligandi finalisti	Confermare che le strutture selezionate possano essere ottenute e analizzate sperimentalmente
Alta	Valutare solubilità, stabilità, aggregazione e comportamento colloidale dei finalisti	Escludere artefatti e verificare proprietà non dimostrate dai descrittori computazionali
Media	Ripetere il docking con protocolli ortogonali e più conformazioni del recettore	Valutare la robustezza delle pose e del ranking rispetto al metodo e alla conformazione di EGFR
Media	Estendere le simulazioni utilizzate per costruire il farmacoforo	Verificare la stabilità delle feature core e ridurre la dipendenza dalle traiettorie brevi
Media	Applicare una generazione molecolare condizionata direttamente dal farmacoforo	Aumentare la probabilità di ottenere hit stretti che superino anche i filtri chimici
Media	Analizzare una quota maggiore delle 5.000 molecole generate	Ampliare la copertura dello spazio chimico e verificare se esistano ulteriori hit farmacoforici
Media	Aggiornare iterativamente il modello BoTorch dopo ogni nuova valutazione strutturale	Aumentare progressivamente l'affidabilità della selezione bayesiana e verificare la stabilità delle proposte

La priorità immediata della Pipeline 4 è verificare MPNN_POOL_023, perché rappresenta la proposta concreta prodotta dal modello BoTorch. Il risultato della sua valutazione strutturale dovrebbe essere aggiunto al set di addestramento prima di avviare un nuovo ciclo di selezione. Per la Pipeline 5, la priorità è confermare la trattabilità chimica dei quattro finalisti storici e riesaminarne la plausibilità strutturale mediante pose esplicitamente site-focused sulla native EGF-EGFR interface, mantenendo MOL00484 come candidato già dotato di supporto site-relevant nella posa selezionata. Parallelamente, una nuova generazione condizionata direttamente dal farmacoforo potrebbe cercare di superare il principale limite attuale: l'assenza di molecole che soddisfino contemporaneamente la regola farmacoforica stretta e i criteri chimici.

18 Conclusioni

Le Pipeline 1–5 costruiscono complessivamente un razionale continuo che parte dalla caratterizzazione strutturale dell'interfaccia EGF-EGFR e procede, attraverso livelli successivi di selezione e validazione computazionale, verso la progettazione di nuovi peptidi e la generazione di ipotesi small-molecule.

Le Pipeline 1–3 costituiscono la base strutturale e dinamica dell'intero workflow. La Pipeline 1 riduce una struttura complessa a una regione peptidica motivata dall'interfaccia: D22–51 viene definito come seed

ufficiale dopo AnalyseComplex. La Pipeline 2 comprime ulteriormente questa regione e combina apprendimento locale, generazione controfattuale e refinement strutturale per ottenere lead peptidici interpretabili; in questo contesto, F0010 rappresenta il peptide di riferimento di 11 aa estratto da EGF. La Pipeline 3 verifica quali priorità mantengano supporto quando l'interfaccia viene osservata come sistema dinamico e quando le configurazioni campionate vengono confrontate anche mediante un proxy energetico.

All'interno di questa prima fase, CF02 presenta il profilo dinamico più stabile, mentre CF06 mostra la rete di interazioni persistenti più numerosa e il proxy energetico endpoint medio più favorevole. La priorità congiunta CF02 + CF06 adottata nel protocollo 07a-07e riflette quindi proprietà complementari e non l'identificazione di un singolo candidato definitivamente superiore. Questi risultati costituiscono inoltre una parte dell'informazione strutturale e dinamica trasferita alle fasi successive del progetto.

Le Pipeline 4 e 5 estendono PEARL dalla caratterizzazione dell'interfaccia peptide-EGFR alla generazione e alla selezione di nuove ipotesi peptidiche e molecolari. Il workflow integra metodi differenti senza trasformare i loro risultati in una misura unica di affinità: ogni candidato viene valutato conservando la provenienza, il livello di evidenza raggiunto e le principali incertezze.

La Pipeline 4 introduce una strategia di progettazione peptidica assistita da modelli. I 100 campioni prodotti da ProteinMPNN corrispondono a 24 sequenze uniche. Cinque candidati vengono sottoposti alla validazione strutturale con FoldX e Rosetta, mentre MPNN_NEW_01 e MPNN_NEW_05 avanzano alle analisi dinamiche ed energetiche più approfondite.

Tra i due peptidi completamente valutati, MPNN_NEW_01 presenta il miglior equilibrio complessivo tra validazione strutturale, comportamento dinamico, struttura prevista e proprietà di sviluppabilità. MPNN_NEW_05 conserva invece il supporto energetico endpoint più favorevole tra i nuovi candidati. La differenza tra i risultati non viene interpretata come una contraddizione, ma come l'indicazione che i due peptidi possiedono profili complementari.

La versione aggiornata del workflow estende inoltre la valutazione di sviluppabilità all'intera coorte mediante risultati CamSol autenticati e associati alle rispettive sequenze. Su questa base, il ranking finale di Pipeline 4 è organizzato in livelli separati, in modo da confrontare soltanto candidati dotati di copertura informativa equivalente: 24 sequenze con evidenze ProteinMPNN, ESM-2 e CamSol; cinque candidati con validazione strutturale; due nuovi peptidi con valutazione completa.

BoTorch è stato applicato come esperimento pilota di selezione sequenziale. Il modello, addestrato sulle cinque sequenze dotate di osservazioni strutturali, ha analizzato le 19 sequenze non ancora valutate e ha indicato MPNN_POOL_023, con sequenza VGARNQYRDLN, come prossimo candidato da sottoporre a FoldX e Rosetta. Questa proposta non rappresenta un nuovo lead o una previsione di affinità, ma il punto di partenza per un eventuale ciclo iterativo di acquisizione di nuove evidenze.

La Pipeline 5 trasferisce le interazioni persistenti osservate negli ensemble MD di CF02, CF06 e MPNN_NEW_05 in un modello farmacoforico. Le 17 feature core di consenso vengono consolidate in 10 gruppi complessivi: cinque obbligatori, quattro opzionali e uno contestuale non vincolante. Nella regola di screening partecipano quindi direttamente nove gruppi.

Delle 1.000 molecole analizzate, 996 vengono incorporate correttamente in tre dimensioni. MOL00570 e MOL00336 soddisfano la regola farmacoforica stretta, ma non superano i filtri chimici. Il workflow non produce pertanto un candidato che combini contemporaneamente piena corrispondenza al farmacoforo e idoneità chimica secondo i criteri adottati.

Una rescue track permette di approfondire otto near-miss chimicamente accettabili che soddisfano i gruppi farmacoforici obbligatori, ma non il requisito opzionale. Dopo DiffDock e il rescoring locale con Vina, quattro molecole raggiungono la selezione integrata finale.

MOL00583 mostra la convergenza più ampia, collocandosi tra i primi due candidati in quattro dei sei assi di valutazione, ed è stato designato da 09g come lead computazionale primario storico; le successive verifiche site-specifiche mostrano tuttavia che la posa propagata nel follow-up è off-site rispetto alla native EGF-EGFR interface. MOL00484, MOL00600 e MOL00273 vengono conservati come alternative ortogonali perché ricevono supporto da combinazioni differenti di evidenze. Tutti e quattro risultano

Pareto non dominati nello spazio decisionale adottato, ma mantengono la classificazione di candidati della rescue track e non devono essere presentati come hit farmacoforici stretti.

Nel complesso, le Pipeline 1–5 definiscono un percorso coerente e tracciabile che parte dalla struttura dell'interfaccia EGFR, genera nuove sequenze peptidiche, identifica interazioni persistenti e le trasferisce alla selezione di piccoli ligandi. Il risultato è una serie di priorità computazionali motivate, accompagnate da controlli espliciti e da una chiara documentazione dei limiti.

Il workflow non dimostra tuttavia che i peptidi o i piccoli ligandi selezionati si leghino a EGFR, ne inibiscano la funzione o possiedano proprietà sperimentali adeguate. Simulazioni più lunghe e replicate, nuovi cicli di validazione strutturale e misure sperimentali di legame, attività, solubilità, stabilità e aggregazione restano necessarie prima di attribuire ai candidati un'effettiva rilevanza biologica o terapeutica.

Alla luce delle verifiche site-specifiche effettuate, un eventuale follow-up della Pipeline 5 dovrebbe partire da una preparazione strutturale esplicitamente focalizzata sulla native EGF–EGFR interface. Ciò richiederebbe una nuova selezione o generazione delle pose con un criterio site-focused, seguita da raffinamento locale e, solo successivamente, da dinamica molecolare e analisi energetica delle configurazioni pertinenti all'interfaccia. In questo contesto, MOL00484 può essere mantenuto tra i candidati di interesse perché la posa selezionata conserva supporto strutturale site-relevant, senza che ciò comporti la sua promozione automatica a nuovo lead. Analogamente, eventuali pose alternative site-relevant degli altri candidati dovrebbero essere considerate mediante una nuova valutazione comparativa, anziché sostituite retrospettivamente alle pose utilizzate nel workflow storico.

Termine	Definizione
ARO	Feature farmacoforica che rappresenta una regione capace di stabilire interazioni aromatiche.
Backbone	Struttura portante della catena peptidica, formata dalla successione degli atomi principali dello scheletro. In ProteinMPNN ne viene mantenuta la geometria mentre viene progettata la sequenza.
BoTorch	Libreria per l'ottimizzazione bayesiana. In 08i è stata utilizzata in un esperimento pilota per ordinare 19 sequenze non ancora valutate a partire da cinque osservazioni strutturali.
CamSol	Metodo computazionale per la previsione della propensione alla solubilità di proteine e peptidi. I suoi risultati non equivalgono a misure sperimentali di solubilità.
Confidence DiffDock	Indice interno che esprime la confidenza del modello nella posa proposta. Valori più alti, cioè meno negativi nei risultati ottenuti, sono più favorevoli, ma non rappresentano energie di legame.
DiffDock	Metodo generativo che propone possibili posizioni e orientazioni tridimensionali di un ligando rispetto a una proteina.
Endpoint energy	Indicatore energetico calcolato sottraendo all'energia del complesso le energie del recettore e del peptide considerati separatamente. Valori più negativi sono relativamente più favorevoli nel protocollo adottato, ma non corrispondono alla variazione di energia libera di legame (ΔG di legame).

ESM-2	Modello di linguaggio proteico utilizzato per valutare quanto una sequenza sia coerente con le regolarità apprese da grandi raccolte di proteine. Non predice direttamente il legame con EGFR.
ESMFold	Metodo di previsione della struttura tridimensionale a partire dalla sequenza. In questo workflow è impiegato per analizzare i peptidi isolati.
Farmacoforo	Rappresentazione tridimensionale delle proprietà chimiche ritenute necessarie per riprodurre determinate interazioni, indipendentemente dalla struttura specifica della molecola.
FlexPepDock	Protocollo Rosetta utilizzato per il raffinamento delle pose di peptidi associati a una proteina.
FoldX	Software basato su una funzione energetica empirica, utilizzato per confrontare la compatibilità strutturale ed energetica dei complessi.
GRAVY	Media dell'idropatia dei residui di una sequenza. Valori più negativi indicano maggiore idrofilia relativa, ma non misurano direttamente la solubilità.
HBA	Feature farmacoforica che rappresenta un accettore di legame a idrogeno.
HBD	Feature farmacoforica che rappresenta un donatore di legame a idrogeno.
HYD	Feature farmacoforica che rappresenta una regione idrofobica.
Ligando	Molecola o peptide valutato per la capacità di interagire con il recettore. Nella Pipeline 5 il termine indica principalmente le piccole molecole sottoposte a docking.
Near-miss rescue	Candidato che soddisfa tutti i gruppi farmacoforici obbligatori, ma non il requisito opzionale necessario per essere classificato come hit stretto.
NEG	Feature farmacoforica che rappresenta una regione con carattere negativo o anionico.
Pareto non dominato	Candidato per il quale non esiste un altro candidato almeno equivalente in tutti i domini e migliore in almeno uno. Non implica che sia ottimale in senso assoluto.
Peptide	Breve catena di amminoacidi. In questo workflow i peptidi sono progettati o selezionati per riprodurre l'interazione della catena D con la catena B di EGFR.
pLDDT	Indice, generalmente compreso tra 0 e 100, che esprime la confidenza locale del modello nella struttura prevista. Non misura direttamente l'accuratezza della posa legata o l'affinità.
POS	Feature farmacoforica che rappresenta una regione con carattere positivo o cationico.
Posa	Posizione, orientazione e conformazione tridimensionale proposta per un ligando rispetto al recettore.

Pose-support	Indicatore interno che combina confidence DiffDock e descrittori dei contatti per selezionare una posa rappresentativa. Non è un'energia fisica.
ProteinMPN N	Modello di inverse folding che propone sequenze amminoacidiche compatibili con una geometria di backbone assegnata.
Recettore	Componente del complesso rispetto alla quale viene valutato il legame. Nel presente workflow corrisponde alla catena B della chinasi EGFR nella struttura 3NJP.
RMSD	Misura dello scostamento geometrico medio tra strutture dopo il loro confronto spaziale. A parità di protocollo, valori più bassi indicano strutture più simili.
RMSF	Misura della fluttuazione media di ciascun residuo o atomo durante una traiettoria. Valori più bassi indicano minore mobilità locale.
Strict hit	Molecola che soddisfa tutti i gruppi farmacoforici obbligatori e almeno uno dei gruppi opzionali entro le soglie stabilite.
Vina score	Score empirico prodotto da AutoDock Vina. Valori più negativi sono relativamente più favorevoli nello stesso protocollo, ma non rappresentano una ΔG di legame rigorosa.

Glossario Progetto PEARL — Pipeline 1–5

Glossario consolidato dei principali termini utilizzati nel workflow integrato delle Pipeline 1–5. Le definizioni sono formulate secondo il significato assunto dai termini nel presente progetto.

Termine	Definizione
Alanine scanning	Sostituzioni ad alanina utilizzate per valutare la sensibilità mutazionale di specifiche posizioni; BuildModel e AnalyseComplex descrivono quantità differenti e non devono essere interpretati come misure equivalenti.
Bayesian optimization	Strategia di ottimizzazione sequenziale che utilizza un modello surrogato per proporre nuovi design sulla base delle osservazioni disponibili.
CamSol	Metodo computazionale utilizzato nella Pipeline 4 per valutare la solubilità delle sequenze peptidiche.
CLEAR	Metodo di ottimizzazione controfattuale utilizzato per cercare modifiche locali, minime e interpretabili rispetto a una sequenza di riferimento.
Contact persistence	Frazione dei frame analizzati nei quali uno specifico contatto è presente secondo il criterio geometrico adottato.
DiffDock	Metodo di docking basato su modelli diffusivi utilizzato nella Pipeline 5 per generare e valutare pose di piccoli ligandi rispetto a EGFR.
Endpoint energy	Proxy energetico calcolato su configurazioni campionate; nel presente workflow non equivale a una energia libera standard di binding (ΔG_{bind}).
ESM-2	Modello linguistico per proteine utilizzato nella Pipeline 4 per rappresentare e valutare informazione di sequenza.
ESMFold	Metodo di predizione strutturale utilizzato come controllo strutturale complementare; nel workflow non costituisce una validazione indipendente.
Evidence dependence	Dipendenza tra criteri computazionali che condividono input, pose o risultati intermedi; la loro concordanza aumenta la coerenza interna del workflow ma non equivale automaticamente a evidenze indipendenti.
FlexPepDock	Protocollo Rosetta utilizzato per docking e refinement di complessi proteina-peptide.
FoldX	Funzione energetica empirica utilizzata per stime relative delle variazioni energetiche associate a mutazioni o configurazioni strutturali.
Frame / snapshot	Configurazione atomica salvata a uno specifico istante di una simulazione di dinamica molecolare.
GBn2/ACE endpoint	Proxy energetico calcolato sulle configurazioni campionate mediante il protocollo GBn2/ACE adottato; non costituisce una misura rigorosa della ΔG di binding e non è direttamente convertibile in Kd o Ki.
GNN oracle	Modello neurale su grafi utilizzato per predire localmente il target delle varianti considerate nel workflow.
Historical computational lead	Candidato selezionato come prioritario in una fase precedente del workflow. La denominazione conserva la provenance della selezione e non implica una successiva validazione site-specifica.
Hotspot	Nel workflow storico, posizione o design anchor derivato dalle analisi computazionali; non implica un hotspot di binding sperimentalmente validato.

Lead	Candidato prioritario per analisi o verifiche successive; nel presente rapporto il termine non implica validazione sperimentale o sviluppo farmacologico.
MD	Dinamica molecolare: evoluzione temporale delle coordinate atomiche secondo un modello classico e uno specifico protocollo di simulazione.
Native EGF–EGFR interface	Regione dell'interfaccia extracellulare tra EGF ed EGFR definita strutturalmente nel sistema 3NJP e utilizzata come riferimento biologico per le verifiche site-specifiche.
Off-site pose	Posa localizzata al di fuori della native EGF–EGFR interface secondo la verifica site-specifica adottata nel workflow.
Pharmacophore	Rappresentazione astratta delle caratteristiche chimico-fisiche e geometriche ritenute rilevanti per l'interazione molecolare e utilizzata per guidare screening o generazione di candidati.
ProteinMPNN	Modello di progettazione di sequenze proteiche condizionato dalla struttura, utilizzato nella Pipeline 4 per generare nuove sequenze peptidiche.
Provenance	Tracciabilità dell'origine di una selezione, etichetta, posa o risultato lungo il workflow; consente di conservare il significato storico di una decisione senza trasformarlo in una validazione successiva.
REINVENT4	Framework generativo utilizzato nella Pipeline 5 per produrre candidati small-molecule successivamente sottoposti a screening e filtraggio.
RMSD	Deviazione strutturale globale rispetto a una configurazione di riferimento; il suo significato dipende dal sistema di allineamento e dal riferimento adottati.
RMSF	Misura della fluttuazione locale di residui o posizioni atomiche lungo una traiettoria.
Single-trajectory	Approccio nel quale più componenti energetiche sono valutate a partire dagli stessi snapshot; i frame della medesima traiettoria sono correlati e non costituiscono repliche indipendenti.
SingleTaskGP	Modello a processo gaussiano utilizzato nella fase di Bayesian optimization della Pipeline 4 come modello surrogato delle osservazioni disponibili.
Site-relevant pose	Posa che presenta pertinenza strutturale rispetto alla native EGF–EGFR interface secondo i criteri adottati nel workflow.
Vina local refinement	Ottimizzazione locale di una posa mediante AutoDock Vina; non equivale a una nuova ricerca di docking globale sull'intera superficie del recettore.
Whole-receptor docking	Ricerca di pose sull'intera superficie considerata del recettore senza imporre che la soluzione appartenga alla native EGF–EGFR interface.
ΔG_{bind}	Energia libera standard di binding; non coincide con una endpoint energy o con un semplice confronto di energie potenziali/implicite calcolate su snapshot.

Appendice A – Mappa dei notebook e provenienza dei risultati

Per ciascuna fase, il report utilizza come riferimento l'esecuzione completa più recente. Le versioni di test sono considerate esclusivamente come documentazione dello sviluppo e non contribuiscono ai risultati quantitativi finali.

Notebook	Versione o modalità utilizzata	Output principale utilizzato nel report
08a – ESM-2 Peptide Sequence Scoring	Esecuzione completa	Plausibilità ESM-2 delle sequenze di riferimento, profili posizione per posizione ed embedding
08b – ProteinMPNN Structure-Conditioned Peptide Design	test=FALSE	100 campioni ProteinMPNN corrispondenti a 24 sequenze uniche
08c – ESM-2/ ProteinMPNN Integrated Candidate Selection	Esecuzione completa	Ranking integrato e shortlist di cinque nuovi peptidi
08d – ProteinMPNN Candidate Structural Validation	Esecuzione completa	Validazione FoldX e Rosetta FlexPepDock dei cinque candidati
08e – Top ProteinMPNN Lead MD Validation	TEST=NO	Dinamica molecolare di 1 ns per MPNN_NEW_01 e MPNN_NEW_05
08f – ProteinMPNN Endpoint Energy Comparison	TEST=FALSE, esecuzione di produzione con 50 snapshot	Confronto energetico endpoint tra i due nuovi peptidi e i riferimenti
08g – ESMFold Structural Validation	Esecuzione completa	pLDDT e confronto strutturale ESMFold dei due nuovi peptidi
08h – Solubility/ Developability Screening	Versione FULL_COHORT-2, coorte completa con CamSol validato	Descrittori di sequenza e risultati CamSol autenticati per 27 sequenze complessive: 24 design ProteinMPNN e 3 riferimenti.
08i – Bayesian Optimisation with BoTorch	Versione FULL_COHORT-2, BoTorch eseguito	Modello pilota addestrato su cinque osservazioni strutturali, ranking di 19 sequenze non valutate e proposta di

08j – Final Multi-Objective Ranking	Versione EVIDENCE_TIERS –2	Ranking separato in tre livelli: 24 sequenze con evidenze comuni, cinque candidati strutturali e due candidati completamente valutati nel workflow computazionale
09a – MD-Derived Pharmacophore Extraction	Test=False , esecuzione di produzione	59 feature persistenti, 32 cluster spaziali e 17 feature core di consenso
09b – Pharmacophore Consolidation	Versione di produzione eseguita, file con suffisso –2	Consolidamento in 10 gruppi complessivi: cinque obbligatori, quattro opzionali e uno contestuale
09c – Pharmacophore-Constrained Molecular Generation	Test=False , modalità di produzione	Analisi di 1.000 molecole, 996 incorporazioni 3D, 83 assegnazioni obbligatorie complete e due hit stretti
09d – Chemical Filtering, Drug-likeness, Liabilities and Diversity	Esecuzione completa	Esclusione chimica dei due hit stretti e selezione di otto candidati della rescue track
09e – DiffDock Docking and Pose Evaluation	Esecuzione completa	80 pose DiffDock, selezione di una posa rappresentativa per ciascuno degli otto candidati
09f – Vina Local Rescoring and Interaction	Esecuzione completa	Rescoring e ottimizzazione locale Vina dei quattro candidati meglio classificati in 09e
09g – Integrated Pipeline 5 Lead Selection	Esecuzione completa	Selezione storica di MOL00583 come lead computazionale primario secondo il ranking multi-criterio di 09g, con MOL00484, MOL00600 e MOL00273 come ulteriori finalisti. La qualifica di MOL00583 è mantenuta come provenance del workflow e non implica validazione site-specifica rispetto alla native EGF–EGFR interface.
09h – MOL00583–EGFR MD Validation	Esecuzione completa	Follow-up MD della configurazione storica propagata da 09f. La verifica site-specifica mostra 0/400 frame a contatto con la native EGF–EGFR interface; configurazione off-site.
09i – MOL00583–EGFR Endpoint Analysis	Esecuzione completa	Analisi endpoint GBn2/ACE della traiettoria off-site di 09h: circa –20,10 ± 2,37 kcal/mol . Non costituisce ΔG rigorosa, Kd o Ki né validazione energetica del binding al sito EGF

09j – MOL00583 Free-Water MD Comparison	Esecuzione completa	Tre repliche free-water da 10 ns per la caratterizzazione conformazionale e di idratazione di MOL00583. Il confronto con la configurazione associata a EGFR è descrittivo e non costituisce un ciclo termodinamico.
09k – MOL00583– EGFR CUDA Replicates	Esecuzione completa	Tre rami stocastici da 10 ns della configurazione off-site ereditata da 09h. Verifica site-specifica: 0/2400 frame a contatto con l'interfaccia EGF; distanze minime 9,04 / 7,73 / 9,80 Å .

Le versioni precedenti di o8h, o8i e o8j vengono conservate come documentazione dell'evoluzione del workflow, ma non devono essere utilizzate per descrivere i risultati finali. In particolare:

- la versione precedente di o8h operava senza risultati CamSol e utilizzava soltanto descrittori proxy;
- la versione precedente di o8i verificava la predisposizione all'ottimizzazione bayesiana, ma non eseguiva BoTorch;
- la versione precedente di o8j confrontava direttamente soltanto MPNN_NEW_01 e MPNN_NEW_05 mediante ranking composito e analisi di Pareto.

Il report utilizza invece le versioni aggiornate a coorte completa, nelle quali CamSol è validato, BoTorch viene eseguito come selettore pilota e il ranking finale della Pipeline 4 è separato in livelli con diversa copertura delle evidenze.

Appendice — Note di approfondimento

1) ESM-2 è un modello di linguaggio addestrato su grandi collezioni di sequenze proteiche. Viene usato come riferimento statistico per valutare quanto una sequenza amminoacidica sia coerente con i pattern appresi dalle proteine note. Un punteggio più favorevole indica una maggiore compatibilità con tali regolarità, ma non dimostra che il peptide assuma una struttura stabile o si leghi a EGFR. ProteinMPNN affronta invece un problema di inverse folding: riceve come riferimento una struttura tridimensionale del backbone proteico e genera sequenze amminoacidiche compatibili con quella geometria. Nel progetto PEARL il modello ridisegna il frammento peptidico derivato da EGF, utilizzando come riferimento strutturale l'interfaccia con la catena B della porzione extracellulare di EGFR e proteggendo le posizioni considerate importanti per l'interazione. Le sequenze prodotte sono quindi condizionate dal backbone e dai vincoli imposti, ma il loro score non costituisce una previsione diretta dell'affinità di legame. I due modelli forniscono informazioni complementari: ESM-2 valuta la plausibilità della sequenza nel contesto dei pattern proteici appresi, mentre ProteinMPNN propone sequenze compatibili con una struttura tridimensionale definita. Per questo motivo i candidati selezionati vengono successivamente sottoposti a verifiche strutturali, dinamiche ed energetiche.

2) Il backbone è la struttura portante di una proteina o di un peptide. È costituito dalla successione degli atomi principali di ciascun amminoacido, mentre le catene laterali sono i gruppi chimici variabili collegati a questa struttura centrale. ProteinMPNN utilizza come riferimento la geometria tridimensionale del backbone e propone quali amminoacidi possano essere compatibili con essa. Nel workflow PEARL, quindi, il modello mantiene come guida la forma strutturale dell'interfaccia peptide-recettore e modifica la sequenza nelle sole posizioni autorizzate. La compatibilità con il backbone non dimostra tuttavia che il peptide generato si leghi effettivamente a EGFR.

3) Un farmacoforo è una rappresentazione astratta delle caratteristiche chimiche e spaziali ritenute necessarie per il riconoscimento molecolare di un bersaglio. Non corrisponde a una specifica molecola né descrive la struttura completa di un ligando. Indica invece la disposizione tridimensionale di proprietà quali donatori e accettori di legami a idrogeno, regioni idrofobiche o aromatiche e gruppi dotati di carica positiva o negativa.

Nella Pipeline 5 il farmacoforo è stato ricavato dalle interazioni osservate durante le simulazioni di dinamica molecolare dei complessi formati da EGFR con CF02, CF06 e MPNN_NEW_05. Dall'analisi di 300 frame complessivi sono state individuate 17 feature core di consenso, successivamente consolidate in 10 gruppi spaziali: cinque obbligatori, quattro opzionali e uno contestuale. La regola di screening richiedeva il soddisfacimento di tutti i gruppi obbligatori e di almeno un gruppo opzionale.

Il modello farmacoforico rappresenta quindi un'ipotesi computazionale sulle proprietà che una piccola molecola dovrebbe presentare per riprodurre parte delle interazioni osservate nei complessi peptide-EGFR. Il rispetto del farmacoforo non dimostra che una molecola si leghi effettivamente a EGFR, né fornisce una misura diretta dell'affinità o dell'attività inibitoria. I candidati selezionati devono essere sottoposti a ulteriori verifiche strutturali, chimiche e sperimentali.

4) Nel contesto della Pipeline 5, il termine ligando indica una piccola molecola candidata a occupare una regione dell'interfaccia di EGFR e a riprodurre parte delle interazioni descritte

dal farmacoforo derivato dalla dinamica molecolare. Gli identificativi MOL00583, MOL00484, MOL00600 e MOL00273 sono codici interni della libreria analizzata; non sono nomi farmacologici e non indicano composti già validati.

I quattro ligandi finalisti non sono hit farmacoforici stretti. I due composti che soddisfacevano la regola completa, MOL00336 e MOL00570, non hanno superato i filtri di qualità chimica. I finalisti provengono invece dalla rescue track: soddisfano i gruppi farmacoforici obbligatori, ma non l'intero criterio che richiedeva anche almeno un gruppo opzionale. Sono stati mantenuti perché hanno superato i filtri chimici e hanno ricevuto supporto nelle successive analisi di docking e rescoring.

MOL00583 è definito lead computazionale primario perché presenta la convergenza più ampia tra i sei assi di valutazione. Questa priorità non implica che possieda la migliore affinità reale né che sia già un inibitore di EGFR. DiffDock propone pose plausibili e Vina fornisce uno score comparativo dopo ottimizzazione locale; soltanto saggi sperimentali potranno verificare legame, inibizione, selettività e sviluppabilità. Il termine lead identifica quindi un candidato da sottoporre a verifiche successive, non un farmaco validato.

5) Il pLDDT, predicted Local Distance Difference Test, è un indice di confidenza assegnato dal modello di predizione strutturale a ciascun residuo della sequenza. Il valore è compreso tra 0 e 100: punteggi più elevati indicano che il modello considera più affidabile la geometria locale prevista attorno a quel residuo.

In termini orientativi, valori superiori a 90 indicano una confidenza locale molto alta, valori tra 70 e 90 una previsione generalmente affidabile, valori tra 50 e 70 una confidenza ridotta e valori inferiori a 50 una regione che deve essere interpretata con particolare cautela. Il pLDDT può essere sintetizzato mediante una media sull'intera sequenza, ma l'analisi posizione per posizione conserva maggiori informazioni.

Il pLDDT non misura l'affinità di legame, la stabilità termodinamica o l'attività biologica. Nel caso di peptidi corti analizzati fuori dal complesso recettoriale, come MPNN_NEW_01 e MPNN_NEW_05, rappresenta soltanto la confidenza del modello nella struttura locale prevista. Per questo motivo, nella Pipeline 4 viene interpretato insieme all'RMSD rispetto alla conformazione legata e alle altre evidenze strutturali e dinamiche.

Bibliografia essenziale

1. Lu C, Mi LZ, Grey MJ, et al. Evidenze strutturali di un accoppiamento debole tra legame del ligando e attivazione della chinasi nel recettore del fattore di crescita epidermico. *Mol Cell Biol.* 2010;30:5432–5443. doi:10.1128/MCB.00742-10.
2. Zhang X, Pickin KA, Bose R, Jura N, Cole PA, Kuriyan J. Inibizione del recettore EGF mediante il legame di MIG6 a un'interfaccia attivante del dominio chinasi. *Nature.* 2007;450:741–744. doi:10.1038/nature05998.
3. Hanold LE, Oruganty K, Ton NT, Beedle AM, Kannan N, Kennedy EJ. Inibizione della dimerizzazione di EGFR mediante mimetici del braccio di dimerizzazione con ponti triazolici. *PLoS One.* 2015;10:e0118796. doi:10.1371/journal.pone.0118796.
4. Fulton MD, Hanold LE, Ruan Z, et al. Peptidi conformazionalmente vincolati bersagliano l'interfaccia allosterica del dimero chinasi e inibiscono l'attivazione di EGFR. *Bioorg Med Chem.* 2018;26:1167–1173. doi:10.1016/j.bmc.2017.08.051.
5. Tavakoli F, Ganjalikhy MR. Progettazione di peptidi inibitori basata sulla struttura diretti al sito di legame del substrato peptidico nella tirosin-chinasi EGFR. *PLoS One.* 2019. doi:10.1371/journal.pone.0217031.
6. Progettazione razionale di peptidi che perturbano la dimerizzazione di EGFR: una nuova strategia per contrastare la resistenza ai farmaci nella terapia mirata del carcinoma polmonare. 2020. PMID 32721503.
7. Feiner RC, Kemker I, Krutzke L, et al. Peptidi leganti EGFR: dalla progettazione computazionale all'indirizzamento dei capsidi dei virus adeno-associati verso il tumore. *Int J Mol Sci.* 2020;21:9535. doi:10.3390/ijms21249535.
8. Lavoro correlato sul ripiegamento e sulla stabilizzazione di MIG6, 2022/2023 — da completare con riferimento bibliografico definitivo prima della sottomissione del manoscritto.
9. Sedan Y, Marcu O, Lyskov S, Schueler-Furman O. Server PeptiDerive: derivare inibitori peptidici dalle interazioni proteina–proteina. *Nucleic Acids Res.* 2016;44:W536–W541. doi:10.1093/nar/gkw385.
10. van Wier SP, Beekman AM. Progettazione di peptidi per controllare le interazioni proteina–proteina. *Chem Soc Rev.* 2025;54:1684–1698. doi:10.1039/D4CS00243A.
11. Bryant P, Elofsson A. Progettazione di peptidi leganti mediante ripiegamento inverso e predizione della struttura proteica. *Commun Chem.* 2023;6:229.
12. Dauparas J, Anishchenko I, Bennett N, et al. Progettazione robusta di sequenze proteiche basata sull'apprendimento profondo mediante ProteinMPNN. *Science.* 2022;378:49–56. doi:10.1126/science.add2187.
13. Lin Z, Akin H, Rao R, et al. Predizione della struttura proteica a livello atomico su scala evolutiva mediante un modello linguistico. *Science.* 2023.
14. Chen T, Pertsemlidis S, Chatterjee P. Progettazione di peptidi leganti condizionata dalla sequenza del bersaglio mediante modellazione linguistica mascherata / PepMLM. *Nature Biotechnology*, pubblicato online nel 2025, volume a stampa 2026.
15. Sormanni P, Aprile FA, Vendruscolo M. Il metodo CamSol per la progettazione razionale di mutanti proteici con solubilità migliorata. *J Mol Biol.* 2015;427:478–490. doi:10.1016/j.jmb.2014.09.026.
16. Shrestha R, Fajardo JE, Fiser A. Approcci farmacoforici basati sui residui per studiare le interazioni proteina–proteina. *Curr Opin Struct Biol.* 2021;67:205–211. doi:10.1016/j.sbi.2020.12.016.
17. Ibrahim & Zacharias. Stabilizzatori delle interazioni proteina–proteina da farmacofori derivati da simulazioni MD. *J Chem Inf Model.* 2026.

18. Voet A, Zhang KYJ. Modellazione farmacoforica come strumento di screening virtuale per la scoperta di piccole molecole inibitrici delle interazioni proteina–proteina. *Curr Pharm Des.* 2012;18:4586–4598. doi:10.2174/138161212802651616.
19. Xu D, Bum-Erdene K, Si Y, et al. Mimare le interazioni native per ottenere piccole molecole inibitrici di interazioni proteina–proteina strette. *J Chem Inf Model.* 2017;57:2250–2272. doi:10.1021/acs.jcim.7b00181.
20. Hayward D, Beekman AM. Strategie per convertire peptidi con motivi di ripiegamento e peptidi ciclici in piccole molecole dirette alle interazioni proteina–proteina. *RSC Chem Biol.* 2024;5:198–208. doi:10.1039/D3CB00222E.
21. Loeffler HH, He J, Tibo A, et al. REINVENT 4: moderna progettazione molecolare generativa guidata dall'IA. *J Cheminform.* 2024;16:20. doi:10.1186/s13321-024-00812-5.
22. Corso G, et al. DiffDock: passi di diffusione, torsioni e rotazioni per il docking molecolare. *ICLR 2023.*
23. Trott O, Olson AJ. AutoDock Vina: migliorare velocità e accuratezza del docking con una nuova funzione di punteggio, ottimizzazione efficiente ed esecuzione multithread. *J Comput Chem.* 2010;31:455–461. doi:10.1002/jcc.21334.
24. Hauser AS, Windshügel B. LEADS-PEP: un insieme di dati di riferimento per valutare le prestazioni del docking peptidico. *J Chem Inf Model.* 2016;56:188–200. doi:10.1021/acs.jcim.5b00234.
25. Wen Z, He J, Tao H, Huang SY. PepBDB: una banca dati strutturale completa delle interazioni biologiche peptide–proteina. *Bioinformatics.* 2019;35:175–177. doi:10.1093/bioinformatics/bty579.
26. Xu X, Zou X. PepPro: un insieme di dati strutturali non ridondante per il benchmarking del docking computazionale peptide–proteina. *J Comput Chem.* 2020;41:362–369. doi:10.1002/jcc.26114.